

**UNIVERSIDADE DO VALE DO ITAJAÍ
ESCOLA DO MAR, CIÊNCIA E TECNOLOGIA
CURSO DE CIÊNCIA DA COMPUTAÇÃO**

**UTILIZAÇÃO DE ALGORITMOS GENÉTICOS PARA
GERAÇÃO DE MOSAICO COM OS MELHORES PIXELS DE UMA
SÉRIE TEMPORAL DE IMAGENS PARA BATIMETRIA**

por

João Felipe Barbosa Cerqueira Carvalho

Itajaí (SC), novembro de 2022

**UNIVERSIDADE DO VALE DO ITAJAÍ
ESCOLA DO MAR, CIÊNCIA E TECNOLOGIA
CURSO DE CIÊNCIA DA COMPUTAÇÃO**

**UTILIZAÇÃO DE ALGORITMOS GENÉTICOS PARA
GERAÇÃO DE MOSAICO COM OS MELHORES PIXELS DE UMA
SÉRIE TEMPORAL PARA BATIMETRIA**

Área de Oceanografia e Ciência da Computação

por

João Felipe Barbosa Cerqueira Carvalho

Relatório apresentado à Banca Examinadora do
Trabalho Técnico-científico de Conclusão de Curso
do curso de Ciência da Computação para análise e
aprovação.

Orientador(a): Rodrigo Lyra, Mestre

Itajaí (SC), novembro de 2022

Dedico este trabalho a todos buscam um futuro melhor e como eu lutaram e lutam arduamente para conquistar seus sonhos, aos meus pais que sacrificaram muito para que eu tivesse acesso as oportunidades e a minha esposa, Emilly Gabriele, que me apoiou em todos os momentos que precisei.

AGRADECIMENTOS

Agradeço primeiramente a Deus por me conceder vida, saúde e inteligência para alcançar meus objetivos, aos meus pais que me ensinaram a buscar meus sonhos e fazer o meu melhor para ser o melhor, a minha esposa que esteve ao meu lado nos momentos em que mais precisei e a equipe do CASSIE que me apoiaram e auxiliaram no desenvolvimento deste trabalho.

RESUMO

CARVALHO, João Felipe Barbosa Cerqueira. Utilização de Algoritmo Genético para geração de mosaico com os melhores pixels de uma série temporal. Itajaí, 2022. 100 f. Trabalho Técnico-científico de Conclusão de Curso (Graduação em Ciência da Computação) – Escola do Mar, Ciência e Tecnologia, Universidade do Vale do Itajaí, Itajaí, 2022.

No contexto de batimetria existem inúmeras formas de se medir a profundidade de uma área submersa, como rios e lagos. Um dos métodos que vem sendo estudado e evoluído a mais de quarenta anos é a batimetria derivada de satélite. Este método busca facilitar a medição da profundidade de áreas de difícil acesso e necessita basicamente de dois elementos, sendo eles as imagens multibandas do local e um modelo de regressão, este segundo podendo ser algorítmico ou por aprendizado de máquina, trazendo um custo bem menor comparado a outros métodos existentes. Para obter as estimativas de batimetria geralmente são aplicados alguns processos no chamado fluxo de trabalho de batimetria, que envolve a escolha de imagens, o pré-processamento das imagens, aplicação no modelo de regressão e por fim a validação dos dados. Muitos dos algoritmos que existem hoje em dia tem ótimos resultados e estimativa, porém encontram problemas na parte de escolha de imagem e pré-processamento, muitos autores sempre apontam a necessidade de se ter o pré-processamento para obter melhores resultados, bem como a dificuldade de estimativa caso não seja obtida a quantidade de imagens suficientes sem nuvem para fazer a análise da batimetria. O presente trabalho busca trazer uma solução para escolha de imagens e pré-processamento, construindo uma aplicação que possa gerar máscaras de escolha de pixels de uma série temporal de imagens, tendo como produto um mosaico sem artefatos indesejáveis, como nuvens, sombras e embarcações, preservando as informações das bandas para manter a análise precisa. A necessidade desta solução nasceu de um requisito para o módulo de batimetria da ferramenta de análise costeira CASSIE e necessita-se de uma forma mais automatizada e precisa de escolha de imagens, em busca de melhorar consequentemente os resultados das estimativas. Para implementação foi utilizado Algoritmos Genéticos para buscar os pesos de escolha de pixels para gerar uma imagem destinada ao cálculo de batimetria, utilizando como equação de fitness o erro gerado da predição da batimetria com a imagem mosaico gerada pela escolha de pixel em relação aos dados de treino. A predição da batimetria é realizada por meio de um algoritmo de razão de bandas cedido pela equipe do CASSIE, onde é retornado o erro de predição com base nos dados de treino. Para o desenvolvimento do trabalho, foi utilizada a API do Google Earth Engine para o Python, visto que a plataforma planejada não atendeu as necessidades do código. Por fim, o presente trabalho busca contribuir na fase de escolha das imagens e pré-processamento do fluxo de cálculo da batimetria derivada de imagens de satélite, visando principalmente a aplicação no módulo de batimetria do CASSIE.

Palavras-chave: Batimetria. Composição de Pixels. Aprendizado de Máquina.

ABSTRACT

In the context of bathymetry there are numerous ways to measure the depth of a submerged area, such as rivers and lakes. One of the methods that has been studied and evolved for more than forty years is satellite-derived bathymetry. This method seeks to facilitate the measurement of the depth of areas of difficult access and basically requires two elements, which are the multiband images of the location and a regression model, the latter being able to be algorithmic or by the use of machine learning, bringing a much lower cost compared to other existing methods. To obtain bathymetry estimates, some processes are usually applied in the so-called bathymetry workflow, which involves choosing images, pre-processing the images, applying them to the regression model and finally validating the data. Many of the algorithms that exist today have excellent results and estimation, but they encounter problems in the part of image choice and pre-processing, many authors always point out the need to have pre-processing to obtain better results, as well as the difficulty estimate if not enough cloud-free images are obtained to perform the bathymetry analysis. The present paper seeks to bring a solution for image choice and pre-processing, building an application that can generate masks for choosing pixels from a time series of images, having as a product a mosaic without undesirable artifacts such as clouds, shadows and vessels, preserving the information of the bands to maintain an accurate analysis. The need for this solution arose from a requirement for the bathymetry module of the CASSIE coastal analysis tool, and the need for a more automated and accurate way of choosing images, in order to consequently improve the estimation results. For implementation, Genetic Algorithms was used to search for the pixel choice weights to generate an image destined for bathymetry calculation, using as fitness equation the error generated from the bathymetry prediction with the mosaic image generated by pixel choice in relation to the training data. The bathymetry prediction is performed using a band ratio algorithm provided by the CASSIE team, where the prediction error based on the training data is returned. For the development of the work, the Google Earth Engine API for Python was used, since the planned platform did not meet the needs of the code. Finally, this paper seeks to contribute to the phase of image selection and pre-processing of the bathymetry calculation flow derived from satellite images, mainly aiming at the application in the CASSIE bathymetry module.

Keywords: *Bathymetry. Pixel Composition. Machine Learning.*

LISTA DE ILUSTRAÇÕES

Figura 1. Fluxograma da fase de seleção.....	29
Figura 2. Fluxograma do funcionamento de um algoritmo genético.	30
Figura 3. Exemplo de uma população em AG em que cada indivíduo tem genes únicos.....	31
Figura 4. Processo de geração de uma população.	32
Figura 5. Fluxograma da geração de novas populações.	35
Figura 6. Relação de imagens versus medições em campo, com um detalhe para duas captações de imagem que só foi encontrada metade da imagem.	49
Figura 7. Fluxograma do modelo proposto.	52
Figura 8. Diagrama de sequência do modelo proposto para ser usado durante a implementação.....	54
Figura 9. Diagrama de sequência do funcionamento do modelo proposto com o sistema já existente do C.A.S.S.I.E.	57
Figura 10. Diagrama de classe do objeto indivíduo.	58
Figura 11. Comparativo da imagem modelo do primeiro cenário e imagem de mosaico.	66
Figura 12. Imagens selecionadas em diferentes datas para mostrar o padrão de morfologia da área.....	67
Figura 13. Comparativo do mapa batimétrico da imagem modelo do primeiro cenário e da imagem de mosaico.	Erro! Indicador não definido.
Figura 14. Comparativo da imagem modelo do segundo cenário e imagem de mosaico.	69
Figura 15. Comparativo do mapa batimétrico da imagem modelo do segundo cenário e da imagem de mosaico.	Erro! Indicador não definido.
Figura 16. Imagem de mosaico de uma máscara específica para o segundo cenário e mapa batimétrico gerado a partir desta imagem.....	71
Figura 17. Comparativo da imagem modelo do terceiro cenário e imagem de mosaico.	72
Figura 18. Comparativo do mapa batimétrico da imagem modelo do terceiro cenário e da imagem de mosaico.	Erro! Indicador não definido.
Figura 19. Imagem de mosaico de uma máscara específica para o terceiro cenário e mapa batimétrico gerado a partir desta imagem.....	73
Figura 20. Comparativo da imagem modelo do quarto cenário e imagem de mosaico.	75
Figura 21. Comparativo do mapa batimétrico da imagem modelo do quarto cenário e da imagem de mosaico.	Erro! Indicador não definido.
Figura 22. Comparativo da imagem modelo do quinto cenário e imagem de mosaico.	77
Figura 23. Comparativo do mapa batimétrico da imagem modelo do quinto cenário e da imagem de mosaico.	Erro! Indicador não definido.
Figura 24. Imagem de mosaico de uma máscara específica para o quinto cenário e mapa batimétrico gerado a partir desta imagem.....	78
Figura 25. Comparativo da imagem modelo do sexto cenário e imagem de mosaico.	79
Figura 26 Comparativo do mapa batimétrico da imagem modelo do sexto cenário e da imagem de mosaico.	Erro! Indicador não definido.
Figura 27. Imagem de mosaico de uma máscara específica para o sexto cenário e mapa batimétrico gerado a partir desta imagem.....	80

Figura 28. Comparativo da imagem do segundo período e imagem de mosaicos.	82
Figura 29. Comparativo da imagem do segundo período e imagem de mosaicos.	Erro! Indicador não definido.
Figura 30. Gráfico de distribuição das bandas da imagem modelo, da mediana e do mosaico.	83
Figura 31. Comparativo da imagem gerada pela mediana e a imagem de mosaico.....	84
Figura 32. Comparativo dos mapas batimétricos da imagem mediana e da imagem de mosaico.....	Erro! Indicador não definido.
Figura 33. Gráfico de distribuição das bandas da imagem modelo, da mediana e do mosaico.	85
Figura 34. Imagem dos pontos medidos em campo que originaram os dados batimétricos. ...	86
Figura 35. Gráfico de distribuição das diferenças entre a profundidade predita e a profundidade medida em campo.	87
Figura 36. Gráfico da variação da diferença entre a profundidade medida e a real em função da profundidade real	89

Lista de Quadros.

Quadro 1 - Relação de chave de busca e resultados	38
Quadro 2 – Comparativo de trabalhos relacionados.....	47
Quadro 3 – Parâmetros planejados para o algoritmo genético e seus respectivos valores.....	56
Quadro 4. Cenários de teste utilizados nas simulações.	63

LISTA DE TABELAS

Tabela 1 - Porcentagem de mutação em cada banda do pixel	55
Tabela 2. Pesos para cada banda – Primeiro Cenário/Primeiro teste.	65
Tabela 3. Pesos para cada banda – Primeiro Cenário/Segundo Teste.	67
Tabela 4. Pesos para cada banda – Primeiro Cenário/Segundo Teste.	68
Tabela 5. Pesos para cada banda – Terceiro Cenário/Segundo Teste.	71

LISTA DE ABREVIATURAS E SIGLAS

SDB	Satellite Derived Bathymetry – Batimetria derivada de satélite
ML	Machine Learning – Aprendizado de máquina.
IA	Inteligência Artificial
AG	Algoritmos Genéticos
UFSC	Universidade Federal de Santa Catarina
LIA	Laboratório de Inteligência Aplicada
CASSIE	Coastal Analyst System from Space Imagery Engine
DHN	Diretoria de Hidrografia e Navegação
DGPS	Differential Global Positioning System
GPS	Global Positioning System
CHM	Centro de Hidrografia da Marinha
IHO	International Hydrographic Organization
SONAR	Sound Navigation and Ranging
ADCP	Acoustic Doppler Current Profiler
LASER	Light Amplification by Stimulated Emission of Radiation
LIDAR	Light Detection and Ranging
ALB	Airborne Laser Bathymetry
NIR	Near InfraRed (infravermelho próximo).
IMU	(Unidade de Medida inercial de navegação)
API -	Application Programming Interface
GEE	Google Earth Engine
RF	Random Forest
RMSE	Root Mean Squared Error (Erro Quadrático Médio)
MAE	Mean Absolut Error (Erro Médio Absoluto)
IOPs	
SNR	Signal-to-Noise Ratio (relação sinal-ruído)
DN	Digital Numbers
ToA	Top of the Atmosphere (Topo da Atmosfera)
C2RCC	Case 2 Regional CoastColour
USGS	United States Geological Survey
ACCA	Automated Cloud Cover Assessment)
FMASK	Function of Mask
ESA	European Space Agency
6S	Second Simulation of The Satellite Signal in The Solar Spectrum
FLAASH	Fast Line-of-sight Atmospheric Analysis of Spectral Hypercubes
ATCOR	Airborne Atmospheric and Topographic Correction
QUAC	Quick Atmospheric Correction). Topographic Correction
NDWI	Normalized Difference Water Index (Índice de Água de Diferença Normalizada)
GIS	Geographic Information System
SVM	Support Vector Machine
DL	Deep Learning
RN	Redes Neurais
RNA	Redes Neurais Artificiais
CE	Computação Evolutiva
PC	Personal Computer
DSAS	Digital Shoreline Analysis

SVR
MNC

Support Vector Regression (Regressão por Vetor de Suporte)
Maximum NDVI Composite

SUMÁRIO

1 INTRODUÇÃO	14
1.1 Problematização.....	16
1.2 Formulação do Problema.....	16
1.2.1 Solução Proposta	16
1.3 Objetivos.....	17
1.3.1 Objetivo Geral	17
1.3.2 Objetivos Específicos.....	17
1.4 Metodologia.....	18
2 FUNDAMENTAÇÃO TEÓRICA.....	19
2.1 BATIMETRIA	19
2.2 SENSORIAMENTO REMOTO	21
2.2.1 Pré-processamento das imagens.....	23
2.3 PROCESSAMENTO DIGITAL DE IMAGENS.....	24
2.3.1 Principais aplicações e métodos do processamento digital de imagens	25
2.3.1.1 Técnicas de pré-processamento digital de imagens.....	25
2.3.1.2 Técnicas de composição de pixels ou mosaico de pixels	27
2.4 Algoritmos genéticos	29
2.4.1 Métodos de seleção	32
Aqui serão listados alguns dos métodos mais comuns para o processo de seleção.....	32
2.4.1.1 Método baseado em roleta	33
2.4.1.2 Método baseado em classificação (rank)	33
2.4.1.3 Método baseado em torneio	33
2.4.2 Métodos de cruzamento	34
Aqui serão apresentados alguns exemplos de métodos de cruzamento existentes.	34
2.4.2.1 One-Point Crossover	34
2.4.2.2 Cruzamento aritmético	34
2.4.3 Mutação	35
2.5 C.A.S.S.I.E.....	36
2.6 Trabalhos relacionados	37
2.6.1 Seasonal Composite Landsat TM/ETM+ Images Using the Medoid (a Multi-Dimensional Median) - Flood (2013).....	40
2.6.2 High-Dimensional Pixel Composites From Earth Observation Time Series - Roberts et al. (2017).....	41
2.6.3 Generating Continental Scale Pixel-Based Surface Reflectance Composites in Coastal Regions with the use of a Multi-Resolution Tidal Model - Sagar et al. (2018)....	42
2.6.4 Automated Mosaicking of Sentinel-2 Satellite Imagery - Shepherd et al. (2020)	43
2.6.5 Enhancement Of The Segmentation Process Of Multicomponent Images Using Fusion With Genetic Algorithm – Awad et al. (2008)	44

2.6.6 Image Fusion by a Hybrid Multiobjective Genetic Algorithm Technique – Kulkarni (2022).....	45
2.6.7 Comparativo entre trabalhos	46
3 DESENVOLVIMENTO.....	48
3.1 Metodologia.....	48
3.2 Materiais e métodos.....	48
3.2.1 Dados	48
3.2.2 Métodos	49
3.3 Execução.....	51
3.3.1 Fluxo de trabalho.....	51
3.3.2 Construção dos códigos.....	57
Algoritmo Genético.....	57
Algoritmo de batimetria.....	59
3.3.3 Dificuldades e planos de contingência	60
3.4 Resultados e discussão.....	62
3.4.1 Análise e desenvolvimento de cenários de teste	62
3.4.2 Primeiro Cenário: Período de 01/05/2018 a 30/06/2018 – Região próxima ao porto.	64
3.4.3 Segundo Cenário: Período de 01/01/2018 a 30/04/2018– região próxima ao porto.	68
3.4.4 Terceiro Cenário: Período de 01/08/2018 a 30/12/2018– região próxima ao porto.	71
3.4.5 Quarto Cenário: Período de 01/10/2018 a 30/11/2018– região próxima ao porto.	73
3.4.6 Quinto Cenário: Período de 01/01/2018 a 30/05/2018– região próxima as ilhas.....	76
3.4.7 Sexto Cenário: Período de 01/06/2018 a 30/12/2018– região próxima as ilhas.	78
3.4.8 Comparação com a imagem mediana e análise de histogramas.	81
3.4.9 Comparativo de erros.....	86
4 CONCLUSÃO.....	90
4.1 Trabalhos futuros	92
5 REFERÊNCIAS	93

1 INTRODUÇÃO

Batimetria é a ciência que busca determinar e representar a profundidade de áreas submersas, ou seja, ambientes aquáticos tais como rios, mares, lagos, entre outros. (PEREIRA; BARACUHY, 2008). Através de levantamentos batimétricos é possível fazer medições de profundidades de áreas submersas, com base na distância entre o fundo do local e a superfície, e representar estes dados em cartas náuticas, que são usadas para compreender o comportamento da área mapeada (GAGG, 2016).

O mapeamento das áreas submersas é uma estratégia importante, visto que este é um ambiente que engloba várias oportunidades econômicas, como também informações científicas valiosas (JESUS; LUGON JUNIOR; FERREIRA, 2015). Os dados batimétricos podem ser utilizados em estudos de evolução morfológica, avaliação de segurança nos canais de navegação, obras de dragagem, estudo de sedimentos, instalação de dutos, implantação e movimentação de portos, entre outros. Esses dados são transformados em vários documentos náuticos, como as cartas náuticas que são o principal produto da batimetria, mapas topobatimétricos, modelos 3D da região, entre outros, que permitem o reconhecimento do local (GAGG, 2016).

Existem muitos métodos para obtenção destes dados, sendo alguns muito rudimentares como o prumo de mão, régua graduada e outros mais avançados como ecobatímetro e sensoriamento remoto (KRUEGER, 2005 apud GAGG, 2016). O método mais comum para obtenção de dados batimétricos é por sistema acústico, utilizando o ecobatímetro, porém há fortes tendências para o uso de método de batimetria derivada de satélite em águas rasas, visto que as imagens têm uma capacidade preditiva muito boa e o fato de utilizar imagens, permite o mapeamento de áreas mais difíceis de estudar com métodos comuns (GAGG, 2016). O sensoriamento remoto é o método de obter dados sobre um objeto sem estar em contato direto com ele, geralmente utilizando dispositivos remotos que podem mapear os dados do objeto de estudo (LILLESAND; KIEFER, 1994). Este método pode utilizar vários dispositivos, permitindo a existência de outros métodos de batimetria, como batimetria por radar, batimetria por sistema acústico (ecobatímetro) e batimetria por processamento digital de imagens, ou batimetria eletroespectral (JESUS; LUGON JUNIOR; FERREIRA, 2015).

A utilização da batimetria derivada de satélite fornece dados batimétricos qualitativos, uma vez que utilizando técnicas de processamento digital de imagens, permite identificar a variação de profundidade pela cor do fundo. Essa variação é percebida pelos efeitos da

reflexão da luz solar no fundo do ambiente aquático. Existem métodos que permitem a análise de profundidade de vários tipos de situação de água, como água limpa, turva, costeira, etc. Os algoritmos atualmente usados variam muito sua precisão de acordo com alguns fatores, como turbidez da água, matérias do fundo, profundidade e qualidade da imagem, desta forma são aplicados costumeiramente em cenários de água rasa e clara (GAO, 2009; LYZENGA, 1978).

A aplicação de dados de imagens multitemporais podem melhorar a qualidade de dados de imagens para obtenção de batimetria. Este método possibilita a correção de dados e diminuição do erro de análise manual, utilizando várias cenas em períodos diferentes (PE'ERI et al, 2014). Trabalhos recentes, buscam aplicar pontos de calibração nas imagens multitemporais para obter a correção de imagens com algum tipo de erro de dado, como nuvem, ou material em suspensão (CABALLERO, STUMPF, 2019).

A escolha e o pré-processamento de imagens de satélite para o fim de batimetria é um dos passos mais importantes do método, além de ser um pré-requisito para obter uma boa precisão nas estimativas. Geralmente a parte de escolha de imagens é feita de forma manual, onde são escolhidas imagens que visualmente tem relevância para análise a ser feita, tornando o processo um tanto demorado, mesmo com a ajuda de softwares que filtram uma certa quantidade de imagens, dependendo da porcentagem de nuvens ou outros artefatos. Entretanto, visando agilizar essa etapa e trazer bons resultados para análise foram criadas e estudadas diversas técnicas baseadas em matemática e estatística para geração de mosaicos com os melhores pixels de imagens multitemporais. Essas técnicas conseguem gerar mosaicos com qualidades ímpar e podem preservar as propriedades radiométricas da imagem, tornando o seu produto de grande valia para diversos estudos (ROBERTS et al., 2017).

A utilização de aprendizado de máquina para o processo de escolha de imagens, bem como a análise e estimativa de batimetria, tem trazido grandes avanços para batimetria derivada de satélite. Com a utilização de IA (Inteligência Artificial), a escolha de imagens adequadas para utilização de batimetria, buscando cenas em que há água clara e limpa, otimizou um trabalho que levaria meses ou anos de filtragem de imagens, visto que a utilização de computação em nuvem ou supercomputadores, traria em minutos essa mesma filtragem. Essa tecnologia busca padrões nas imagens e gera um modelo que escolhe imagens com potencial elevado para batimetria, trazendo pixels com resolução de 10 m que possibilitam medição de até 30 m de profundidade com uma precisão relevante (GOODRICH, SMITH, 2021).

O trabalho estará limitado em criar uma aplicação que utiliza Algoritmos Genéticos para gerar uma máscara de seleção dos melhores pixels de uma série temporal de imagens de

um determinado local e construção de um mosaico com os pixels selecionados, para enfim ser destinada a algum algoritmo de batimetria. Como local de experimentação foi utilizado alguns pontos da Baía de Babitonga, onde foram fornecidos dados batimétricos por parte do projeto BaySqueeze. Como parte da validação da aplicação foi utilizado o algoritmo de batimetria que está sendo implementado pelo projeto para estimar a batimetria, onde é gerado um erro que irá mensurar o quanto o mosaico gerado pela aplicação é preciso comparado a uma imagem escolhida manualmente.

1.1 PROBLEMATIZAÇÃO

Nesta seção será discorrido melhor o problema introduzido, detalhando as características que esta pesquisa busca resolver para contribuir e melhorar a estimativa batimétrica através de imagens de satélite.

1.2 FORMULAÇÃO DO PROBLEMA

O cálculo da batimetria em imagens de satélite, feito por algoritmos que buscam quantificar a relação da refletância do espectro na coluna d'água em profundidade, pode sofrer divergências e certos problemas devido a artefatos e ruídos nas imagens. Os artefatos mais comuns que atrapalham a análise de imagens de satélite para o cálculo de batimetria são nuvens, sombra de nuvens, variação de maré, ruído atmosférico, barcos, material suspenso, entre outros. A presença desses ruídos pode inibir o cálculo da batimetria na coordenada em que se tem esse ruído, necessitando que essa localização seja preenchida por pixels de uma imagem de outra data próxima para que a análise seja completa no local, usando assim séries de imagens multitemporais.

Como as imagens utilizadas para o processo de batimetria elaborado pelo CASSIE depende de uma escolha manual ou de uma imagem mediana do período selecionado pelo usuário, nem sempre a imagem terá a qualidade necessária para o cálculo da batimetria, pois pode ocorrer de existir ruídos como nuvens, ondas, ruídos atmosféricos, entre outros, nas datas selecionadas. Com isso o problema que este trabalho busca resolver é encontrar um método de filtragem de nuvens e outras características de uma coleção de imagens, sem que a imagem resultante perca suas características radiométricas e gere uma estimativa batimétrica com o menor erro possível.

1.2.1 Solução Proposta

Este trabalho busca contribuir na escolha de imagens para aplicação em algoritmos de batimetria, automatizando a escolha das imagens e buscando eliminar os ruídos mais comuns que atrapalham o cálculo da batimetria. A proposta é a criação de uma aplicação que utiliza Algoritmos Genéticos onde, baseado nas bandas de imagens de satélite, possa gerar os pesos para construção de uma máscara de escolha de pixels e após gere um mosaico suficiente para o cálculo de batimetria. Esta aplicação está prevista para implementação no módulo de batimetria do projeto CASSIE (*Coastal Analyst System from Space Imagery Engine*) e foi comparada com as tecnologias utilizadas na ferramenta para comparar o impacto do mosaico gerado no cálculo de batimetria. Vale ressaltar que a solução não busca implementar um algoritmo de batimetria, apenas gerar uma máscara de escolha de pixel e montar um mosaico com estes pixels para então aplicar no algoritmo de batimetria.

1.3 OBJETIVOS

Nesta seção será apresentado os objetivos a serem atingidos neste trabalho, buscando utilizar ML para resolver problemas relacionados a batimetria, especificamente na parte de filtragem de imagens e preparação das imagens.

1.3.1 Objetivo Geral

Construir uma aplicação que permita gerar mosaicos com os melhores pixels de uma série temporal de imagens, destinadas a aplicação no cálculo de batimetria, utilizando algoritmos genéticos.

1.3.2 Objetivos Específicos

- Escolher as principais características que dificultam a filtragem de imagens e o cálculo de batimetria tratadas com esta pesquisa;
- Desenvolver um modelo de algoritmo genético para seleção dos melhores pixels da entrada de imagens e geração de mosaico;
- Aplicar as imagens geradas pelo modelo de algoritmo genético em algoritmos de batimetria em regiões selecionadas da Baía de Babitonga;
- Avaliar as imagens construídas em função das características e da aplicação no algoritmo de cálculo de batimetria, comparando com as soluções de escolha manual e imagem mediana.

1.4 METODOLOGIA

Como metodologia para identificar as características que dificultam a filtragem de imagens e a batimetria, foram realizadas reuniões com os envolvidos no projeto de batimetria, para entender quais as principais dificuldades encontradas no projeto que poderiam ser tratadas ou resolvidas nesta pesquisa. Com isso foi feita uma pesquisa bibliográfica para buscar artigos e revistas que fossem abordados os problemas passados pela equipe do projeto, correlacionando ou não com o objetivo da pesquisa que é a utilização de ML para solucionar os problemas relacionados ao SDB (*Satellite Derived Bathymetry*).

Vale destacar que parte da referência bibliográfica foi indicada pela equipe do projeto, visto que já são feitas pesquisas na área, desta forma os resultados dos artigos selecionados foram filtrados a partir dos modelos passados, a fim de ter referências na mesma qualidade e relevância.

A fundamentação teórica foi baseada nas referências obtidas nas pesquisas bibliográficas realizadas, complementadas com pesquisas bibliográficas de assuntos específicos da área de batimetria, como definições e processos realizados, visando contextualizar esta área e relevar sua importância.

Para obtenção das imagens utilizadas no desenvolvimento do projeto, foi solicitada a equipe do projeto, que detêm levantamentos batimétricos feitos em campo e que podem ser utilizados como base para treinamento e validação dos resultados retornados do modelo a ser construído.

2 FUNDAMENTAÇÃO TEÓRICA

As seções a seguir buscam definir melhor os conceitos relacionados ao tema de batimetria, sensoriamento remoto, batimetria por imagens de satélite e o uso de processamento de imagens e IA nesse contexto.

2.1 BATIMETRIA

A realização de estudos sobre o oceano e ambientes aquáticos é um processo muito importante para oceanografia e demais áreas que tem dependências aquáticas. A batimetria é uma das áreas mais importantes para o estudo do oceano, sendo responsável pela medição das profundidades submersas. Sua importância é definida em vários aspectos, como navegação marítima, portos, dragagem, etc. (GAGG, 2016), (LI et al., 2019)

Segundo Gagg (2016), a palavra batimetria vem da junção de duas palavras gregas “*bathus*” que significa profundo e “*metron*” que significa medida. Para Pereira J. e Baracuh J. (2008) batimetria é a ciência que visa determinar e representar o relevo do fundo de áreas submersas, como lagos, rios e mares, sendo expressa cartograficamente por curvas batimétricas com pontos de mesmas profundidades. Gagg (2016) define batimetria como um conjunto de princípios, métodos e convenções para determinar a medida de contorno da superfície submersa de ambientes aquáticos. Souza (2006, apud FRANÇA, 2019, p. 33) cita a batimetria como o primeiro e o mais tradicional método de investigação de áreas submersas, que foram evoluindo com o tempo, passando de ferramentas manuais para sistemas elaborados e precisos, fornecendo topografias do fundo e mapas precisos.

A realização dos processos referentes à batimetria pode ser feita através de vários métodos, alguns manuais e rústicos, como a régua de medição, outros mais precisos e caros, como o ecobatímetro. E existem os métodos remotos, que podem variar no custo e precisão. (KRUEGER, 2005 apud GAGG, 2016).

A medição de profundidades sofre algumas limitações em áreas de difícil acesso, visto que a medição manual é inviável. A batimetria por sensoriamento remoto vem sendo estudada e aperfeiçoada, buscando torná-la mais precisa e barata, principalmente utilizando imagens de satélite, que podem ser obtidas de forma gratuitas e podem ser processadas por algoritmos que estimam a batimetria de acordo com características da água e reflexão do sol no fundo do ambiente. (DANILO e MELGANI, 2019), (SALAMEH et al, 2019), (TURNER et al, 2021), (NIROUMAND-JADIDI et al, 2020).

Os dados batimétricos são obtidos através de Levantamentos Batimétricos, que tem por objetivo medir as profundidades, baseando-se nas coordenadas da embarcação na superfície da água, buscando representar e conhecer a morfologia de uma área submersa através de cartas náuticas. Os dados têm abordagem planimétrica, ou seja, em duas dimensões (X, Y) que se referem a posição da embarcação, que por sua vez é obtida por sinal DGPS (*Differential Global Positioning System*) (GAGG, 2016). Segundo Pereira e Baracuhy (2008) essa atividade consiste na obtenção das coordenadas de um ponto fornecida pelo sinal GPS (*Global Positioning System*) em tempo real e a profundidade obtida pelo ecobatímetro. Os dados obtidos são gerenciados por computadores que permitem a análise e geração de mapas e gráficos que permitem a geração da carta náutica do local.

O levantamento batimétrico em campo, assim como toda atividade, necessita de um planejamento prévio, tais como a localização geral da área a ser levantada e o contato de órgão competentes (GAGG, 2016). No Brasil as especificações e instruções técnicas para a execução de levantamentos batimétricos é feita pela DHN – Diretoria de Hidrografia e Navegação (Marinha do Brasil), que também é responsável pela construção das cartas náuticas. O órgão responsável por planejar e validar os dados obtidos nos levantamentos é o CHM (Centro de Hidrografia da Marinha), que por sua vez está relacionado ao órgão internacional de normativas batimétricas o *International Hydrographic Organization* (IHO) (IHO, 2008 apud BILHALVA, 2013). Após essa fase do planejamento, é feita uma inspeção no local para verificar as condições do local, como interferências no meio ambiente, projetos de construções no local etc., para então ser definido a metodologia e os equipamentos necessários. Vale ressaltar que é necessário se atentar aos fatores de visibilidade, profundidade, aplicação, tempo de execução, dimensão da área, entre outros fatores no planejamento do levantamento batimétrico, visto que qualquer um desses fatores pode tornar o levantamento menos produtivo (GAGG, 2016).

Existe muitas dificuldades quanto ao levantamento batimétrico em campo, dentre eles está a dificuldade de chegar ao local a ser levantado, o controle do posicionamento da embarcação, visto que não é possível manter estável os pontos de observação, como também a questão de recepção dos dados levantados, que podem sofrer com ruídos. (GAGG, 2016).

Segundo Krueger (2005) as medições podem ser feitas de forma direta com ferramentas como prumo de mão, máquina de sondar e estádias, ou de forma indireta com a utilização de sensores acústicos como ecobatímetro, sensores eletromagnéticos espaciais e aerotransportados. Ecobatímetro é a ferramenta mais utilizada em levantamentos batimétricos, que tem como função medir com acurácia a distância entre o transdutor (dispositivo que emite

ondas sonoras) e o fundo submerso (FRANÇA, 2019). O equipamento consiste em uma fonte emissora de sinais acústicos e um relógio que mede o intervalo de tempo em que o sinal sai do emissor e volta para o sensor. O som é captado pelo transdutor, que é um dispositivo com um sensor que transforma ondas de retorno de eco em sinais elétricos. Desta forma o ecobatímetro consegue medir com precisão a distância vertical entre o casco do barco, onde fica o ecobatímetro e o fundo aquático (PEREIRA; BARACUHY, 2008).

O sensoriamento remoto apresenta uma alternativa de baixo custo para geração de mapas batimétricos com boa precisão em locais difíceis podendo complementar ou iniciar levantamentos batimétricos onde os métodos mais comuns, como ecobatímetro e LIDAR, podem não atender devido à dificuldade de acesso ao local ou relevo submerso complexo (KRUG E NOERNBERG, 2005 apud BILHALVA, 2013).

2.2 SENSORIAMENTO REMOTO

A utilização de recursos analíticos e o avanço da tecnologia aprimoraram a forma em que é observada o planeta Terra, permitindo observar as características do planeta em diversas perspectivas, influenciando a forma de administrar inúmeros problemas, descobertas e ações do ser humano no planeta. Estes recursos tecnológicos, podem trazer mais rapidez e flexibilidade no mapeamento do planeta, mesmo que tenha limitações na questão de precisão e tratamento dos dados para usuários finais (KENNEDY et al., 2021).

Existe uma grande tendencia no uso dessa técnica, visto que existem vários fatores que impedem o levantamento batimétrico por meio de ecobatímetro ou LIDAR, além do grande custo e tempo de execução desses métodos. Existem vários estudos que visam empregar algoritmos e modelos de Inteligência Artificial (IA) para gerar mapas batimétricos com o uso de imagens de satélite (GAGG, 2016). O estudo da batimetria por imagens de satélite é um tema abordado a muito tempo, Lyzenga (1985), por exemplo, propõe o uso de métodos empíricos para obtenção de batimetria, métodos que são usados até hoje como referência. Outro autor muito citado é Stumpf (2003) que propõe alterações nos métodos de Lyzenga (1985) para melhorar a precisão dos algoritmos. Outros autores buscam utilizar modelos de aprendizado de máquina para gerar mapas batimétricos como Misra et.al (2018), Dickens e Armstrong (2019), Traganos et. al (2018), entre outros.

O sensoriamento remoto está dividido em dois ramos principais, com imagem e sem imagem, cada um com seu método de obtenção de profundidade, limitações e configurações. O método sem imagem, que já foi explanado anteriormente, é conhecido como LIDAR, que

utiliza tecnologia de pulso a laser ou óptico para medição da profundidade, onde são emitidos dois pulsos e a profundidade é medida pela diferença de tempo entre as duas (GAO, 2009). O Sensoriamento remoto através de imagens permite acesso aos dados de faixa do espectro eletromagnético e a partir disso estimar a batimetria. Com o uso de imagens de satélite é possível obter a profundidade, analisando pixels relevantes que tenham o dado de reflectância da luz no fundo da área submersa, fazendo uma relação da resposta espectral e a profundidade e assim produzir mapas batimétricos de qualidade para entendimento da morfologia do local (GAO, 2009).

Os dados de imagens são obtidos em diversas plataformas, podendo ser gratuitas, como por exemplo missões Landsat-8 e Sentinel-2 estão disponíveis para acesso gratuito e podem ser utilizadas para monitoramento, utilizando sensores que detectam várias bandas do espectro e permitem uma análise da coluna d'água com mais precisão. APIs (*Application Programming Interface*) como GEE (*Google Earth Engine*) integra um grande repositório de imagens das missões Landsat-8 e Sentinel-2 além de serviços de supercomputação em nuvem gratuitamente para maioria dos usuários, outros exemplos como EO Browser tool (Sentinel Hub) e Planet Labs Inc, oferecem serviços de acesso a imagens de satélite de forma gratuita. (SALAMEH et al, 2019), (Turner et al, 2021).

O princípio básico da batimetria por satélite é que a quantidade de radiação ou energia refletida na coluna d'água é proporcional a sua profundidade e a atenuação de luz na coluna de água é uma função do comprimento de onda onde o comprimento de onda mais curto atenua menos do que o comprimento de onda mais longo (GAO, 2009), (LUMBAN-GAOL, 2020). A batimetria é inferida a partir dos valores dos pixels das imagens, com base nas mudanças de intensidade de uma fonte externa de radiação, como por exemplo a luz do sol. Estas imagens são geradas por radiômetros que permitem visualizar várias bandas do espectro e assim analisar a variação de intensidade em diversas bandas para identificar a profundidade do ambiente submerso (FREIRE, 2017).

Um importante processo para o sensoriamento remoto é a técnica utilizada para estimar a batimetria, sendo ela por método analítico ou empírico, essa técnica visa encontrar a batimetria observando características únicas da coluna d'água. Dentre as técnicas de sensoriamento remoto por imagem, existem várias opções de estimativa, como a determinação por variação de micro-ondas para determinar a profundidade em casos de rugosidade marítima, ou ondas. Além desta, existe a estimativa através das propriedades radiométricas da imagem e assim determinar a profundidade, através da concentração de irradiância de certas bandas em locais da imagem, tendo como formas a imagem estática e a imagem de vídeo,

sendo a segunda aplicada de forma mais eficiente para área intertidal, que sofre com a variação da maré e por conta disso essa forma pode identificar a variação da maré e determinar a profundidade do local (GAO, 2009).

Atualmente existem alguns métodos de obter batimetria derivada de satélite, estes métodos são baseados em conceitos de refletância de luz na superfície e podem ser divididos em métodos empíricos, analíticos e semi-analíticos, cada um com sua característica de derivação (GAO, 2009). A grande diferença entre os métodos empíricos e métodos analíticos é que os métodos empíricos buscam relações entre a profundidade e as características da imagem através de observações e assim necessitam de dados no local para calibração, enquanto os métodos analíticos baseados em física precisam apenas de correção atmosférica e de distorções subsuperficiais (TURNER et al, 2021).

Outro processo importante para o sensoriamento remoto é a aquisição dos dados de imagem. Este processo precisa acompanhar as datas de medição de campo para que possa haver validação dos dados estimados com dados de medição reais. Desta forma é necessário filtrar as datas das imagens para que compreendam as datas de medições como cartas náuticas e dados de batimetria em campo. Este processo pode levar a diminuição de dados de imagem, visto que algumas datas não têm cobertura do satélite ou a cobertura foi feita em dias nublados. (MISRA et al., 2018).

2.2.1 Pré-processamento das imagens

O pré-processamento dos dados de imagens para o sensoriamento remoto, vem sendo essencial para qualquer análise feita. Visto que o emprego do pré-processamento, elimina ruídos da imagem e efeitos atmosféricos, refletância desnecessária, brilho do sol e distorções gerais que pode haver na imagem. Para isso são feitas etapas de pré-processamento, de acordo com o resultado desejado de cada imagem, visando o melhor aproveitamento e precisão na estimativa da batimetria (MISRA et al., 2018).

Neste passo pode ser utilizado vários métodos para corrigir efeitos da imagem, eliminar artefatos desnecessários, entre outros pré-processamentos. Muitos autores, optam pela utilização de softwares já prontos para essa finalidade, como Misra et al. (2018) que utilizou o software ENVI 5.1 para correção atmosférica e calibração radiométrica, sendo a segunda necessária para converter os valores DN (*Digital Numbers*) em refletância de topo da atmosfera (ToA). Já Traganos e Reinartz (2018) utilizaram a rede neural C2RCC (Caso 2 Regional CoastColour) para executar a correção atmosférica das imagens.

Um dos passos de pré-processamento básicos é a máscara de nuvens, onde, em cada imagem contém uma banda de qualidade da imagem, gerada pelo provedor dos dados, por exemplo USGS (*United States Geological Survey*) para missões Landsat ou ESA (*European Space Agency*) para missões Sentinel-2, contendo uma máscara de nuvem por pixel. Com isso é possível delimitar a porcentagem de nuvem que se deseja nas imagens, onde a porcentagem é determinada pela quantidade de pixels com nuvem na imagem, sendo descartadas todas as imagens que não atingirem a porcentagem desejada (VOS et al., 2019).

As missões Landsat e Sentinel-2 oferecem uma série de pré-processamentos já implementados com correção de brilho, nuvens e atmosférica, permitindo a filtragem de imagens de boa qualidade já na extração de dados. Essas missões estão disponíveis através da ferramenta Google Earth Engine (GEE) que dá acesso a computação em nuvem para correções de imagem e filtragem de banda, além de acesso as imagens dessas missões totalmente gratuito. (TRAGANOS et al., 2018).

Alguns autores utilizam algoritmos de processamento digital de imagens para separar os dados relevantes da coluna d'água, eliminar nuvens, correção atmosférica e separação de água e terra. Roberts et al. (2017) utilizou os algoritmos ACCA (*Automated Cloud Cover Assessment*) e FMASK (*Function of Mask*) para identificar artefatos indesejados e retirar das imagens, analisando pixel a pixel e retirando esses artefatos, foi utilizado regras lógicas “OR” para aplicação de cada um desses algoritmos em cada pixel da imagem.

A separação de água e terra é outro passo importante para o pré-processamento, onde é feita a distinção do que é água e o que é terra, focando apenas a parte da imagem que se quer estimar batimetria. Muitas vezes é necessário pois a vegetação da parte terra pode absorver as bandas utilizadas e causar ruídos na imagem, desta forma é utilizado geralmente a banda infravermelho próximo e médio para fazer essa separação (MISRA et al., 2018).

2.3 PROCESSAMENTO DIGITAL DE IMAGENS

Atualmente com o crescimento do uso de dados de imagem para diversos processos e áreas, se fez necessário o processamento extenso desses tipos de dados, que frequentemente podem sofrer ruídos e distorções mediante a forma que são adquiridas e distribuídas. Para tanto são usadas técnicas de processamento digital de imagens, que inclui principalmente a remoção de ruído, implantação de criptografia, compactação, armazenamento e muitos outros aspectos relacionados a imagem (ZHANG et al., 2018).

2.3.1 Principais aplicações e métodos do processamento digital de imagens

A eliminação do ruído da imagem é importante devido a distorção de alguns dados presentes na imagem por conta da aquisição, processamento e distribuição que podem distorcer características importantes e que precisam ser ajustadas para retomar o significado original. O ruído é derivado principalmente do processo de transmissão e quantização, ele pode ser dividido entre ruído aditivo, ruído multiplicativo e ruído de quantização (ZHANG et al., 2018).

Os métodos mais comuns de filtragem de ruído incluem um método de filtro médio, um método de filtro de Wiener adaptativo, um filtro de mediana e um método de transformada *wavelet*. O filtro médio, pode ser basear na média de vizinhança de pixels, podendo eliminar ruídos de digitalização de imagem em troca de uma certa ambiguidade proporcional ao raio do campo de vizinhança escolhido. O filtro Wiener ajusta o ruído com base na variação local da imagem, podendo eliminar principalmente ruídos brancos. Já o filtro por mediana é comumente usado para filtragem de ruídos sal e pimenta de uma imagem, usando suavização linear. A análise *wavelet* utiliza de coeficientes de camadas de ondas leves para eliminar os ruídos e preservar os detalhes da imagem (ZHANG et al., 2018).

Outra aplicação muito comum para o pré-processamento é a compressão ou compactação dos dados de imagens, visando a eliminação de dados redundantes ou a compressão de dados para um tamanho de arquivo menor para envio e distribuição. Essa técnica é muito usada no sensoriamento remoto, visto que as imagens de satélite contêm muitos dados, muitas vezes com várias bandas e alta resolução (ZHANG et al., 2018).

2.3.1.1 Técnicas de pré-processamento digital de imagens

O pré-processamento aplicado ao sensoriamento é um passo importante para uma análise correta da imagem e a extração de dados desejada, principalmente em casos de estimativa de batimetria por satélite, este processo é aplicado antes da aplicação de algoritmos ou análises por aprendizado de máquina. O sensoriamento remoto para imagens multiespectrais enfrenta desafios com ruídos atmosféricos e propriedades da água, devido a interações complexas entre a energia eletromagnética emitida pelo sol, como absorção e dispersão na atmosfera e na água como clorofila - A, material suspenso e matéria orgânica dissolvida (BASITH e PRASYANI, 2020).

Para o sensoriamento remoto, uma das correções mais importantes realizadas pelo processamento digital de imagens é a correção atmosférica. Esse efeito se tornou um grande desafio, visto que ele degrada a qualidade radiométrica da imagem de satélite e consequentemente pode gerar análises errôneas das bandas da imagem. Existem vários modelos implementados para corrigir esses efeitos, esses modelos geralmente são divididos em três categorias, modelo de transferência radiativa, modelo relativo baseado em imagem e modelo empiricamente estatístico (BASITH e PRASTYANI, 2020).

O modelo de transferência radiativa oferece o melhor desempenho e maior precisão, exigindo conhecimento prévio e tempo real da atmosfera, além de parâmetros específicos. Para esse modelo são utilizados vários algoritmos que usam a transferência radiativa, muitos deles muito comuns entre as técnicas de pré-processamento de imagem de sensoriamento remoto, como o 6S (*Second Simulation of The Satellite Signal in The Solar Spectrum*), o FLAASH (*Fast Line-of-sight Atmospheric Analysis of Spectral Hypercubes*) e ATCOR (*Airborne Atmospheric and Topographic Correction*) (BASITH e PRASTYANI, 2020).

O modelo relativo oferece um processamento menos complexo e utiliza algoritmos que corrigem o efeito atmosférico com base em características da imagem, um exemplo é o QUAC (*Quick Atmospheric Correction*). Já o modelo empírico estatístico reduz e elimina o ruído atmosférico através de relações estatísticas entre a refletância de sensoriamento remoto com a refletância em imagem, por exemplo estatística linear (BASITH e PRASTYANI, 2020).

A separação de água e terra é outro passo importante para o sensoriamento remoto e tem sido um processo importante, principalmente na estimativa de batimetria. Essa separação é feita após a correção atmosférica e é feita para que a análise que será efetuada através de algoritmos ou Aprendizado de Máquina irá considerar apenas pixels de água. Um dos métodos mais comuns para separação de terra e água é através do Índice de Água de Diferença Normalizada (NDWI), fazendo separação através do infravermelho próximo (NIR) e região verde para separar a terra e vegetação. Algumas abordagens também usam a região azul para fazer a separação, visto que ele permanece mais tempo na água antes de ser absorvida, além de outras bandas de infravermelho para diferentes tipos de água. A função que calcula o NDWI é expressa na equação 1.

$$NDWI = \frac{Região\ azul - NIR2}{Região\ azul + NIR2} \quad (1)$$

Existem atualmente algumas pesquisas e trabalhos e até mesmo modelos prontos que visam levar o pré-processamento digital de imagens para o aprendizado de máquina, buscando otimizar o processo e obter resultados melhores que os algoritmos já existentes. Essas aplicações buscam utilizar abordagens diferentes como o uso de algoritmos genéticos e técnicas de Fuzzy para melhorar métodos já existentes ou até buscar novas relações que trariam melhoria para imagem final. Muitos dos estudos buscam, otimizar o método *Wavelet* para trazer melhorias as etapas do processamento digital de imagens e elevar os resultados desse método, mesmo que enfrentem desafios com a melhora de resolução das imagens atuais. (ZHANG et al., 2018).

2.3.1.2 Técnicas de composição de pixels ou mosaico de pixels

As composições de pixels estão cada dia se tornando mais necessárias no contexto de sensoriamento remoto, isso ocorre pois muitas vezes não é possível ter uma cobertura total de um local, que seja possível analisar de forma clara a superfície, devido a artefatos na imagem, principalmente nuvens e neblina. Dito isso, a composição de pixels visa remontar uma imagem de um local específico juntando pixels de uma série temporal do mesmo local em que seja possível retirar os pixels com ruídos, artefatos e demais problemas que afetem a análise e substituir por pixels do mesmo local com um cenário limpo e claro, mantendo as propriedades radiométricas da imagem (ROBERTS et al., 2017).

Existem duas técnicas principais para composição de pixels, a costura que junta uma série de imagens nítidas e a outra é o mosaico de pixels onde são combinados pixels de diferentes épocas baseando-se em algoritmos. O mosaico em geral traz resultados melhores, pois tem um equilíbrio de banda melhor que a costura de imagens nítidas, além de permitir a automatização dos algoritmos para lidar com grandes volumes de dados, principalmente dados de satélite (ROBERTS et al., 2017).

Esses mecanismos de escolha de “melhor” pixel, geralmente são baseados em estatística ou em regras específicas, como grau de verde na imagem, distância de nuvens, períodos de tempos específicos, ou até mesmo a junção de várias regras. O método estatístico é baseado em uma série de observações e cálculos que geram valores numéricos das concentrações em cada banda da imagem, em geral busca-se estabelecer uma média ou mediana dos valores observados e reconstruir os pixels com o valor que deveria ter. Muitas técnicas não conseguem preservar algumas relações das bandas nas composições, por exigir cálculos mais complexos, métodos de aprendizado de máquina ou grande poder

computacional. Para solucionar esse problema é preciso construir a composição através de técnicas estatísticas de alta dimensão, que possam analisar todas as bandas ao mesmo tempo e preservar as relações biofísicas das imagens, como por exemplo a mediana geométrica usada por Roberts et al. (2017) para reconstruir imagens da Tasmânia. (ROBERTS et al., 2017), (SAGAR et al., 2018).

Um dos problemas mais difíceis encontrados pela composição de pixels, em casos de mapeamentos de áreas aquáticas, é a variação de maré que causa valores diferentes de concentração das bandas de acordo com a altura da maré e que pode causar distorções na composição de uma série temporal. Esse problema se torna presente mesmo se utilizando de técnicas de índice de água, visto que a vizinhança pode trazer pixels de épocas em que a maré está diferente e até mesmo ter pixels de terra no meio. Para solução desse problema, tem se buscado métodos estatísticos pixel a pixel juntamente com modelos auxiliares que possam ter informação de maré e seja possível ligar as duas coisas, suavizando o efeito da maré. (SAGAR et al., 2018).

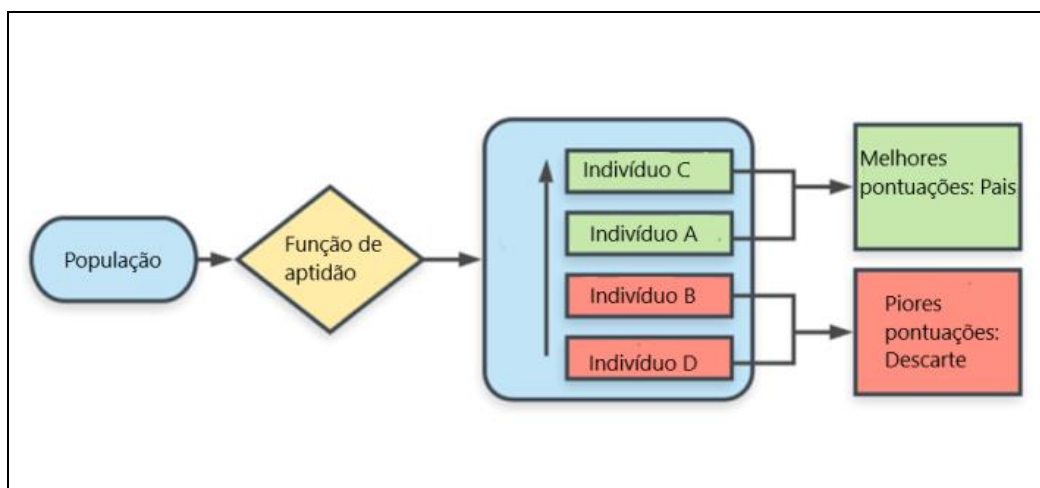
A qualidade da imagem composta é ditada principalmente por dois fatores, a qualidade das imagens de entrada e a quantidade de imagens de entrada. A qualidade geralmente não pode ser controlada, visto que existem muitos fatores que deixam a imagem distorcida, como nuvens, efeitos atmosféricos, sombras, entre outros. Entretanto se faz necessário ao menos algumas quantidades de imagens com boa qualidade, para se ter referências de todos os locais analisados. Por outro lado, mesmo que não haja qualidade suficiente em todas as imagens, quanto maior foi a base de imagens, mais precisa será a composição, visto que é possível se ter o mapeamento de todos os locais com um base maior, tornando esse o fator principal para a qualidade do mosaico. (SAGAR et al., 2018).

O uso de aprendizado de máquina pode auxiliar na forma de avaliação do melhor pixel e construir o mosaico, através de análises automatizadas com base em valores medidos em campo, ou através de regras definidas por algoritmos de classificação (SAGAR et al., 2018). Roberts et al. (2017) fala que os dados gerados pela mediana geométrica, um método estatístico utilizado para reconstruir pixels, pode ser utilizado como entrada de algum algoritmo de aprendizado de máquina. Com a aplicação de aprendizado de máquina é possível ter uma análise mais aprofundada e possivelmente trazer dados mais relevantes e normalizados para imagem. (SAGAR et al., 2018)

2.4 ALGORITMOS GENÉTICOS

Os algoritmos genéticos são baseados numa subseção da inteligência artificial chamada computação evolutiva em que as soluções são adquiridas em forma de seleção natural baseada em princípios biológicos como a evolução darwiniana. As soluções são avaliadas por uma heurística que determinará sua relevância, geralmente chamada por função de aptidão, onde é definida a influência de um indivíduo na próxima geração, essa fase é ilustrada pela figura 1. O objetivo é fazer com que as características individuais de uma solução se mesquem com outras características positivas de outras soluções até que a geração formada esteja única e absoluta gerando a chamada convergência (COLLINS, 2019).

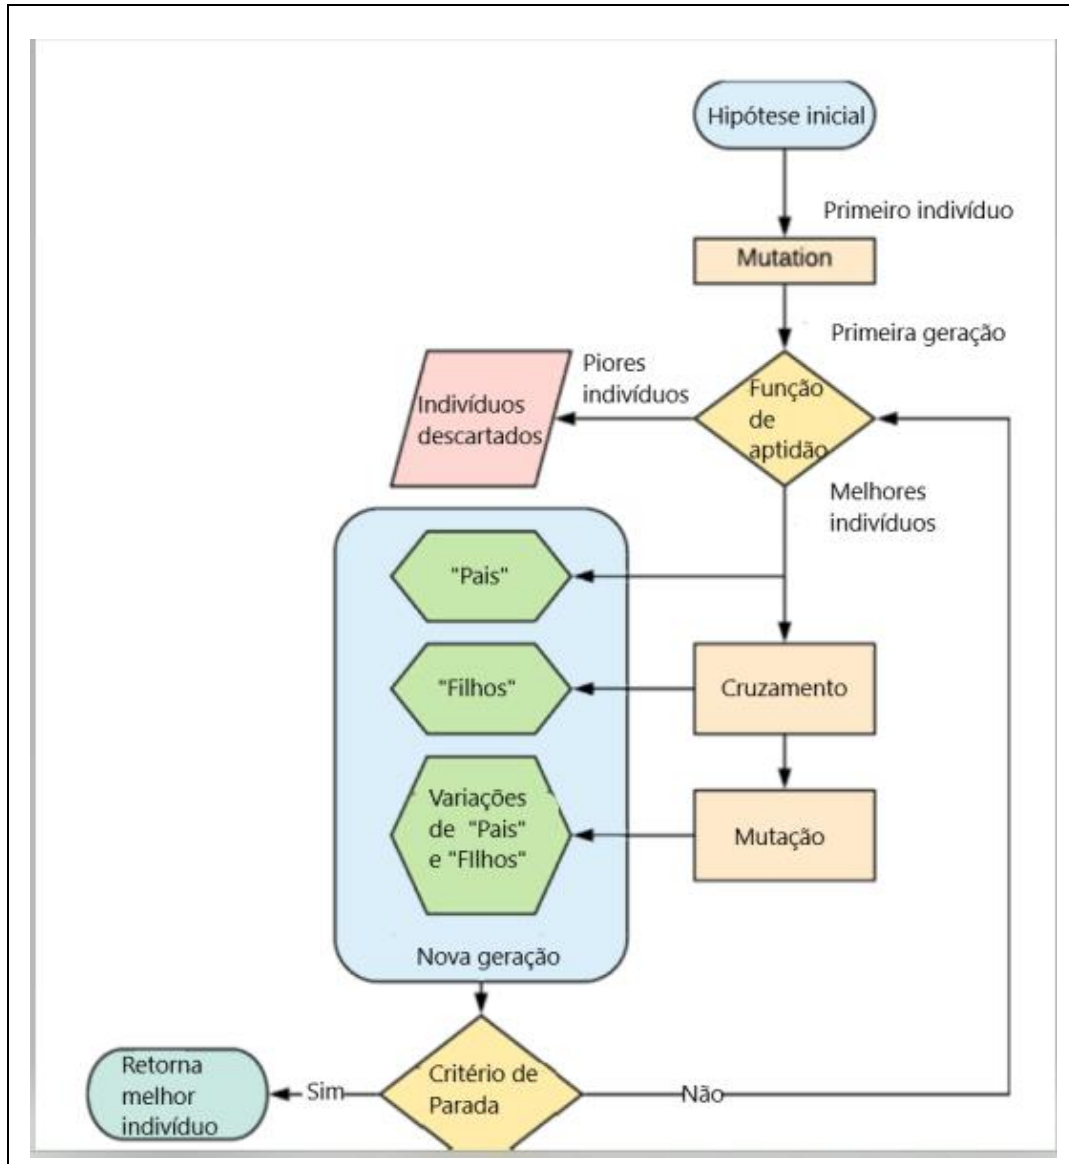
Figura 1. Fluxograma da fase de seleção.



Fonte: Adaptado de Costa et al. (2020).

Os indivíduos que tiverem características mais predominantes para o ambiente terão mais chances de gerar gerações que irão perdurar seus genes, o ambiente é simulado com a função de aptidão. Essa fase tem o objetivo de eliminar indivíduos que não tem grandes soluções ou que as soluções não irão perdurar muito e combinar soluções com mais potencial a fim de buscar a melhor solução possível (COSTA et al., 2020). A figura 2 demonstra o fluxo de trabalho de um algoritmo genético.

Figura 2. Fluxograma do funcionamento de um algoritmo genético.



Fonte: Adaptado de Costa et al. (2020).

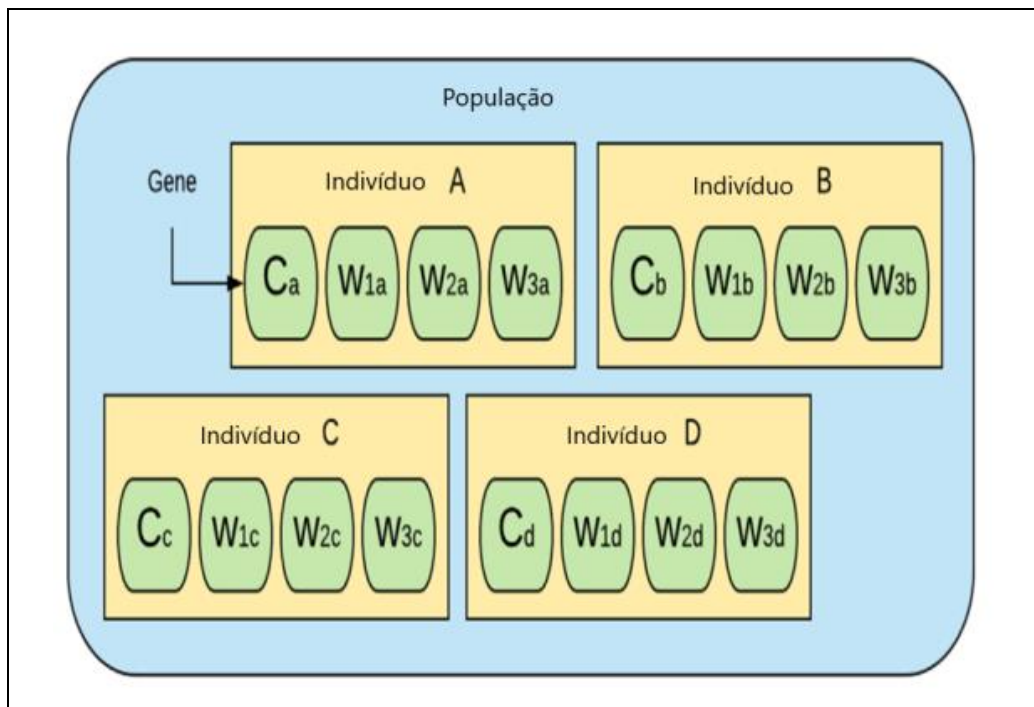
Em geral as técnicas de Computação Evolutiva (CE) têm características em comum, são essas a População de candidatos, propriedade de troca ou reprodução de inspiração biológica, aptidão ou medida heurística de sucesso e critérios de convergência que determina o nível de sucesso ou iterações máximas alcançadas (COLLINS, 2019).

Segundo Collins (2019) os algoritmos genéticos têm uma estrutura padrão em que são implementados, a estrutura e definição segundo o autor, está descrita abaixo:

- Inicialização: É a fase de geração de população em que são elencadas as soluções que serão iteradas, estas soluções geralmente são aleatórias, salvo exceções. A figura 3 ilustra um exemplo de população e a figura 4 demonstra o processo de geração de uma população;

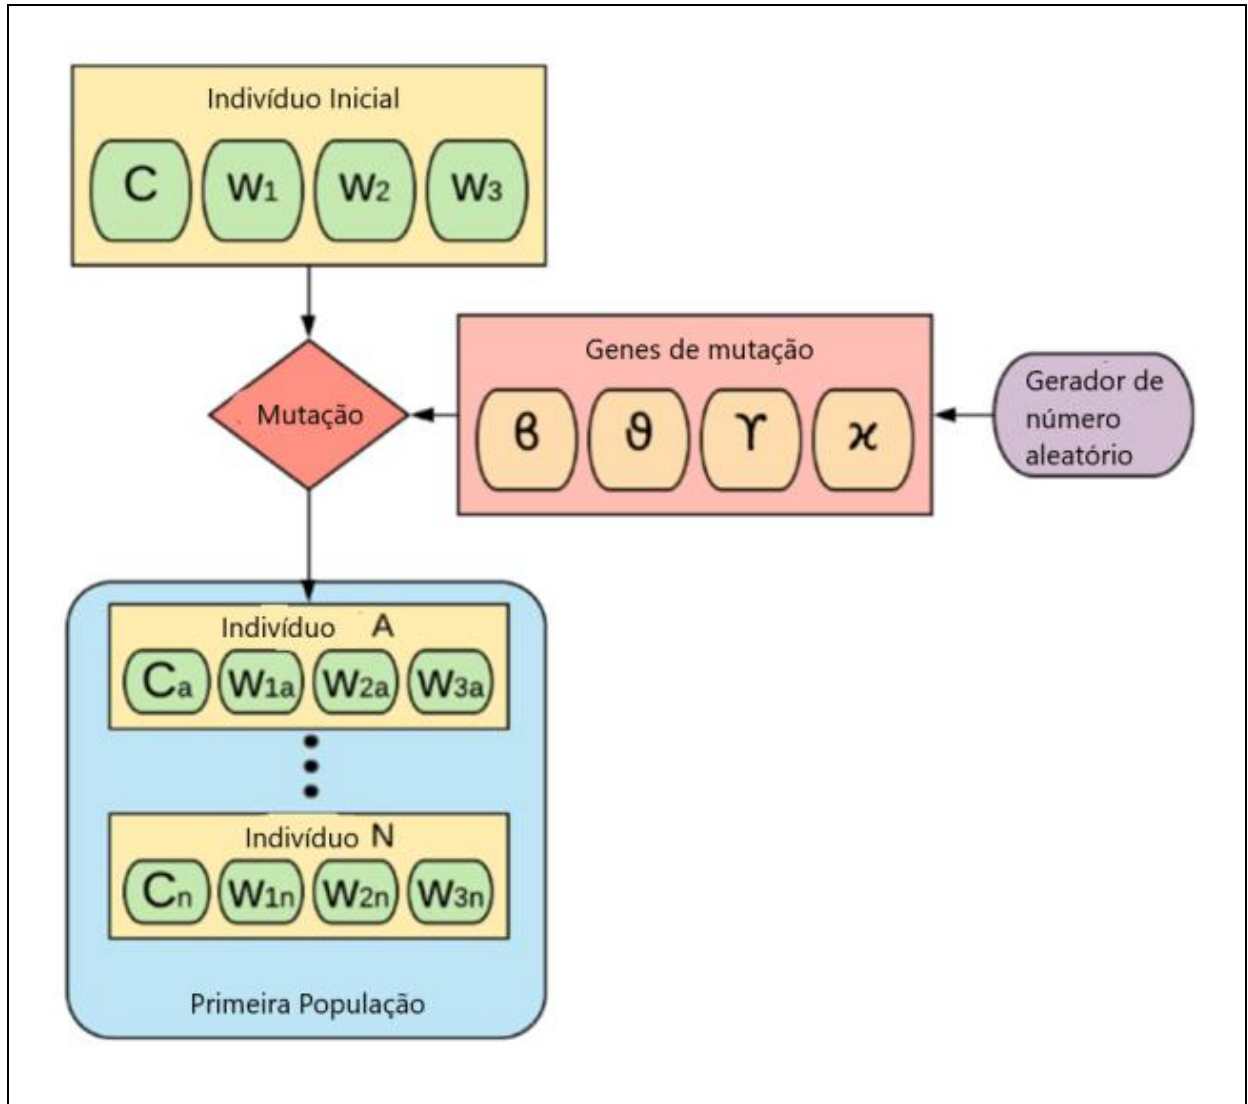
- Aptidão: Fase de determinação da pontuação de cada indivíduo da população de acordo com a função de aptidão;
- Critério de parada: Onde é determinado se uma solução é suficiente para parada das iterações ou outro critério de parada é selecionado caso não encontre nenhuma solução;
- Seleção: Fase de seleção de pares de indivíduos que passaram por um processo de cruzamento e mutação a fim de gerar novas gerações, conforme a figura 4 e a figura 5;
- Nova população: Repetição da fase de Seleção até que a população esteja inteiramente nova;
- Continuação: Repetição de todas as fases a partir da fase de Aptidão.

Figura 3. Exemplo de uma população em AG em que cada indivíduo tem genes únicos.



Fonte: Adaptado de Costa et al. (2020).

Figura 4. Processo de geração de uma população.



Fonte: Adaptado de Costa et al. (2020).

Para o passo de gera  o de uma nova popula  o existem tr s processos importantes, s o eles a sele  o, onde s o selecionados os indiv duos que ir o gerar as novas gera  es, o cruzamento (*crossover*) que   o processo de gera  o de novos indiv duos e por fim o processo de muta  o que visa alterar algum gene de alguns indiv duos para torn -lo diferente e buscar novos resultados (COLLINS, 2019), (COSTA et al., 2020).

2.4.1 M todos de sele  o

Aqui ser o listados alguns dos m todos mais comuns para o processo de sele  o.

2.4.1.1 Método baseado em roleta

Este método é uma das formas mais utilizadas de método de seleção, nela é criada uma roleta virtual onde os pais são escolhidos, onde cada indivíduo ocupa uma área proporcional ao seu *fitness*. O método consiste em calcular os valores *fitness* dos indivíduos e após somar todos eles para definir o tamanho da roleta, posteriormente é dividido o valor do tamanho da roleta pelo *fitness* de cada indivíduo para determinar quantas posições da roleta ele ocupará. (FILHO, 2018).

A seleção é feita por um ponteiro virtual que passará por todas as posições da roleta e irá parar em uma área que corresponderá a um indivíduo. Indivíduos com maiores *fitness* são comumente escolhidos, visto que a área que ele ocupará na roleta será maior que outros indivíduos. Entretanto, a seleção é feita de acordo com o número de indivíduos, possibilitando que um indivíduo seja selecionado várias vezes e outros não sejam selecionados, causando o problema comum deste algoritmo que é a possibilidade de um indivíduo de bom valor de *fitness* não ser selecionado e diminuir a eficácia do algoritmo genético. Para isso existe um método chamado *Stochastic Universal Sampling* (Amostragem Universal Estocástica) que divide a roleta em áreas de tamanhos iguais para todos os indivíduos, possibilitando a escolha justa e maior diversidade de indivíduos. (FILHO, 2018).

Segundo Lopes (2006) este método tende a ser agressivo na escolha, visto que ele privilegia indivíduos com melhor *fitness* e despreza indivíduos com pontuações menores, convergindo em poucas gerações e para um local específico.

2.4.1.2 Método baseado em classificação (rank)

O método baseado em *rank* se resume em ordenar todos os indivíduos da população de acordo com sua nota de *fitness*, considerando apenas a quantidade x de indivíduos com melhor valor. Feito isso é atribuído a cada indivíduo um valor de probabilidade de ser escolhido, independente da sua pontuação, podendo ser ajustado para que indivíduos com melhores notas tenham mais chances de ser escolhidos. Após isso é feito o sorteio com base na probabilidade de escolha. (BENTO e KAGAN, 2008)

2.4.1.3 Método baseado em torneio

O método de torneio é baseado no *fitness* individual dos indivíduos e não da população, comparando um número x , geralmente dois ou três, de indivíduos e selecionando o indivíduo de melhor *fitness* para gerar a próxima população. A escolha dos indivíduos é feita

aleatoriamente para comparação das pontuações, permitindo que sejam filtrados os melhores indivíduos em uma comparação aleatória. Este método tende a ser melhor que o método de roleta pois a pressão de escolha é menor. (FILHO, 2018).

Existem duas variações deste método, o torneio simples em que os indivíduos que não forem escolhidos podem participar novamente do torneio e o torneio da morte que elimina o indivíduo que perder na comparação, sendo excluído do torneio. A primeira variação tende a ter uma pressão seletiva menor, visto que indivíduos de melhor pontuação tem menos chances de não serem escolhidos, em troca de não ter uma variedade muito grande na população. Já a segunda variação tem mais chances de ter uma população mais diversificada, visto que os indivíduos não podem voltar a participar do torneio. (FILHO, 2018).

2.4.2 Métodos de cruzamento

Aqui serão apresentados alguns exemplos de métodos de cruzamento existentes.

2.4.2.1 One-Point Crossover

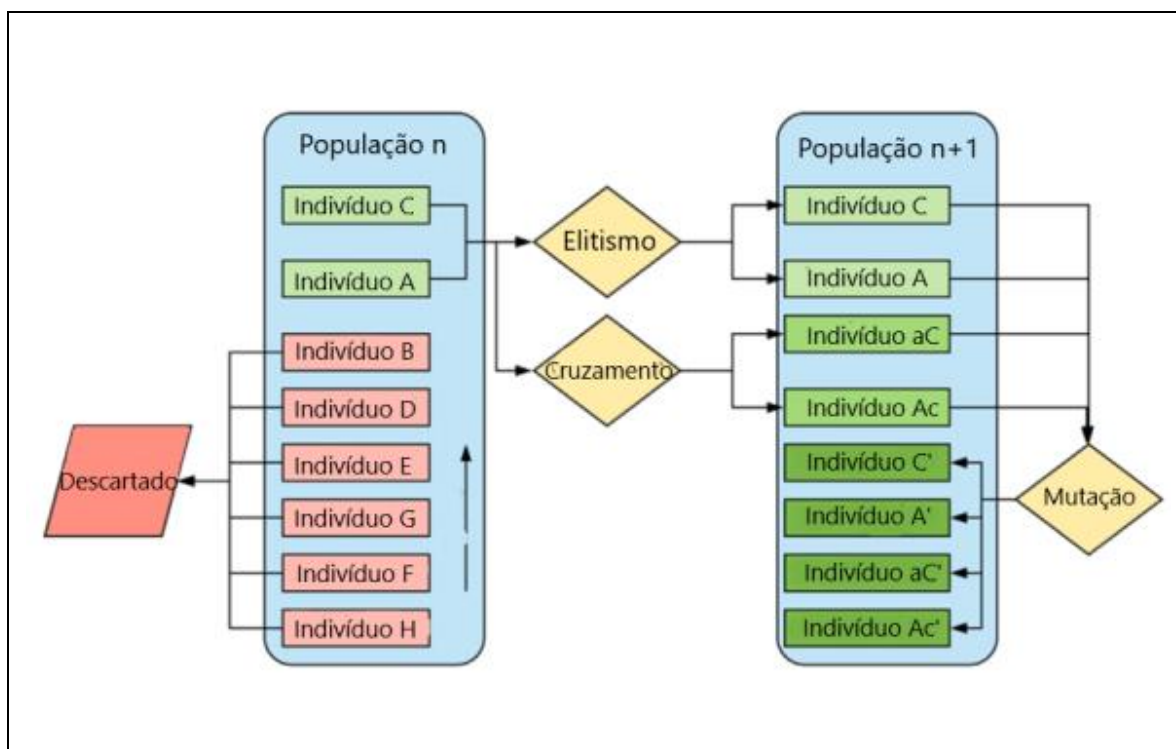
O método *One-Point Crossover* (Cruzamento em um ponto) consiste em ponto de corte que é escolhido aleatoriamente, onde este ponto irá dividir os genes dos pais e atribuir uma parte de cada pai para os filhos a serem gerados. Os pedaços podem ser combinados para gerar quantidades diferentes de filhos, desde que existam genes suficientes para gerar filhos diferentes, para isso geralmente são utilizados mais pontos de corte. (FILHO, 2018).

2.4.2.2 Cruzamento aritmético

O método aritmético é feito através de duas médias aritméticas ponderadas, ou seja, combinações lineares dos pais, onde os filhos através do cálculo dessas médias. A função que calcula a média ponderada que gerará cada filho está disposta na Equação 2, na qual α é um número aleatório entre 0 e 1. (FILHO, 2018).

$$\begin{aligned} Filho1 &= \alpha Pai1 + (1 - \alpha) Pai2 \\ Filho2 &= (1 - \alpha) Pai1 + \alpha Pai2 \end{aligned} \tag{2}$$

Figura 5. Fluxograma da geração de novas populações.



Fonte: Adaptado de Costa et al. (2020).

2.4.3 Mutaçao

Essa etapa é muito importante para diversidade de novos indivíduos e a variaçao genética da população. Nesta fase cada indivíduo tem chance igual de ter um de seus genes mutados para um valor aleatório, onde a probabilidade de acontecer é dada pela Taxa de mutação que é definida na configuração do algoritmo. A variaçao da taxa de mutação pode ser fixa ou dinâmica dependendo da configuração do algoritmo e do objetivo a ser atingido (HONG; WANG, 1996 apud. FILHO, 2018).

Na taxa fixa, que é a mais comum, não há variaçao durante o processo e a mesmo porcentagem de indivíduos será mutada a cada nova geraçao. Na taxa dinâmica, a probabilidade de indivíduos serem mutados varia de acordo com a média do valor de *fitness*, onde quanto maior for essa média maior vai ser a probabilidade de mutação. A taxa dinâmica é uma boa soluçao para caso a convergência ocorra muito rápido e os indivíduos estejam com características muito próximas, possa ser feita uma busca global para variabilidade genética (FILHO, 2018).

Segundo Bento e Kagan (2008), o operador de mutação frequentemente encontra três finalidades, a primeira é a de método paliativo para evitar a perda de alelos permanentemente, a segunda é manter a taxa de variaçao baixa e constante ao longo da execuçao do algoritmo e,

por fim, tem a finalidade de empregar uma taxa única a todos os genes de todos os indivíduos em uma população. Em Algoritmos Evolutivos, customa-se iniciar o algoritmo com valores altos de mutação e diminuindo o valor de acordo com a quantidade de geração geradas, ou seja, inicialmente busca-se a variedade de genes e a exploração e por fim busca-se estabilizar os indivíduos ao redor do melhor valor e sinalizar a convergência do algoritmo (BENTO; KAGAN, 2008).

2.5 C.A.S.S.I.E

O CASSIE nasceu como uma aplicação web que juntaria todas as ações necessárias para análise de linha de costa, em um único lugar. A ferramenta permitiria a análise temporal evolutiva da linha de costa, permitindo entender a mudança ocorrida, seja de erosão, evolução ou sem mudança. Sua principal diferença foi unir a possibilidade de seleção de local em todo mundo, implementação de técnicas de análise de linha de costa, juntamente com a geração de análises estatísticas tudo na mesma ferramenta, o que só era possível através de vários softwares. Além disso uma das funcionalidades do CASSIE é permitir a exportação das análises para um arquivo local, que pode ser utilizado em outros softwares de análise geográfica ou análise de costa (ALMEIDA et al., 2021).

O CASSIE foi construído com base na API do GEE e utiliza de imagens de satélite multitemporais das missões LanSat e Sentinel para fazer as análises de linhas de costa. Utilizando a computação em nuvem do GEE o CASSIE permite que o usuário tenha alto poder de processamento, mesmo sem a infraestrutura local adequada, necessitando apenas de acesso à internet. A ferramenta web é gratuita e pode ser utilizada por várias plataformas, como celular, PC (*Personal Computer*), laptop, entre outros. (ALMEIDA et al., 2021).

O CASSIE foi realizado e desenvolvido pelo laboratório LIA e contou com a ajuda de pesquisadores e professores para seu desenvolvimento e manutenção, hoje está acessável pelo link <<https://cassiengbine.org>> e dispõe atualmente apenas do módulo de análise de costa. A ferramenta é de código aberto e pode ser acessado através do site que direciona para um repositório no GitHub.

Para alavancar o potencial da ferramenta, além do módulo de análise de costa, está sendo desenvolvido um módulo de batimetria por imagem de satélite na mesma ferramenta, possibilitando a análise costeira quase que completa, com profundidade e linha de costa. O módulo já conta com algoritmos de batimetria e alguns trabalhos que ajudaram a solucionar

problemas para a estimativa de batimetria e trazer novas abordagens como a pesquisa desenvolvida por Santacattarina (2021).

2.6 TRABALHOS RELACIONADOS

A fim de trazer trabalhos significativos para pesquisa e embasamento deste trabalho, foi buscado uma série de artigos que continham informações sobre batimetria e batimetria derivada de satélite, focando nas abordagens relacionadas a inteligência artificial, visto que o trabalho irá abordar uma das técnicas da área para resolver um problema comum nas estimativas de batimetria por satélite. Para a filtragem e seleção inicial foi utilizada a técnica de chave de busca para encontrar artigos que contenham palavras chaves no título e corpo e assim trazer resultados relevantes da área num filtro de data de 10 anos.

As chaves de buscas passaram por alterações ao longo das pesquisas para encontrar artigos necessários para o embasamento desta pesquisa, em alguns casos foram considerados artigos mais antigos que fossem relevantes para a área. O Quadro 1 informa as chaves de busca utilizadas e a quantidade de artigos retornados na ferramenta Google Scholar.

Após a busca de artigos, foi selecionado artigos em que o título ou resumo tivessem conceitos que seriam abordados nesse trabalho, dando preferência em trabalhos que resolviam problemas não muito comuns como ondas, maré, material em suspensão etc. Com isso foi reduzido a quantidade de artigos base para esta pesquisa e refinado os conceitos de referência. Vale ressaltar que para a abordagem trabalhada neste projeto não foi encontrado nenhum semelhante, os resultados sempre apontavam para utilização de IA para estimativa da profundidade e não para o processamento e escolha das imagens, bem como modelos para processamento e escolha de pixels não estavam relacionados ao tema de batimetria ou análise costeira. Desta forma foi mesclado ambos os conceitos para tentar trazer uma solução suficiente.

Quadro 1 - Relação de chave de busca e resultados

Chave de busca	Quantidade de artigos retornados	Quantidade de artigos escolhidos
("Bathymetry" "Remote Bathymetry" OR "SDB" OR "Satellite Derived Bathymetry" OR "Remote Sensing" OR "Estimating Bathymetry") AND ("mapping" OR "nearshore" OR "coastal sedimentary" OR "coastal sedimentary" OR "coral reef" OR "Sentinel-2")	17.700	Apróx. 20
("Bathymetry" "Remote Bathymetry" OR "SDB" OR "Satellite Derived Bathymetry" OR "Remote Sensing" OR "Estimating Bathymetry") AND ("rough" OR "tide" OR "wave breaking" OR "suspended material" OR "estuary" OR "wave" OR "intertidal zone" OR "tidal delta" OR "surf zone")	17.800	Apróx. 10
"pre-processing" and ("SDB" or "bathymetry")	144	11
Choice pixel in multi temporal image with genetic	16.800	10
"Pixel Composites" "remote sensing"	288	9

Fonte: O autor.

A seguir será relacionado alguns dos autores mais importantes para o desenvolvimento desta pesquisa. Vale ressaltar que existem artigos não lidos na fila de leitura e que tem grandes chances de auxiliarem na montagem do modelo proposto, desses autores serão citados apenas o nome do artigo e uma breve descrição da solução proposta.

Um dos autores mais relevantes para batimetria em geral foi Lyzenga, suas hipóteses publicadas em 1978 e 1985 foram pioneiras no ramo de SDB e tem relevância até hoje, sendo constantemente melhorada e estudada. Exemplos de adaptações e estudos em cima do modelo proposto de Lyzenga é feito por Pacheco et al. (2014) que adapta o modelo proposto por Lyzenga (1985) para estimar batimetria. Traganos et al. (2018) compara o método de Lyzenga a outros métodos atuais e se sobressai em boa parte das estimativas, se mostrando um método muito eficiente frente as propostas atuais. Lyzenga (1985) assume que há uma relação linear entre as bandas log-transformadas e a profundidade conhecida, via regressão linear (múltipla).

Outra abordagem muito conhecida e citada é a de Stumpf et al. (2003), que propõe um modelo que usa uma razão de refletância da água transformada logaritmicamente por bandas com diferentes absorções na água, assumindo então que a razão de refletâncias mudará com a profundidade. A transformação logarítmica é responsável pela exponencial diminuição da luz com a profundidade, permitindo a análise de profundidade o que permite essa análise (CABALLERO e STUMPF, 2019). Esta abordagem é citada por Caballero e Stumpf (2019)

que testam a aplicação do modelo para bandas específicas. A abordagem de Stumpf (2003) também é utilizado por Traganos et al. (2018) na comparação entre métodos de estimativa de batimetria.

Outra abordagem recente que teve bons resultados e tem grande potencial é feita por Li et al. (2019) que busca estimar a batimetria com base em uma série de observações e abordagens com base na refletância da luz na água e atenuação da luz na água e sua relação com a profundidade. São utilizadas funções de cálculo de NDWI com base na banda verde, de cálculo de refletância na superfície da água, refletância do sensoriamento remoto, refletância abaixo da superfície da água e uma adaptação do algoritmo de razão de bandas de Stumpf et al. (2003), entre outras funções para derivar a concentração de certos compostos na água como fitoplanctons e clorofila-a. Esta abordagem teve ótimos resultados comparado ao LIDAR e teve contribuição em outros projetos.

Abordagens baseadas em ML estão sendo muito comuns nos últimos anos, seja abordando técnicas empíricas baseadas nos modelos de Lyzenga (1985) e Stumpf et al. (2003) ou de forma analítica. Alguns exemplos dessas abordagens são Sagawa et al. (2019) que utiliza uma técnica baseada em Florestas Aleatórias (RF) para estimar a batimetria para imagens multitemporais, outro exemplo é o de Misra e Ramakrishnan que utilizam Regressão por Vetor de Suporte (SVR) que tenta aprender a relação entrada-saída resolvendo um problema quadrático de programação. Mais um exemplo de uso de ML para estimar batimetria é feita por Najar et al. (2021) que utiliza dois métodos de aprendizado profundo para estimar batimetria em águas com ondas.

As abordagens acima estão mais relacionadas aos conceitos principais para este trabalho, como a relação das bandas com a profundidade, principalmente a atenuação das bandas azul e verde e a aplicação de aprendizado de máquina nesta área. As abordagens que terão mais impacto nesta pesquisa serão abordadas nas subseções a seguir, tais trabalhos são focados na reconstrução de imagens de uma série temporal gerando um mosaico dos melhores pixels se utilizando de diferentes métodos. Vale ressaltar que existem alguns trabalhos que envolvem a composição de pixels de várias imagens, entretanto não foi possível ter acesso a estes, visto que não estão dispostos publicamente.

2.6.1 Seasonal Composite Landsat TM/ETM+ Images Using the Medoid (a Multi-Dimensional Median) - Flood (2013)

O autor propõe a composição de pixels representativo utilizando um análogo multidimensional da mediana como método de seleção, o medoid. Este método geralmente traz a medida do meio de um conjunto de dados, mas pode ser adaptado para obter dados representativos de todas as bandas de um conjunto de imagens. A motivação do estudo se dá pela ineficiência de métodos tradicionais de correção atmosférica e de nuvens que não trazem um resultado tão bom de imagens, além de reduzir o tamanho dos dados, visto que trabalhar com imagens multiespectrais requer muito armazenamento e tempo de processamento, que pode facilmente ser resolvido com uma única imagem composta.

O modelo foi aplicado as imagens multiespectrais da missão Landsat TM/ETM+ utilizando como local de estudo o estado da Queensland na Austrália que foram tratadas com filtros de nuvem e sombra com os algoritmos FMask e *Shuttle Radar Topographic Mission* (DEM). Para validação foi comparado os resultados da medoid com o método MNC (*Maximum NDVI Composite*) que é outra técnica capaz de eliminar contaminações indesejáveis de imagem, como nuvem e sombra de nuvem. O trabalho é focado em trazer dados representativos em regiões de vegetação, por isso a utilização do MNC como validação comparativa do método medoid.

Os métodos MNC e medoid consistem em selecionar um representante para um conjunto de dados, neste caso o representante é um pixel real de uma determinada data da série temporal. A diferença é que no método MNC é selecionado como pixel representante aquele que tem maior concentração de NDVI, enquanto na medoid é escolhido o ponto que minimiza a soma das distâncias de todos os outros pontos. A medoid é uma medida de centro de um conjunto multivariado de pontos, semelhante a uma mediana. O medoid se assemelha também a mediana geométrica, exceto que no medoid o ponto é escolhido do conjunto de dados, enquanto na mediana geométrica esse dado pode ser fabricado.

A função que descreve a medoid está disponível na Equação 6, onde $X \subset \mathbb{R}^n$ é o conjunto de pontos no espaço n-dimensional, o operador $\| \cdot \|$ é a distância euclidiana, e o operador $\arg \min_{x_i \in X}$ seleciona o elemento de X que minimiza a expressão dada.

$$\text{Medoid}(X) = \arg \min_{x_i \in X} \sum_{x_j \in X} |x_j - x_i| \quad (3)$$

Os resultados obtidos foram em sua maioria como esperado, com a medoid acompanhando as variações de NDVI melhor que o MNC que superestimou na maioria das estações, tendo também valores sazonais (valores representativos) que representam melhor a refletância para a estação em comparação ao MNC

2.6.2 High-Dimensional Pixel Composites From Earth Observation Time Series - Roberts et al. (2017)

Roberts et al. (2017) propôs um método baseado em estatísticas para composição de pixels de uma série temporal de imagens e reduz a uma única imagem com as relações de bandas espectrais mantidas, desprovida de *outliers* (valores faltantes) e com ruído espacial reduzido. O método utilizado pelo autor é baseado na mediana geométrica, que é um método estatístico de alta dimensão, que tem por objetivo trocar uma pilha de pixels temporais de baixa qualidade por uma única composição de pixel de alta qualidade e com ruído espacial reduzido.

Como local de estudo foi utilizado a ilha da Tasmânia na Austrália que tem uma cobertura de nuvens muito grande que, por muitas vezes, inibe uma observação nítida do local, visto que dificilmente terá imagens sem nuvens. Os dados de imagens foram obtidos da missão Landsat-8 OLI (LS8) concentradas no ano de 2014. As bandas utilizadas foram Azul, Verde, Vermelho, Infravermelho Próximo e Infravermelho de ondas curtas 1 e 2 (Bandas 6 e 7 do Landsat-8). Os dados passaram por filtros de nuvens, sombra de nuvens e correção atmosférica, através de algoritmos como Fmask, ACCA e Quality (para determinar a qualidade do pixel), onde são aplicados a cada pixel como se cada um deles fosse uma imagem.

A função que representa a mediana geométrica é mostrada na Equação 7, considerando que dado um conjunto finito X de pixels da banda p em observações (ou seja, séries temporais de pixel multibanda) como vetores $\mathbf{x}_1, \dots, \mathbf{x}_n \in \mathbb{R}^p$. Onde $\|\cdot\|$ é a norma euclidiana e $\arg \min_{\mathbf{x}} f(\mathbf{x})$ o “argumento dos mínimos”, que dá o ponto \mathbf{x} que minimiza a função f . Desta forma a mediana geométrica é a p -dimensional mais próxima do vetor $\mathbf{x} \in \mathbb{R}^p$ para todas as bandas- p de cada pixel das observações em \mathbb{X} usando a norma euclidiana como medida de distância. Este método é utilizado comumente em estatística de alta dimensão devido seu alto valor de quebra e é muito útil quando a distribuição de probabilidade dos dados não é necessariamente normalmente multivariada ou quando os valores discrepantes estão presentes nos dados.

$$\text{Mediana geométrica} = \arg \min_{x \in \mathbb{R}^p} \sum_{i=1}^n ||x - x_i|| \quad (4)$$

O funcionamento básico proposto por Roberts et al. (2017) consiste em retirar os artefatos das imagens multitemporais que sejam indesejáveis, e passar esses dados em vetores pelo algoritmo de reconstrução, onde para cada valor faltante na imagem será reconstruído o pixel em questão por meio do algoritmo da mediana geométrica. O algoritmo de reconstrução foi feito em Cython que gera um código eficiente em C com ligação ao Python e está disponível como software de código aberto no link do GitHub disponibilizado pelo autor fornecendo uma série de algoritmos de mediana de alta dimensão. Após a reconstrução da imagem, foi feito um pós-processamento com ferramentas para este fim, como a ferramenta GDAL.

Como validação dos resultados foi comparado os resultados deste método com o método medoid proposto por Flood (2013) e a mediana unidimensional aplicada para cada banda separadamente. Tendo como resultado positivo o uso da mediana geométrica perante os outros métodos, visto que ela teve uma forma mais consistente na comparação de variação de banda nas composições de imagem e manteve o relacionamento do espectro sobre diferentes alvos. Apesar de em alguns pontos os dois outros métodos avaliados terem alguns pontos a favor, no geral a mediana geométrica foi superior e pode remontar uma imagem completa da ilha da Tasmânia sem nuvens, sem valores faltantes e com ruído espacial corrigido.

2.6.3 Generating Continental Scale Pixel-Based Surface Reflectance Composites in Coastal Regions with the use of a Multi-Resolution Tidal Model - Sagar et al. (2018)

Sagar et al. (2018) propõe um método de modelagem de maré multi-resolução baseando-se pelo conceito de permitir que os dados conduzam os limites e a escala do modelo. Foi utilizada a segmentação espacial para diminuir o problema da escala espacial prejudicada pela resolução baixa. O modelo é aplicado juntamente com a abordagem da mediana geométrica para criar composições de pixels com boa resolução e modelagem de maré. Desta forma foi possível a utilização de estatística e informações de maré para construir uma imagem com o nível de maré normalizado

Para criar esse modelo composto por mediana geométrica com os dados de maré, o autor utilizou o modelo OTPS TPX08 que é um modelo que consiste em uma solução de

grade batimétrica multi-resolução, baseado em um sistema de equações de Laplace, parametrizado com nove constituintes harmônicos de maré. Foi utilizado também a plataforma *Digital Earth Australia* (DEA) para aplicar o framework desenvolvido nas imagens do LandSat de regiões da Austrália. O autor também fez uma série de correções nas imagens e avaliações de qualidade de pixel para deixar a imagem adequada para o processamento no algoritmo da mediana geométrica.

Os resultados obtidos foram de grande efeito e foi possível gerar mosaicos de pixels das regiões de Montgomery Reef, Roebuck Bay e Talbot Bay na Austrália Ocidental. Foi possível gerar mosaicos de alta e baixa maré, sem ruídos e com imagem limpa e nítida. O modelo gerado permitiu a diminuição da confusão quanto a mudança de maré e provou-se capaz de se adaptar a uma série de mudanças de detecção.

2.6.4 Automated Mosaicking of Sentinel-2 Satellite Imagery - Shepherd et al. (2020)

O autor foca em melhorar o algoritmo Tmask que tem a função de fazer um filtro de nuvens automatizado e com alta precisão, o autor usa o método de paralaxe para produzir uma camada de nuvem inicial e usa um método baseado em objetos para remover detecções falsas de nuvens. Além disso é desenvolvido várias abordagens de pontuação paramétrica para escolher os melhores pixels possíveis para composição de uma imagem com o mínimo de nuvem.

O algoritmo proposto faz uma série de filtros e cálculos para remover nuvens e sombras de nuvens, utilizando o método de paralaxe e o algoritmo de mascaramento de nuvens Fmask. Após finalizar a máscara de nuvens o algoritmo pontua as imagens de acordo com a área livre de nuvens e a sua contribuição no mosaico. A imagem escolhida teria priorização na montagem do mosaico e passaria por mais uma máscara de raster e por fim aplicado seus pixels na composição. Neste caso nem todas as imagens podem contribuir com sua área livre de nuvens, visto que é dada prioridade para imagem com melhor nota, causando áreas com dados faltando em locais nublados.

Os dados para estudo foram obtidos da missão Sentinel-2 na região da Nova Zelândia. Foram feitos testes de geração do mosaico com classificação manual e automática, consistindo nos passos do algoritmo onde é visto a imagem com melhor nota e a partir dela é montado o mosaico selecionando pixels sem nuvem, nos casos em que não é encontrado pixel correspondente é feito manualmente a seleção com o melhor pixel. No método automático

segue o mesmo fluxo, diferenciando que no caso de não encontrar o pixel correspondente com a qualidade desejável este local fica sem dados.

2.6.5 Enhancement Of The Segmentation Process Of Multicomponent Images Using Fusion With Genetic Algorithm – Awad et al. (2008)

Awad et al. (2018) explora o uso de Algoritmos genéticos para fundir imagens provindas de segmentação, buscando melhorar a segmentação final. O autor utiliza os métodos SOM-HGA e ISODATA para segmentar as imagens multibandas e gerar imagens segmentadas que alimentarão o Algoritmo Genético que fundirá os pixels buscando a melhor segmentação. A escolha do algoritmo genético é dada, visto que a segmentação é um problema combinatório, permitindo o uso desta técnica de IA para obter um método de combinação de pixels que melhore a segmentação. A avaliação dos resultados é feita pelo Modelo Funcional que permite medir a estabilidade da segmentação, ajudando a eliminar a sub e a super segmentação.

O Modelo Funcional consiste em um processo iterativo dividido em uma série de cinco etapas de cálculos estatísticos que buscam avaliar se a imagem segmentada é de boa qualidade, sendo as etapas dispostas em Medir, Critério, Controle, Modificação e Parar. A fase Medir, consiste em receber imagens segmentadas, duas ou mais, e aplicar um conjunto de operações estatísticas para verificar a estabilidade e homogeneidade da região, gerando valores que serão recebidos pela fase Critério que é a fase que cria um critério escalar com base nas medidas recebidas através de uma equação matemática. Esse critério é usado para identificar mudanças significativas nos resultados da segmentação. O passo controle gera um valor de controle baseado no critério escalar.

O passo Modificação consiste na modificação da imagem de segmentação que neste trabalho é o Algoritmo Genético, onde é feito o cruzamento de indivíduos que por sua vez são compostos de pixels de imagens segmentadas, até que seja obtido os pixels de escolha final que irão compor a imagem final. Por fim o passo Parar é onde é avaliada a imagem segmentada final, com base na homogeneidade e estabilidade e é decidido se vai ser parado o processo iterativo, por exemplo o número de iterações sem mudanças nos resultados do AG ou o valor resultante final da homogeneidade e estabilidade.

Os experimentos feitos pelo autor, foram a geração de imagens segmentadas pelos métodos SOM-HGA e ISODATA, depois foi feita a aplicação das imagens geradas no método de fusão e avaliada a nota recebida do Modelo Funcional. Os resultados dos experimentos mostraram grande melhora na fusão das imagens, onde a fusão diminuía a

quantidade de polígonos na imagem, que para este tipo de análise é o melhor resultado, fora que a nota recebida do Modelo Funcional foi superior que as imagens originais segmentadas.

2.6.6 Image Fusion by a Hybrid Multiobjective Genetic Algorithm Technique – Kulkarni (2022)

O trabalho deste autor, baseia-se em comparar experimentos de composição de imagens quaisquer com Algoritmos Genéticos, usando três abordagens de Algoritmos Genéticos, o AG comum, o AG híbrido e o AG híbrido multiobjetivo.

No experimento com AG comum é feita a seleção de duas imagens de um conjunto de imagens e é preparado o AG para fundir as imagens. O tamanho da população é de acordo com o tamanho de bits das imagens, bem como o tamanho dos cromossomos da população, na abordagem do autor, cada imagem gera uma população que será iterada no AG. A função de aptidão é gerada e aplicada a imagem fundida para que seja identificado os pixels que geraram melhores resultados na imagem fundida e assim é aplicado o método roleta para seleção dos pais. Ao finalizar as iterações é gerada uma imagem final fundida.

No experimento com AG híbrido, a fusão é feita a nível de pixel e o AG irá buscar os pesos para escolha do melhor pixel para fusão das imagens. Nesta abordagem as imagens de entrada são divididas em segmentos, onde o tamanho dos segmentos é dito pelo AG. A busca genética é feita para avaliar quais os pesos que serão atribuídos aos pixels das imagens, sendo a somatório dos dois pesos é igual a 1. A função de aptidão utilizada é a Raiz do Erro Quadrático Médio (RMSE). Ao fim das iterações os pesos encontrados são multiplicados nos pixels das imagens, unindo parte dos pixels de cada imagem e gerando uma imagem fundida com as informações mais relevantes.

Para o experimento com o AG híbrido multiobjetivo, é aplicado o AG híbrido adicionando múltiplos parâmetros para variar as soluções, ou seja, é variada a forma de geração da população, função de aptidão entre outros parâmetros a fim de testar todas as soluções possíveis e trazer a solução mais próxima do valor ótimo. Nesta implementação é feito o cruzamento em dois pontos.

Os resultados obtidos nos experimentos foram satisfatórios, tendo resultados visuais aceitáveis e erros variando entre bom e não satisfatório. No geral o AG híbrido teve os melhores resultados tanto visualmente quanto na análise de erro, tendo o erro RMSE mais baixo que os outros métodos além de manter os dados visuais da imagem mais uniformes possível. Com isso foi visto que o uso de AG a nível de pixel tem melhor precisão que de outra maneira, além de reforçar que o AG consegue gerar pesos de escolhas aceitáveis. Este

trabalho buscou uma implementação simples para exemplificar o uso de AG na composição de pixels, não tendo muita relevância no uso de imagens mais pesadas e multiespectrais, entretanto, traz bons exemplos de uso do AG na composição de imagens.

2.6.7 Comparativo entre trabalhos

O Quadro 2 mostra um comparativo entre os trabalhos apresentados, mostrando seus aspectos principais e os resultados encontrados. Os trabalhos listados estão ligados a composição de pixels de várias imagens, algumas sendo multitemporais, outras apenas imagens diversas em que foi feito o uso de alguma técnica para gerar uma imagem final com melhor qualidade que a original, ou uma nova imagem que não existe composta por pixels de várias imagens. Em geral não foi encontrado um trabalho para embasamento geral, visto que é pouco comum o uso de AG em composição de pixels e a maioria dos trabalhos encontrados não estão disponíveis publicamente, desta forma estes trabalhos foram listados como motivação de uma pesquisa exploratória na área de composição de pixels e imagens de ambientes aquáticos, buscando ajudar esta área em caso de sucesso na abordagem.

Foi utilizado como apoio na construção do AG proposto, os trabalhos de Awad et al. (2008) e Kulkarni (2022) que foram as únicas referências de composição de pixels usando AG. Também foi utilizado como base o trabalho escrito por Costa et al. (2020) que não fora citado, mas utiliza o AG para estimar valores NDVI, utilizando como genes pesos para as bandas de imagens RGB, sendo essa a característica que liga ao AG explorado, tendo como genes pesos para as bandas de imagens multiespectrais.

Quadro 2 – Comparativo de trabalhos relacionados.

Autor	Título	Técnica	Local de estudo	Resultados
Flood (2013)	Seasonal Composite Landsat TM/ETM+ Images Using the Medoid (a Multi-Dimensional Median)	Medoid	Queensland - Austrália	Melhor precisão comparado ao MNC.
Roberts et al. (2017)	High-Dimensional Pixel Composites From Earth Observation Time Series	Mediana geométrica	Tasmânia - Austrália	Melhor relação de bandas e normalização comparado a mediana normal e ao medoid de Flood (2013).
Sagar et al. (2018)	Generating Continental Scale Pixel-Based Surface Reflectance Composites in Coastal Regions with the Use of a Multi-Resolution Tidal Model	Mediana geométrica com modelo de maré.	Montgomery Reef, Roebuck Bay e Talbot Bay na Austrália Ocidental	Bons resultados de modelagem de maré. Não foi comparado a outro trabalho.
Sheperd et al. (2020)	Automated Mosaicking of Sentinel-2 Satellite Imagery	Melhoramento do algoritmo automático Tmask para geração de mosaicos.	Nova Zelândia	Bons resultados de mosaico sem nuvens, porém permite <i>outliers</i> .
Awad et al. (2008)	Enhancement Of The Segmentation Process Of Multicomponent Images Using Fusion With Genetic Algorithm	Fusão de imagens segmentadas com Algoritmo Genético	Não mencionado	Obteve melhora na imagem segmentada gerada pelos métodos SOM-HGA e ISODATA.
Kulkarni (2022)	Image Fusion by a Hybrid Multiobjective Genetic Algorithm Technique	Fusão de imagens com o AG comum, o AG híbrido e o AG híbrido multiobjetivo	Não utiliza imagens de satélite	Tem bons resultados unindo duas ou mais imagens simples. Compara alguns tipos de AG, com o AG híbrido tendo melhor resultado.

Fonte: o autor.

3 DESENVOLVIMENTO

3.1 METODOLOGIA

Esta pesquisa tem a metodologia experimental, visto que o objeto de pesquisa que são imagens multiespectrais ou hiper espectrais de satélite, tem atributos que podem ser medidos e numerados, sendo capazes de influenciar o objeto, podendo gerar resultados melhores ou piores ao aplicar em algoritmos de batimetria (Lozada et al., 2019). O objetivo desta pesquisa é explorar o uso de algoritmos genéticos para a escolha de pixels e montagem de mosaico de imagens multitemporais, com a finalidade de selecionar os melhores pixels do conjunto de imagens que permitam o melhor resultado de batimetria. O objetivo exploratório caracteriza por explorar a aplicação de uma solução com poucas referências semelhantes, desta forma esse objetivo se encaixa com a pesquisa, visto que não existe uma aplicação de escolha de pixel em imagens multitemporais para aplicação em batimetria (Lozada et al., 2019).

3.2 MATERIAIS E MÉTODOS

Os tópicos seguintes abordam os materiais e métodos que foram utilizados para o desenvolvimento do projeto.

3.2.1 Dados

As imagens utilizadas foram obtidas através da plataforma do Google Earth Engine, que disponibiliza as imagens das missões Sentinel-2 e LandSat. Foram utilizadas apenas imagens do Sentinel-2, visto que o algoritmo cedido pela equipe do CASSIE foi homologado apenas nesta missão e, portanto, não teria muita relevância nesta pesquisa. As imagens não precisaram ser armazenadas para processamento no AG, invés disso foi utilizada a consulta em tempo de execução através da API do GEE. Os dados de medição em campo de batimetria foram obtidos por meio do projeto CASSIE, onde foram fornecidas várias medições de vários anos da Baía da Babitonga, onde foi utilizado apenas as medições de 2018 para validar o retorno do algoritmo de batimetria e para filtragem de data, visto que não existem medições totalmente sincronizadas com as imagens de satélite, desta forma será considerado apenas medições que tem captação de imagem próximas a data de medição.

Foi feito um levantamento de imagens versus medições em campo por um dos integrantes do projeto, que foi utilizado neste trabalho como base de extração de imagens e dados de medição para validação. A Figura 6 mostra a relação de medições e imagens

disponíveis próxima a medição, com intervalo máximo de um ano. Com isso os dados necessários para construção do algoritmo e validação dos resultados estão satisfeitos.

Figura 6. Relação de imagens versus medições em campo, com um detalhe para duas captações de imagem que só foi encontrada metade da imagem.

ANO DE MEDIÇÃO	1985		1995		1996		2001	
MÊS DE MEDIÇÃO	nov		jan		dez		nov	
	Relação de imagens próximas		Relação de imagens próximas		Relação de imagens próximas		Relação de imagens próximas	
SATÉLITE	Landsat	Sentinel	Landsat	Sentinel	Landsat	Sentinel	Landsat	Sentinel
	30/09/1986		18/07/1994		02/04/1996		31/05/2000	
	24/04/1988		03/08/1994		18/04/1996		16/06/2000	
	27/03/1988		02/04/1996		05/04/1997		02/07/2000	
			18/04/1996		24/06/1997		19/08/2000	
					11/08/1997		21/04/2000	
							07/05/2000	
							13/07/2001	
							15/09/2001	
ANO DE MEDIÇÃO	2002		2018		2021		2022	
MÊS DE MEDIÇÃO	out		mai		jul		fev	
	Relação de imagens próximas		Relação de imagens próximas		Relação de imagens próximas		Relação de imagens próximas	
SATÉLITE	Landsat	Sentinel	Landsat	Sentinel	Landsat	Sentinel	Landsat	Sentinel
	10/03/2002		28/01/2019	05/01/2018	18/02/2021	18/02/2021	21/02/2022	30/11/2021
	11/07/2003		14/05/2017	11/03/2018	25/05/2021	23/02/2021	13/02/2022	25/12/2021
	16/07/2002			20/04/2018		10/03/2021		13/02/2022
	02/09/2002			25/04/2018		19/05/2021		18/02/2022
	21/01/2002			15/05/2018		24/05/2021		05/03/2022
	04/01/2002			20/05/2018		13/06/2021		09/04/2022
	25/02/2003			14/07/2018		08/07/2021		
				29/07/2018		23/07/2021		
						28/07/2021		

Fonte: adaptado de Laís Pool – Equipe CASSIE (2022).

3.2.2 Métodos

Foi utilizado como método de pesquisa o Algoritmo Genético para analisar as imagens multitemporais e gerar uma equação para a escolha dos melhores pixels de uma série de imagens multitemporais para gerar um mosaico. Esse mosaico de melhores pixels foi aplicado a um algoritmo de estimativa de batimetria. A hipótese testada é que a coluna d'água não muda massivamente durante o tempo, tornando possível a junção de vários pixels para uma única imagem analisando cada banda multiespectral em cada pixel e melhorando a precisão da batimetria estimada por imagem de satélite.

A escolha do algoritmo genético perante outras abordagens de IA, foi feita visto que é necessário um método não supervisionado para resolver o problema, visto que não existe uma imagem modelo para classificação, além do AG ter um bom desempenho com escolha de soluções entre várias variáveis conforme cita Awad et al. (2008). Além disto, a escolha do AG também foi feita com base na exploração deste método na área, visto que não há muitas referências do seu uso.

A plataforma de desenvolvimento inicialmente foi o *Google Earth Engine* (GEE), entretanto a plataforma não reconhecia alguns comandos da linguagem JavaScript, o que dificultou a aplicação do AG, por conta disso foi trocada a plataforma de desenvolvimento para o Node.js. Entretanto ao tentar executar juntamente ao código do CASSIE, foi encontrado um viés na forma de autenticação do Google Cloud, impedindo a execução do código. Para contornar a situação foi traduzido todos os códigos para o Python para execução no Google Colab e posteriormente localmente através da IDE Pycharm por conta do tempo limite de execução dentro do Colab.

Na execução via Python foi identificada uma lentidão na tradução dos objetos do GEE, visto que tanto as imagens, quanto os artefatos utilizados no algoritmo como o RMSE calculado, são objetos do GEE que só podem ser traduzidos para valores interpretáveis fazendo uma requisição ao servidor do GEE. Essa requisição leva em torno de 2 a 3 minutos, o que causou uma grande lentidão no algoritmo, visto que a cada indivíduo a cada geração seria necessário fazer uma requisição no servidor. Desta forma não foi possível finalizar a execução do algoritmo via Google Colab e por isso foi migrado para execução localmente onde o tempo de execução médio foi de 3 a 4 dias.

Para contornar essa lentidão foi testado a API via REST do GEE, mesmo que esta não tivesse muita documentação para desenvolver uma aplicação mais complexa. Foi utilizado a função REST de obter os pixels da imagem em um *array* e a partir disso fazer os cálculos de projeção e determinar qual a coordenada de cada pixel da matriz, montando assim um *dataset* com as coordenadas e os valores de cada banda. Como viés nesse método, tem-se a aplicação dos pesos nas bandas das imagens para montar a imagem de mosaico, visto que seria necessário fazer um laço de repetição para percorrer todas as imagens e todos os pixels de cada imagem, gerando também uma lentidão na execução, semelhante a execução via biblioteca do GEE. Devido a isso não foi focado nesse método por conta da complexidade e do pouco tempo de desenvolvimento, podendo ser explorado futuramente para obter um desempenho melhor em questão de tempo de execução.

O método de escolha do pixel para compor o mosaico foi baseado na somatória dos valores das bandas, multiplicados pelo valor dos pesos, multiplicado no fim por -0.1, este valor foi utilizado para inverter os valores e evitar que fosse escolhido pixels com valores muito altos que iriam distorcer a imagem, desta forma era sempre escolhido um valor normalizado, este valor foi chamado de Score de banda (S_b). Com este valor calculado para todos os pixels de todas as imagens, era escolhido o maior valor calculado entre todas as

imagens em cada pixel, formando uma matriz contendo os pixels com maior valor de score de banda.

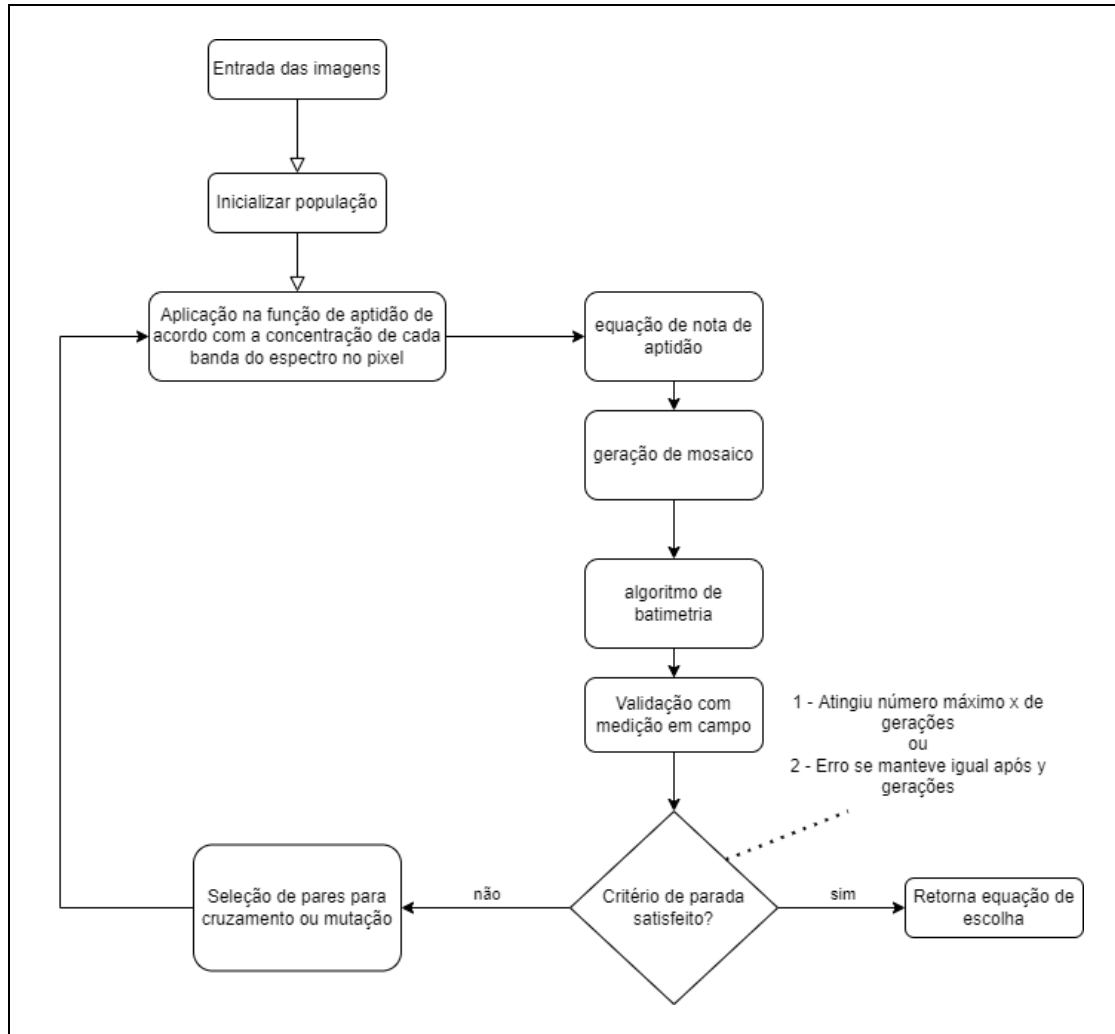
$$Sb = (B1 * P_{B1}) + (B2 * P_{B2}) + (B3 * P_{B3}) + (B4 * P_{B4}) + (B5 * P_{B5}) + (B6 * P_{B6}) + (B8 * P_{B8}) + (NDWI * P_{NDWI}) \quad (5)$$

3.3 EXECUÇÃO

3.3.1 Fluxo de trabalho.

O fluxo de trabalho deste projeto está evidenciado na Figura 7, onde é mostrado o funcionamento planejado para o treinamento do modelo de algoritmo genético. Inicialmente é feita a inicialização da população, com valores aleatórios para os genes dos indivíduos, onde cada gene é um peso que é atribuído a uma banda da imagem e ao NDWI. Com isso, a aplicação é feita nos pixels de todas as imagens da série temporal, onde a função de mosaico irá selecionar os melhores pixels e formar um mosaico para aplicação no algoritmo de batimetria que por sua vez irá retornar o RMSE da predição formando assim o *score*.

Figura 7. Fluxograma do modelo proposto.



Fonte: o autor

Com a aplicação no algoritmo de batimetria, é obtida uma profundidade estimada, extraída da imagem de mosaico, essa estimativa de batimetria é validada com medições em campo, para que sejam encontrados o RMSE (*Mean Squared Error* – Raiz Erro Médio Quadrático), que são um dos critérios de parada, as equações para calcular o RMSE e o MAE estão apresentadas nas Equações 6 e 7. Caso não seja satisfeito nenhum critério de parada é feita a seleção de pares para cruzamento e/ou mutação dos indivíduos, caso seja satisfeita a relação de pesos é retornada. A comunicação entre os objetos presentes no estudo está explanada no diagrama de sequência da Figura 8, mostrando o fluxo parecido com o mostrado na Figura 7, porém em formato de diagrama de sequência.

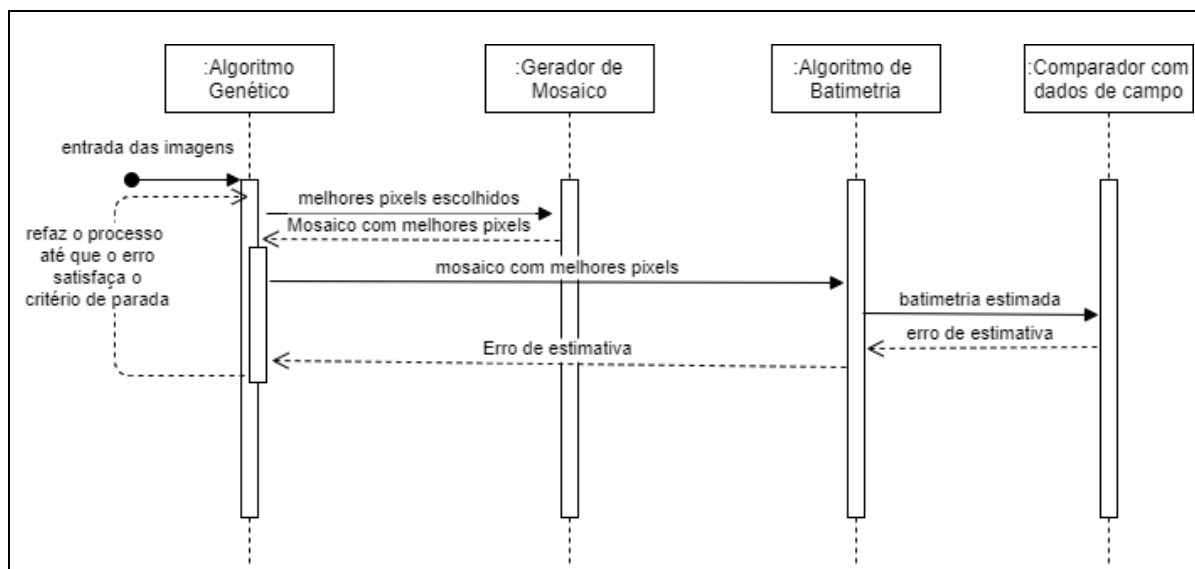
$$MAE = \frac{1}{n} \sum_{i=1}^n |Profundidade_{Imagem} - Profundidade_{Real}| \quad (6)$$

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (Profundidade_{Imagem} - Profundidade_{Real})^2} \quad (7)$$

Este processo de aplicação dos genes de cada indivíduo na função de *Score* de banda para montagem do mosaico composto das imagens da série temporal, seguido pela aplicação no algoritmo de batimetria e por fim comparado o retorno do algoritmo com os dados medidos em campo, irá formar a função de aptidão (*fitness*) do algoritmo genético, sendo ele o valor do RMSE da batimetria predita pelo modelo comparada a batimetria medida em campo, ou seja, a diferença entre os valores de treinamento e os valores de predição. A pontuação de cada indivíduo é avaliada pelo tamanho do erro, ou seja, indivíduos com menores erros serão considerados como indivíduos aptos a gerar novos indivíduos, enquanto os que tem maiores erros serão mais propensos a serem descartados. Para seleção foram usados o método torneio e o método roleta, onde é escolhido dois indivíduos da população para gerar novos indivíduos ou sofrerem mutação, nesses métodos é avaliado quais indivíduos tem o menor valor de RMSE para assim escolher os indivíduos.

Sobre os critérios de parada, foram escolhidos inicialmente dois, o primeiro como sendo o número máximo de gerações, aqui considerado como 100 inicialmente baseado no trabalho feito por Kulkarni (2022), porém devido a lentidão na execução do algoritmo foi reduzida a 50. O número de gerações sem evolução da solução, ou seja, o número de gerações consecutivas em que erro do melhor indivíduo não diminui, foi de 10 gerações, o valor não tem embasamento na literatura, visto que os autores em que esta pesquisa se baseia não citam este critério de parada.

Figura 8. Diagrama de sequência do modelo proposto para ser usado durante a implementação.



Fonte: o autor.

O tamanho da população foi inicialmente fixado em 350, entendendo que seria o suficiente para equilibrar o tempo de execução e a obtenção de bons resultados, entretanto devido a lentidão da tradução de dados do Earth Engine, foi necessário reduzir esse tamanho para 50. Desta forma foi possível finalizar a execução do algoritmo, o que estava muito difícil com uma população maior. Como o trabalho é uma exploração na aplicação de algoritmos genéticos com o Google Earth Engine, não foi possível prever tais problemas e estimar uma população ideal, sendo definida durante o desenvolvimento.

O método de seleção foi o método de roleta, utilizado por Awad et al. (2008) e Kulkarni (2022), juntamente com método de torneio, escolhendo aleatoriamente entre os dois métodos em tempo de execução. Foram utilizados dois métodos de cruzamento, conforme foi utilizado por Collins (2019), para diminuir a autocorreção, os métodos foram o *One-Point Crossover* (Cruzamento em um ponto) e o *Crossover Aritmético* intercalando aleatoriamente entre eles.

A função de mutação foi uma porcentagem fixa de 0,21% em cima de uma banda aleatória, este valor foi calculado com base em uma estatística feita com base em dados obtidos no levantamento batimétrico feito em 2018 na Baía da Babitonga disponibilizado pela equipe do CASSIE. No levantamento batimétrico, foi observado também o valor de refletância de algumas bandas de imagens multiespectrais na coluna d'água e através de cálculos de variância e média foi encontrado este valor.

Para o cálculo da porcentagem, é calculada para cada banda dos dados disponibilizados a sua média e a sua variância e posteriormente é feita a razão desses valores, gerando uma porcentagem para cada banda, vide Equação 8. A média de todas as porcentagens de todas as bandas calculadas corresponde ao valor de 0,21% que foi usado como percentual de mutação da pesquisa. Os valores encontrados para a porcentagem de variância por média em cada banda estão dispostos na Tabela 1.

$$\% \text{variância sobre a média} = \frac{\text{Variância da banda}}{\text{Média da refletância da banda}} \quad (8)$$

Tabela 1 - Porcentagem de mutação em cada banda do pixel

Banda	Porcentagem de variância pela média (%)
Banda 1	0,14%
Banda 2	0,15%
Banda 3	0,16%
Banda 4	0,27%
Banda 5	0,36%
Banda 6	0,20%
Banda 8	0,18%

Fonte: o autor.

Um apanhado geral dos parâmetros de configuração do algoritmo genético está disposto no Quadro 3, onde mostra os parâmetros já citados além da porcentagem de mutação e cruzamento, método de aptidão, entre outros. A porcentagem de mutação e reprodução foi baseada no trabalho de Awad et al. (2008) que faz uma composição de pixels com AG, podendo variar de acordo com os resultados encontrados.

Quadro 3 – Parâmetros planejados para o algoritmo genético e seus respectivos valores

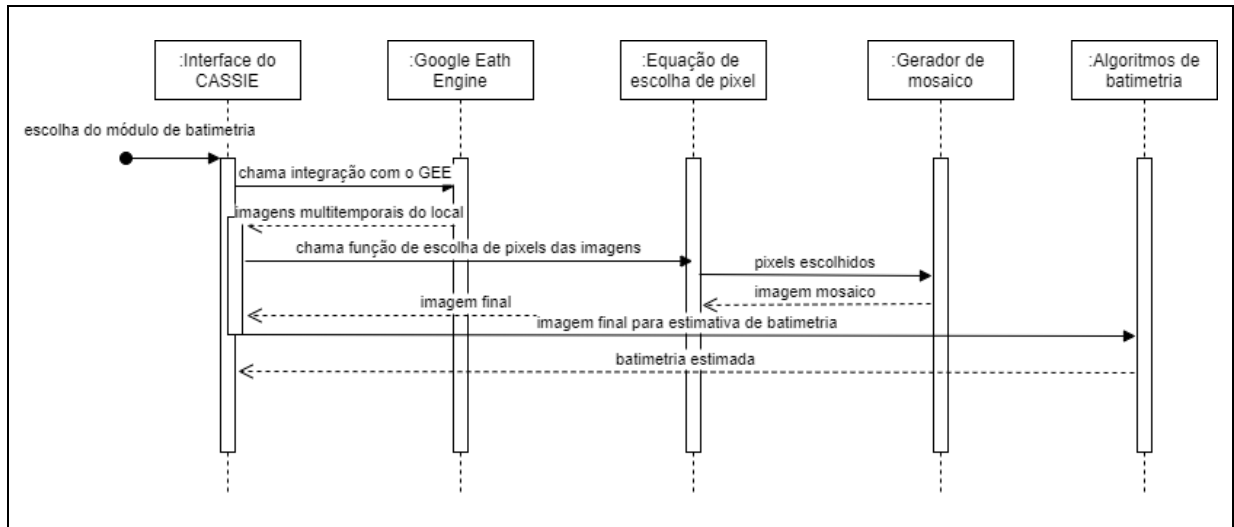
Parâmetro	Valor
População	350
Gerações	100
Genes	As bandas 1 a 6 e a banda 8 do espectro juntamente com o NDWI da banda verde e vermelha.
Método de reprodução	<i>One-point crossover</i> e Cruzamento Aritmético.
Método de seleção	Roleta ou torneio.
Método de mutação	Aplicação de porcentagem fixa de 0,21% com base em estatísticas sobre dados de refletância.
% Reprodução	65%
% Mutação	35%
Função de aptidão	Aplicação dos genes na equação de <i>score</i> , depois aplicado as imagens e selecionada os pixels com maior valor para geração do mosaico, após finalizar o mosaico aplicar a imagem no algoritmo de batimetria e comparar a batimetria estimada com dados medidos em campo, obtendo o Erro Médio Absoluto e Erro Quadrático Médio que determinaram qual indivíduo é melhor.
Critério de parada	Atingir 100 gerações ou o erro de estimação de batimetria se manter o mesmo após 100 gerações.

Fonte: adaptado de Collins (2019).

Para validar se a aplicação de máscaras de bandas nos pixels das imagens fornecidos pelo AG surtiram efeito, foi gerado um comparativo do erro RMSE da batimetria, com e sem a utilização das máscaras. Foi determinado um local específico da Baía da Babitonga, numa data específica onde estava próxima da medição em campo. Para estimação da batimetria sem a máscara, foi utilizada apenas uma imagem de boa resolução com data de 20/05/2018 que obteve um erro RMSE de aproximadamente 2.90 m.

Caso a aplicação obtenha sucesso junto ao CASSIE, a escolha de imagens por meio do modelo treinado foi incorporada a ferramenta, podendo ser melhorada com mais estudos posteriores ou projeto sequenciais a esse. Todo o processo de teste e incorporação ao CASSIE foi feito em conjunto com a equipe do projeto, em reuniões semanais para validação da aplicação e correção de possíveis erros.

Figura 9. Diagrama de sequência do funcionamento do modelo proposto com o sistema já existente do C.A.S.S.I.E.




Fonte: o autor.

3.3.2 Construção dos códigos.

Algoritmo Genético

O algoritmo genético foi desenvolvido com base nas etapas principais contidas no algoritmo genético e os conceitos de cada uma das modalidades de seleção, cruzamento e mutação escolhidas para este trabalho. As etapas principais são: iniciar população, atribuição de score para cada indivíduo, validação de fim de execução, gerar nova população. Dentro da etapa de gerar nova população tem-se as etapas de seleção de pais ou gerar mutação, executar cruzamento ou mutação e preenchimento da nova população. A população foi desenvolvida como uma lista e um indivíduo foi desenvolvido como um objeto com id, genes e score, conforme a Figura 10. Cada indivíduo é retirado da população a cada geração, dando origem a novos indivíduos, exceto os dois melhores de cada geração, preservando assim os melhores genes.

Figura 10. Diagrama de classe do objeto indivíduo.



Fonte: o autor.

Como artefato principal para construção do Algoritmo Genético, foi utilizado o laço de repetição para iterar sobre a população e realizar as operações necessários, como o algoritmo teve de ser reescrito em Java Script e Python, foi decidido utilizar este artefato para não sofrer com questões de bibliotecas incompatíveis entre as linguagens, o Quadro 4 mostra o pseudocódigo da função geral do AG. Para decisões para qual tipo de seleção, qual tipo de cruzamento ou se irá fazer mutação ou cruzamento foi utilizada uma escolha aleatória, onde é sorteado um número entre 0 e 1 e se for menor que 0,5 é escolhida uma das opções e caso contrário é escolhida a segunda opção.

Quadro 4 - Código fonte da função geral do algoritmo genético

```

função iniciar(data_de,data_ate,local, dados_treino):
    imagens = BuscarImagens(data_de, data_ate, local)
    enquanto(Numero_de_geracoes < Maximo_de_geracoes):
        para i menor que Tamanho_populacao faça:
            score = 0
            score=batimetria.geraBatimetria(genes,imagens,
dados_treino)
            popula tion[i]['score'] = score
        população = GeraNovaPopulação()
        contagemDeGeracoes += 1
        if Numero_de_geracoes >= Maximo_de_geracoes:
            pare
  
```

Fonte: O autor (2022).

Na construção do método de seleção roleta foi feita uma implementação com base no score de cada indivíduo, onde o tamanho da roleta é calculado de acordo com o tamanho da população e a somatória de todos os scores daquela geração. Os indivíduos com maior score ocupam um tamanho maior na roleta e tem mais chances de ser escolhidos. Depois é sorteado uma posição da roleta aleatoriamente e verificado qual o indivíduo que corresponde ao id sorteado escolhendo assim os pais para o cruzamento. Para o método de seleção torneio, foi

dividia a população em duas listas, percorrendo cada uma das listas e realizando comparações para verificar qual o indivíduo tem o menor score, visto que aqui o score é o RMSE e quanto menor é este erro, melhor é o indivíduo, para assim este avançar para a próxima chave até que só restem dois indivíduos que são escolhidos como pais para o cruzamento. Para construção dos métodos One Point Crossover foi feita uma função simples que escolhe um ponto aleatório entre os 7 genes e aplica o cruzamento dos genes dos dois pais selecionados, da mesma forma o método aritmético é feito utilizando um valor aleatório para ser o ponto que irá calcular o cruzamento.

Algoritmo de batimetria

O algoritmo de batimetria cedido pela equipe do CASSIE, foi desenvolvido por um dos membros com base na teoria de razão de bandas, onde foi utilizada a razão das bandas verde e azul para criar uma regressão linear que descrevesse a batimetria do local. O algoritmo foi desenvolvido em Java Script para execução na plataforma do Code Editor do GEE, desta forma foi preciso reescrever boa parte do código para funcionar tanto com a API do Java Script, quanto para API do Python.

O algoritmo consiste basicamente, em realizar uma regressão linear para encontrar os coeficientes que explicam a relação entre a razão das bandas verde e azul em função da profundidade. Após isso é calculado o RMSE da predição e exibido um mapa de profundidade estimada pelo algoritmo para a imagem selecionada. Um ponto importante sobre o algoritmo é que ele depende de dados de treino para ser executado, desta forma é necessário que o usuário sempre informe os dados de medições em campo para que possa prosseguir com a predição desejada, mesmo que não seja para a mesma data da medição. Esta dependência foi aplicada também ao CASSIE inicialmente e por conta disso o algoritmo utilizado para essa pesquisa também obteve essa dependência, mesmo que para o resultado não fosse tão impactante, visto que é retornado apenas os pesos para filtragem de imagem.

Os pontos focais deste trabalho em cima do algoritmo de batimetria foram nas funções de adição de banda de qualidade, onde são multiplicados os pesos processados pelo AG nas bandas de cada pixel de cada imagem da coleção de imagens e criado uma banda para cada pixel com o valor calculado. O valor calculado posteriormente é utilizado pela função `qualitymosaic()` do GEE que monta um mosaico com os maiores valores de uma banda passada por parâmetro. A Equação Y mostra o código da função de adição da banda de qualidade de pixel e da função `qualitymosaic()`. O quadro 5 mostra o pseudocódigo final do algoritmo de batimetria.

Quadro 5 - Código fonte da função de batimetria

```
função geraBatimetria(genes, imagens, dados_de_treino):
    colecao_filtradas = filtro_nuvens_ruidos(imagens)
    colecaoQA= adiciona_banda_qualidade(imagens_filtradas)
    mosaico = gera_mosaico_qa(colecaoQA)
    dados_regressao = geraDadosTreino(mosaico,dados_treino)
    modelo = regressao_linear(dados_regressao)
    coeficientes = modelo['coeficientes']
    dados_preditos = predicao_batimetria(coeficientes,
    dados_regressao)
    RMSE = calcula_RMSE(dados_regressao, dados_preditos)
    Retorna RMSE
```

Fonte: O autor (2022).

3.3.3 Dificuldades e planos de contingência

Conforme já explanado, foi encontrado vários problemas para a execução do AG e a obtenção dos resultados, para muitos desses problemas não foram encontradas soluções suficientes para deixar o algoritmo totalmente funcional, entretanto os problemas que impediam a execução foram sanados ou contornados.

O primeiro problema encontrado foi a limitação da plataforma de programação disponibilizada pelo GEE, onde é possível programar em Java Script e utilizar os objetos do GEE e o poder de execução do Google Cloud. A plataforma inicialmente é bem usual, permitindo a fácil manipulação de imagens de satélite e dados pesados, com a possibilidade de plotar gráficos e mapas customizáveis etc. Entretanto foram encontradas várias falhas na leitura de tipos de variáveis, por conta da ferramenta ter uma tipagem própria de variáveis, onde muitas vezes acaba gerando erro em operações por conta da conversão da tipagem universal para tipagem do GEE, como por exemplo a tipagem inteiro é reconhecida pela plataforma, mas por vezes ela é convertida para a tipagem EE.Number que é uma tipagem do GEE e ao comparar uma variável do tipo inteiro e do tipo EE.Number gera erros de execução. A primeira ação sobre esse problema foi reescrever todo o código utilizando a tipagem do GEE, entretanto nesse ponto há outro problema, pois, a tipagem do GEE não permite todas as operações necessárias para execução do AG gerando mais erros de execução e principalmente em comparações de duas variáveis. Com isso foi decidido utilizar a API externa do GEE via Java Script, já aplicando na ferramenta do CASSIE.

O segundo problema enfrentado foi a forma de autenticação legada da plataforma do CASSIE, visto que o Google alterou suas autenticações para o OAuth 2.0 e assim todos os

aplicativos com a forma de autenticação antigas não teriam permissão para executar o modo desenvolvedor do aplicativo. Desta forma ficou inviável implementar o AG e a geração dos mosaicos dentro da ferramenta do CASSIE e seria mais complexo escrever uma aplicação para executar os algoritmos, tomando assim a segunda medida de contingência que foi mudar os algoritmos para Python e executar via Google Colaboratory.

Dentro do Google Colaboratory, foi reescrito o algoritmo de batimetria quase por completo e o algoritmo genético por completo, permitindo assim sua execução na plataforma. A primeira execução gerou muita lentidão por conta do terceiro problema encontrado, sendo este até o momento sem solução, que é a lentidão na tradução dos valores de objetos do GEE, por meio da função `GetInfo()`. Essa tradução é necessária para avaliar o RMSE calculado pelo algoritmo de batimetria e como o resultado fica armazenado numa variável do tipo `EE.Number` é impossível lê-la sem a tradução no servidor do GEE, onde o viés é a lentidão de dois minutos, aproximadamente, cada tradução. Numa execução paralela para diminuir a lentidão, também não é obtido muitos ganhos, visto que há um limite de requisições no servidor e, portanto, causa perda de dados se executado várias requisições ao mesmo tempo.

Por conta da lentidão na execução, ficou impossível de finalizar o algoritmo no Colaboratory, visto que há um limite de execução de 8 horas seguidas no plano gratuito. Como não era possível desenvolver uma função de tradução do objeto e não havia mais melhorias possíveis no código, chegou-se a duas opções de contingência: Executar o algoritmo localmente através da plataforma PyCharm e deixar executando por dias para gerar as máscaras. A segunda opção era pesquisar mais sobre a API via REST do GEE, onde seria possível obter os valores dos pixels em um array e a partir daí realizar todas as operações diretamente no Python.

Para contornar o problema de lentidão foi iniciado um trabalho paralelo para tanto pesquisar sobre a API via REST, quanto executar o algoritmo localmente, desta forma o andamento do projeto não ficaria parado. O algoritmo da API via REST foi iniciado e finalizado, porém ainda sofre com lentidão por conta da lógica de montagem do mosaico e o tamanho dos dados utilizados, onde é necessário encontrar uma forma de aplicar as máscaras em todos os pixels de todas as imagens da coleção e depois calcular o score de cada pixel, para posteriormente selecionar o pixel com maior score para cada coordenada da imagem mosaico a ser gerada. Com disso o algoritmo via REST não é uma alternativa viável para contornar o problema de lentidão até o momento, sendo necessário mais pesquisas sobre o assunto e realizar novos testes. Com isso a forma de contornar o problema de forma localmente e diminuir o tempo de execução que estava levando em torno de 3 a 4 dias, foi

diminuir as gerações e o tamanho da população para que o tempo de execução seja menor e assim seja possível a geração de mais máscaras, atingindo o tempo de 1 dia para executar o algoritmo.

3.4 RESULTADOS E DISCUSSÃO

Nesta seção será decorrido sobre os resultados obtidos nos testes efetuados no algoritmo durante a etapa de desenvolvimento. Vale ressaltar que devido a problemas na plataforma e lentidão na execução não foi possível executar todos os testes planejados para confirmar o funcionamento do algoritmo, entretanto os testes realizados apresentaram resultados melhores que as tecnologias atuais utilizadas pelo CASSIE, em questão de visualização de imagem e RMSE de estimação da batimetria.

3.4.1 Análise e desenvolvimento de cenários de teste

Para realizar os testes, foram desenvolvidos alguns cenários para validar se o algoritmo estava gerando imagens de qualidade para o cálculo de batimetria e se as funções utilizadas estavam montando um mosaico adequado. O Quadro 4 mostra os principais cenários testados.

Quadro 6. Cenários de teste utilizados nas simulações.

Cenário	Descrição
Cenário 1	Período de 01/05/2018 a 30/06/2018, onde é escolhido a melhor imagem desse período e comparado com o mosaico de toda a coleção deste mesmo período. Cenário onde existe imagens com muitas nuvens e com poucas nuvens.
Cenário 2	Período de 01/01/2018 a 30/04/2018, onde é escolhido a melhor imagem desse período e comparado com o mosaico de toda a coleção deste mesmo período. Cenário onde existe imagens com muitas nuvens e com poucas nuvens.
Cenário 3	Período de 01/08/2018 a 30/12/2018, onde é escolhido a melhor imagem desse período e comparado com o mosaico de toda a coleção deste mesmo período. Cenário onde existe imagens com muitas nuvens e com poucas nuvens.
Cenário 4	Período de 01/10/2018 a 30/11/2018, onde é escolhido a melhor imagem desse período e comparado com o mosaico de toda a coleção deste mesmo período. Cenário onde quase todas as imagens da coleção têm muitas nuvens, verificando o comportamento do algoritmo quando não se tem uma imagem de boa resolução para servir de base.
Cenário 5	Período de 01/01/2018 a 30/05/2018, onde é escolhido a melhor imagem desse período e comparado com o mosaico de toda a coleção deste mesmo período. Cenário na região próxima as ilhas onde a morfologia do local é diferente, imagens com e sem nuvens.
Cenário 6	Período de 01/06/2018 a 30/12/2018, onde é escolhido a melhor imagem desse período e comparado com o mosaico de toda a coleção deste mesmo período. Cenário na região próxima as ilhas onde a morfologia do local é diferente, imagens com e sem nuvens.

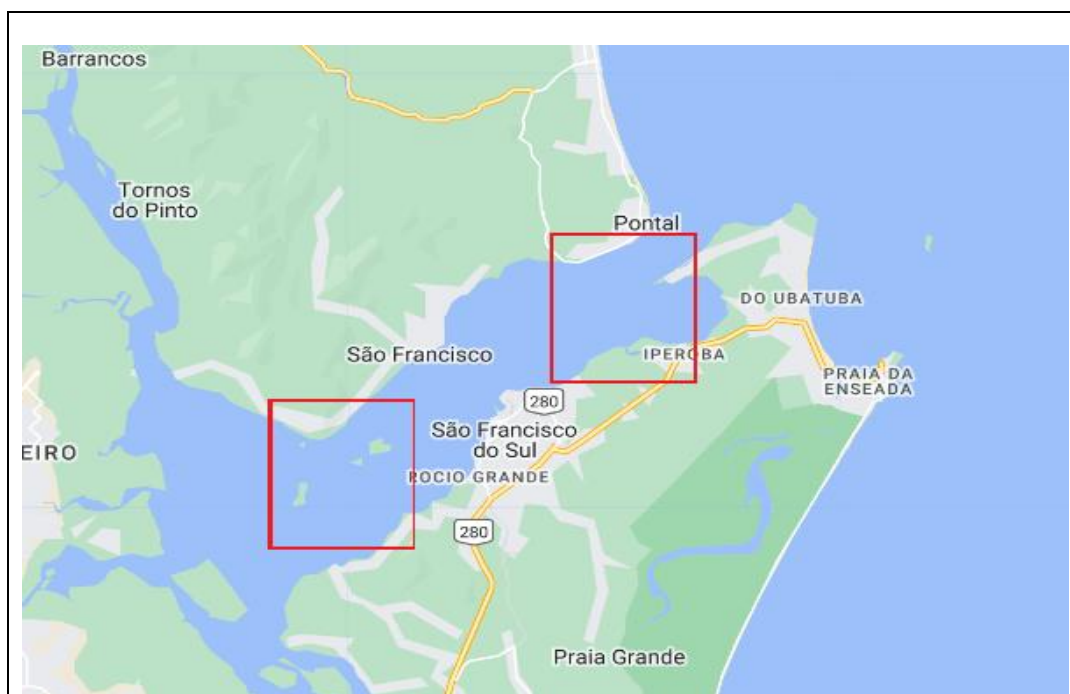
Fonte: o Autor

Para os cenários de 1 a 4 foi selecionada a região próximo ao porto da Baía da Babitonga, onde foi disponibilizada a maior parte dos dados medidos em campo, e foi o local de validação do algoritmo que foi atribuído ao CASSIE, desta forma foi possível comparar os resultados de validação utilizado na homologação da ferramenta juntamente aos resultados que a máscara gerada pelo AG proporcionou. O motivo para a escolha de 4 cenários diferentes para o mesmo local é averiguar o quanto o tamanho da janela temporal da coleção

impacta na qualidade do mosaico gerado, ou seja, verificar se em coleções com um período maior ou menor de tempo existem impactos positivos ou negativos nos resultados.

Para o cenário 5 foi escolhida outra região da Baía da Babitonga, onde a região representasse uma variação morfológica, com a presença de ilhas e trechos com mais material em suspensão. Para este teste foi escolhido as mesmas datas para comparar o comportamento do algoritmo em outros cenários. Foi feito também um teste de adaptação da máscara gerada, ou seja, aplicando a máscara gerada na região 1 em cima da imagem da região 2, como também foi gerada uma máscara específica para a região 2, para comparação dos resultados das duas máscaras. As duas regiões estão dispostas na Figura 11.

Figura 11. Localização no mapa dos locais de teste selecionado



Fonte: o autor.

3.4.2 Primeiro Cenário: Período de 01/05/2018 a 30/06/2018 – Região próxima ao porto.

A primeira execução do algoritmo para a primeira região no período de 01/05/2018 até 30/06/2018 gerou a máscara mostrada na Tabela 2. Neste primeiro teste, testou-se a hipótese de ter alguma correlação entre outras bandas da imagem com a profundidade, não só aquelas que estava sendo usadas no cálculo, ou seja, tentava-se descobrir a influência de alguma outra banda no cálculo de batimetria indiretamente, visando buscar melhores formas de filtragem para imagens não em más condições. Entretanto foi verificado em um teste que ao remover

algumas bandas o resultado das imagens melhorava, como também o RMSE gerado da estimativa de batimetria que será discutido mais à frente.

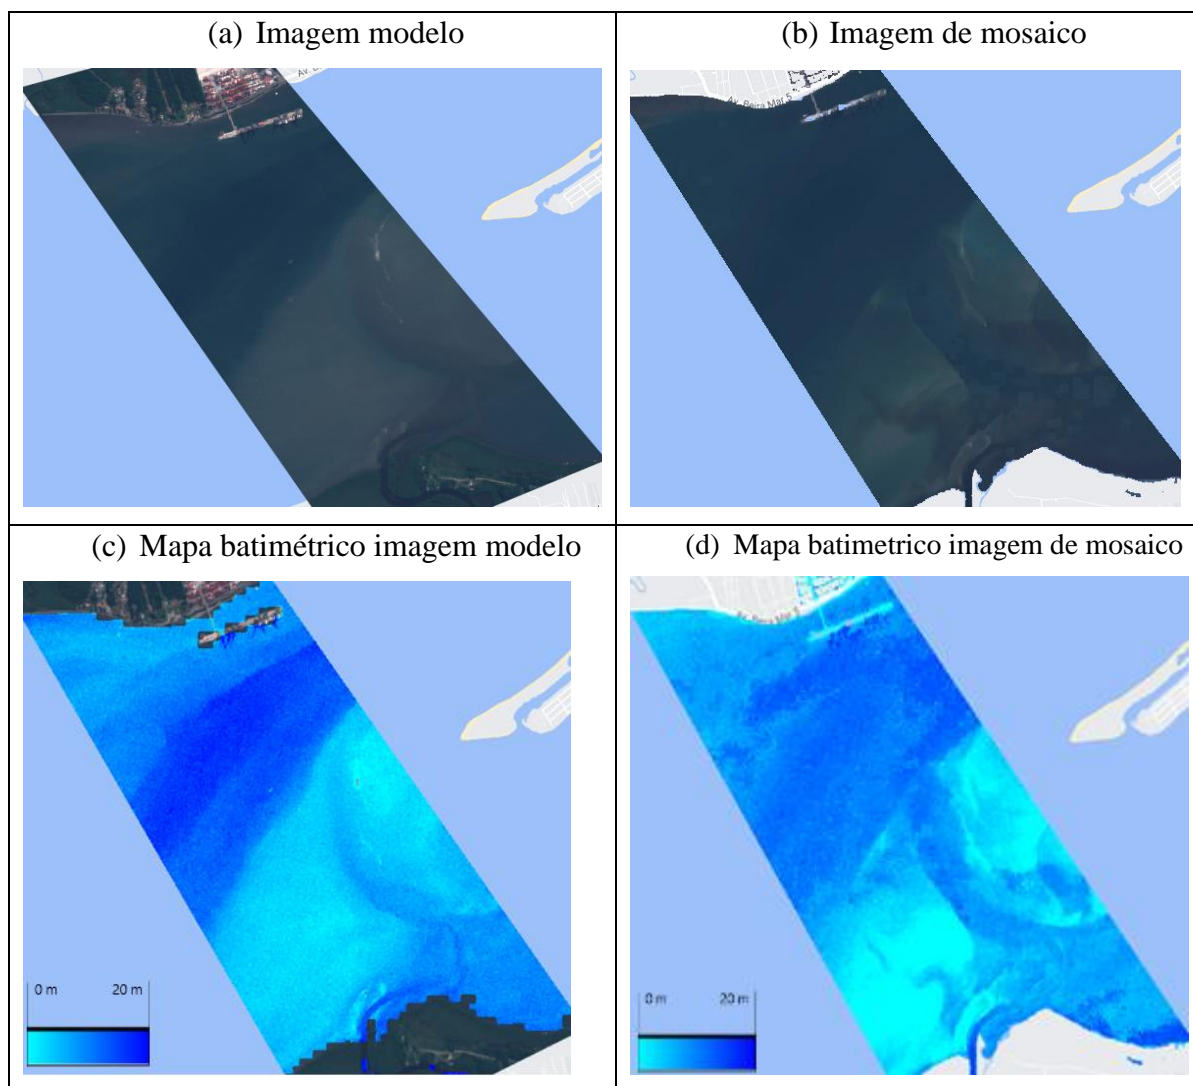
Tabela 2. Pesos para cada banda – Primeiro Cenário/Primeiro teste.

Banda	Peso calculado
Banda 1 - Aerossol	0.0075
Banda 2 – Azul	0.0102
Banda 3 – Verde	0.0001
Banda 4 – Vermelho	0.3019
Banda 5 – Vermelho de borda 1	0.0007
Banda 6 – Vermelho de borda 2	0.0010
Banda 8 – Infravermelho próximo	0.0046
NDWI	0.1840

Fonte: o autor.

Com a máscara em mãos, foi executado o algoritmo de batimetria adicionando nele a banda de qualidade, onde é aplicada a máscara nas bandas correspondentes (bandas de B1 a B6, banda B8 e o NDWI) e gerado o mosaico com a função nativa do GEE, que constrói o mosaico a partir dos maiores valores de uma banda especificada. Por fim é estimado a batimetria e gerado o erro para o período/região escolhido e comparado com o erro gerado para melhor imagem do mesmo período, imagem essa do dia 20/05/2018, que foi escolhida manualmente dentre a coleção do período, avaliando a porcentagem de nuvens que ela continha. O comparativo da melhor imagem e da imagem de mosaico está exposto na Figura 10, onde a Figura 12-a mostra a melhor imagem do período e na Figura 12-b é mostrada a imagem de mosaico, em primeira vista já é possível verificar que a parte rasa da imagem, contrária ao porto, mostra diferenças de material em suspensão ou maré. Na imagem modelo, é visto que há uma certa divergência também em relação com outra imagem boa do período como aponta a Figura 13 que mostra duas imagens de períodos mais distantes, uma de abril de 2018 e outra de setembro de 2018, indicando que a medição em campo pode ter sido feita em condições excepcionais causando erros de estimação com base nos dados medidos em campo caso as condições não sejam satisfeitas.


Figura 12. Comparativo da imagem modelo do primeiro cenário e imagem de mosaico.



Fonte: Code Editor (GEE) – o Autor.

A estimativa da batimetria com o mosaico de imagens gerou um RMSE de 3,70 metros, sendo pior que o RMSE da melhor imagem do período que obteve 2,90 metros, mostrando que neste período o algoritmo não foi capaz de gerar resultados melhores. Um dos motivos do algoritmo não conseguir gerar bons resultados é a qualidade da imagem em comparação, o mosaico acaba por perder qualidade da imagem e a normalização das bandas da imagem pois é constituído de pixels de imagens de outros períodos, podendo sofrer interferência de maré, material em suspensão, entre outros. Outro motivo observado foi o peso de algumas imagens para a montagem do mosaico, em casos que existam mais de uma imagem nítida por período e a concentração de verde e azul é maior em uma das imagens, o que faz com que a função de mosaico do GEE escolha os pixels da imagem com maior concentração de azul e verde e apenas substituir os pixels faltantes ou que não tem boa qualidade.

Figura 13. Imagens seleccionadas em diferentes datas para mostrar o padrão de morfologia da área.



Fonte: Code Editor (GEE) – o Autor.

Para chegar no RMSE de 3,70 metros, entretanto, foi necessário executar o algoritmo por três vezes, analisando os impactos da retirada de algumas bandas. No primeiro teste com todas as bandas foi retornado um erro de 4,65 metros, o que mostrou uma correlação ruim entre as bandas e a profundidade, levando a eliminar os pesos para as bandas B1, B4, B5, B6 e B8, deixando apenas as bandas B2, B3 e o NDWI. Com isso, primeiramente, foi executado novamente o AG para refazer os pesos considerando agora apenas quatro genes. Os pesos gerados são apresentados na Tabela 3, com eles foi possível obter o RMSE de 3,78 metros. Para fins de encontrar as melhores bandas para o cálculo foram efetuadas simulações retirando um dos quatro genes na geração do mosaico e um para cada um deles sozinho e verificado qual tinha maior impacto no RMSE. Após a seção de testes foi identificado que a banda B4 tinha menor correlação com a extinção do erro, desta forma esse peso foi retirado e foi possível chegar no RMSE de 3,70 metros.

Tabela 3. Pesos para cada banda – Primeiro Cenário/Segundo Teste.

Banda	Peso calculado
Banda 2	0.0727
Banda 3	0.3476
Banda 4	0.0365
NDWI	0.5356

Fonte: o autor.

Para melhor visualização, foi construído um mapa da estimativa de batimetria da região (Figura 12-c e 12-d) tanto para imagem modelo (12-c) quanto para imagem de mosaico (12-d), onde pode-se verificar que as imagens divergem na parte mais rasa onde na imagem de mosaico está com a parte azul mais forte, indicando profundidade maior, como também uma pequena divergência na profundidade próxima ao porto, indicando maior área profunda na imagem de mosaico. Isso se deve por conta de outra imagem do período em que o material em suspensão foi menor e tanto a parte mais rasa quanto a mais profunda estão mais visíveis, entretanto essa imagem acaba não tendo muita correlação com a profundidade medida gerando o mesmo problema para a imagem de mosaico.

3.4.3 Segundo Cenário: Período de 01/01/2018 a 30/04/2018– região próxima ao porto.

O segundo cenário previa a geração do mosaico e a realização da estimativa da batimetria no mesmo local, porém em um período diferente, sendo este do dia 01/01/2018 até 30/04/2018. Neste teste os resultados foram menos precisos, visto que atingiram um RMSE maior que a melhor imagem do período e atingiram o maior RMSE de todos os testes efetuados. É fato também e o RMSE da melhor imagem deste período também não foi o melhor, atingindo em torno de 3,39 metros, mostrando que as imagens deste período não tiveram muita correlação com a batimetria medida por conta de alguma característica que dificulta o cálculo como o material em suspensão na água quando a imagem foi capturada.

Para este cenário foi efetuado também dois testes, o primeiro consistia em aplicar os pesos do primeiro período, em que foi retirado os pesos das bandas que não criaram boa correlação com a profundidade, visando verificar o comportamento da máscara em períodos diferentes para constatar que o algoritmo consegue gerar pesos suficientes para todos os períodos. O segundo teste se resumiu em gerar novos pesos para o período específico, com a execução do AG com esses parâmetros.

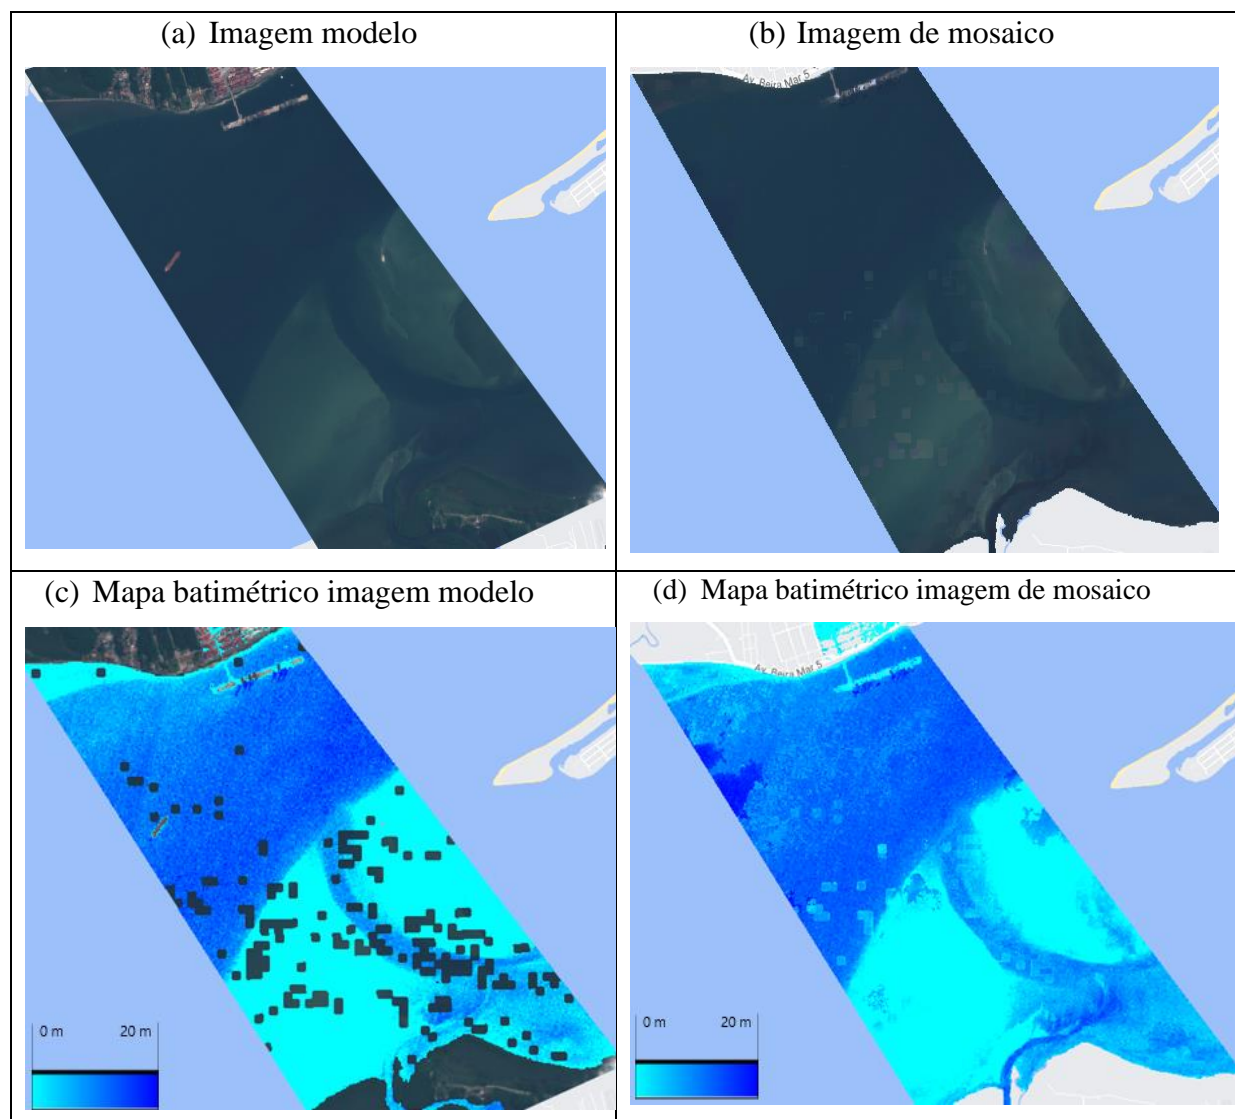
Tabela 4. Pesos para cada banda – Primeiro Cenário/Segundo Teste.

Banda	Peso calculado
Banda 2	0.0005
Banda 3	0.0395
NDWI	0.7269

Fonte: o autor.

A aplicação da mesma máscara do primeiro período, gerou um RMSE de 3,88 metros o que é um resultado relevante em relação a melhor imagem do período, visto que a diferença entre os erros é bem pequena. A Figura 14 mostra a melhor imagem do período, selecionada manualmente de acordo com a porcentagem de nuvens informada pelo GEE, datada do dia 20/04/2018 e a imagem de mosaico gerada a partir do período do segundo cenário. Em primeira vista as imagens mostradas nas Figuras 14-a e 14-b são bem parecidas, mostrando que o algoritmo preservou boa parte da melhor imagem no mosaico retirando apenas artefatos que não iriam gerar uma boa estimativa de batimetria que ficará mais visível nas Figuras 14-c e 14-d que mostra o mapa batimétrico gerado. É possível identificar também os pontos em que o mosaico substitui na imagem de mosaico, visto que há partes de pixels de cor diferente que a maioria e a retirada de uma embarcação que existe na melhor imagem do período, como também um escurecimento da região de deságua do rio, na parte inferior da imagem.

Figura 14. Comparativo da imagem modelo do segundo cenário e imagem de mosaico.

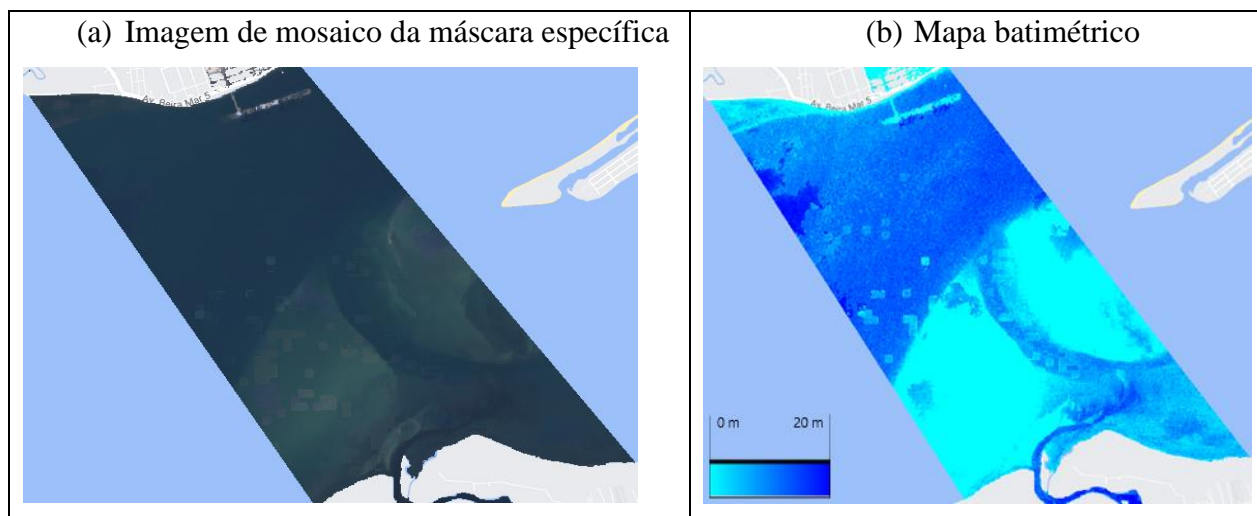


Fonte: Code Editor (GEE) – o Autor.

Referindo-se a questão da estimativa de batimetria vemos uma diferença maior entre as imagens, visto que na melhor imagem período tem-se vários pixels faltantes na estimativa de batimetria, valores que são substituídos na imagem de mosaico com uma precisão semelhante, indicando que o algoritmo pode recuperar pixels faltantes com uma precisão aceitável, conforme mostra a Figura 14-c e 14-d. Nesta observação também pode ser inferido que foi preservado boa parte do valor de profundidade, mantendo o valor mais raso da imagem de mosaico bem próximo do valor da melhor imagem tendo algumas introduções de profundidade exacerbada de forma equivocada. É visível também uma falha na estimativa da área do porto, onde na verdade não deveria ter estimativa por se tratar de um local não água, bem como alguns pontos de terra que foram estimados mesmo não sendo um local aquático. No mais, é possível utilizar a imagem de mosaico como uma aproximação da estimativa de batimetria de datas que compõe o período com uma pequena diferença no RMSE da melhor imagem.

O segundo teste, utilizando pesos gerados especificamente para este período, gerou um RMSE de 3,73 metros o que mostra que apesar da máscara do primeiro período servir para o segundo período ainda não é melhor que uma máscara gerada para o período em questão, o que pode levar a um ponto frágil desta implementação, visto que é demorada a geração de novas máscaras. A Figura 15 mostra a imagem de mosaico gerada pela máscara específica deste período e a estimativa de batimetria e, comparando com as imagens da Figura 14, é possível identificar que a mudança entre os resultados das máscaras é bem superficial, não tendo tanto impacto no resultado geral visualmente, apenas no detalhamento dos pontos, onde minimiza o RMSE comparada a outra máscara. A Tabela 4 demonstra os pesos calculados pelo AG para esse período em questão.

Figura 15. Imagem de mosaico de uma máscara específica para o segundo cenário e mapa batimétrico gerado a partir desta imagem.



Fonte: Code Editor (GEE) – o Autor.

3.4.4 Terceiro Cenário: Período de 01/08/2018 a 30/12/2018– região próxima ao porto.

O terceiro cenário tinha por objetivo, simular a aplicação dos pesos num período maior, considerando um período de cinco meses da janela temporal que não fora testada ainda. Seguindo a premissa do segundo cenário, foi testada a estimativa da batimetria com os pesos do primeiro cenário e a aplicação de pesos gerados especificamente para o período em questão. Vale ressaltar que a partir do segundo cenário, foram considerados como genes os pesos para as bandas B2, B3 e a razão das bandas B2 e B3 normalizada.

Tabela 5. Pesos para cada banda – Terceiro Cenário/Segundo Teste.


Banda	Peso calculado
Banda 2	0.0895
Banda 3	0.0875
NDWI	0.5559

Fonte: o autor.

Neste cenário foi possível obter o menor RMSE para a máscara do primeiro período, chegando a 2,34 metros e atingindo também um erro menor que a melhor imagem da coleção que obteve 3,39 metros. Com esse resultado, podemos observar que o AG permite a geração de máscaras capazes de gerar um mosaico melhor que uma imagem de boa qualidade, dependendo do período testado e principalmente de fatores como material em suspensão e maré. A Figura 16 mostra o comparativo das imagens utilizadas, sendo a melhor imagem da

coleção (16-a) e a imagem de mosaico (16-b), onde é possível identificar que a imagem de mosaico mantém a morfologia da imagem, normalizando alguns pontos e retirando características como barcos e nuvens, provando que a máscara tem efetividade na questão de características mais visíveis e traz uma imagem adequada para a estimativa da batimetria. É possível verificar também, que apesar de substituir as características, o mosaico não consegue substituir por pixels de mesma normalização, demonstrando uma certa falha na composição mesmo que não tenha um impacto tão grande.

Figura 16. Comparativo da imagem modelo do terceiro cenário e imagem de mosaico.



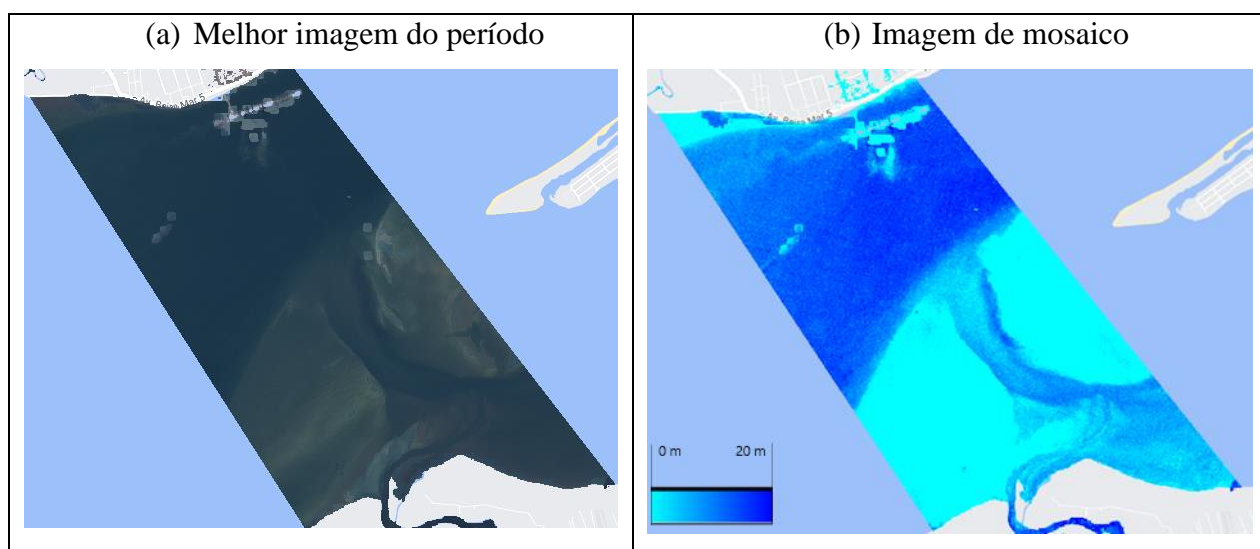
Fonte: Code Editor (GEE) – o Autor.

Em termos de batimetria, a máscara do primeiro período foi capaz de gerar um mapa batimétrico melhor que a imagem de melhor resolução da coleção. A Figura 16-c e 16-d mostra que a imagem de mosaico reconstrói as partes faltantes da imagem de melhor

resolução, mesmo que não seja com a melhor precisão, visto que algumas das partes substituídas são trocadas por área mais profundas ou mais rasas que o real. No mais a imagem de mosaico mantém as melhores partes da melhor imagem e assim consegue alcançar um RMSE menor que a imagem modelo, ficando claro ao conferir que há pequenas diferenças na imagem de mosaico e na imagem modelo.

Efetuada o segundo testes, foi obtido RMSE de 2,43 metros, mostrando que mesmo a máscara gerada para o período em questão pode trazer o melhor resultado, confirmando também que a máscara do primeiro período pode ser utilizada para estimar a batimetria em diversas condições com uma precisão aceitável, visto que manteve o RMSE próximo a imagem de melhor resolução. A Figura 17 mostra a imagem gerada e o mapa batimétrico gerado, sendo possível visualizar que a máscara específica resolve os pontos em que foi substituído errado os pixels de locais rasos por locais profundos, entretanto, esse ajuste visual não implicou no erro geral que foi menor que a outra máscara. Desta forma pode-se utilizar uma máscara específica para a região desejada, caso seja necessário apresentar um mapa mais preciso visualmente do que no detalhamento dos pontos. A Tabela 5 demonstra os pesos gerados especificamente para essa região.

Figura 17. Imagem de mosaico de uma máscara específica para o terceiro cenário e mapa batimétrico gerado a partir desta imagem.



Fonte: Code Editor (GEE) – o Autor.

3.4.5 Quarto Cenário: Período de 01/10/2018 a 30/11/2018– região próxima ao porto.

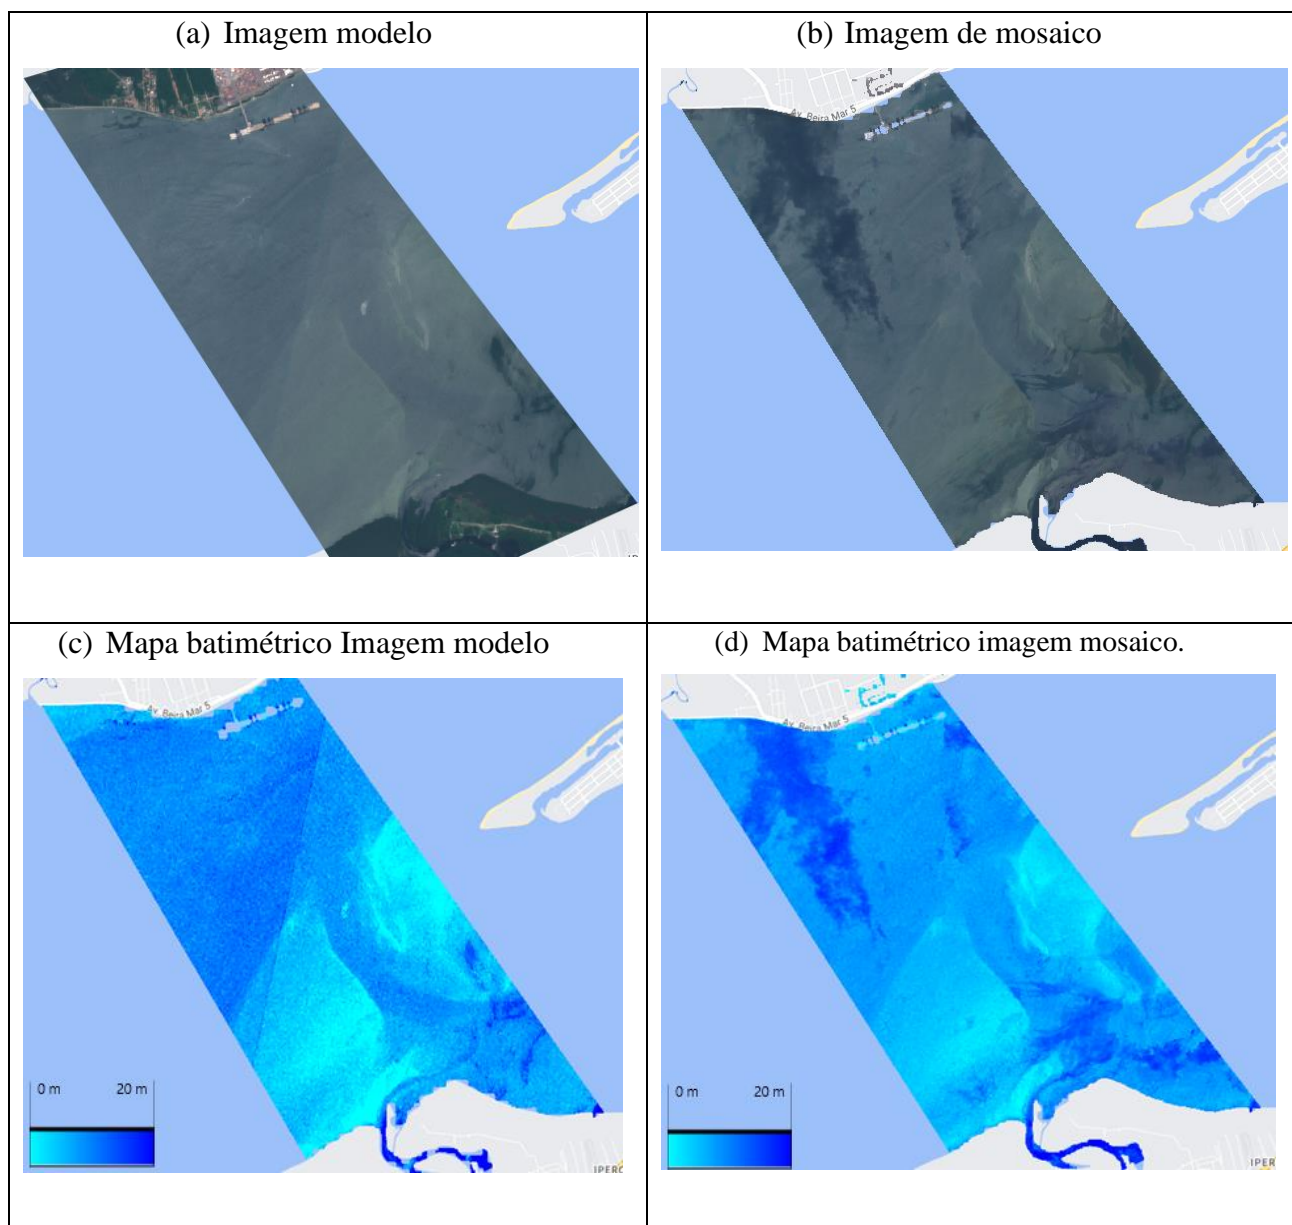
O quarto cenário é tido como o cenário mais desafiador, pois é testado a precisão do mosaico em uma coleção que não tem uma boa imagem para comparar, ou seja, todas as

imagens contêm uma quantidade expressiva de nuvens e aqui é avaliado o quanto o mosaico consegue preservar as melhores partes de várias imagens com baixa qualidade por conta da concentração de nuvens.

A aplicação da máscara do primeiro período gerou um RMSE de 4,18 metros, que apesar de ser um erro grande, considerando o cenário, é um bom resultado. É fato que com o cenário testado, seria muito difícil de obter um erro pequeno, visto que todas as imagens tinham muitas nuvens, entretanto com esta simulação foi possível verificar a eficácia do mosaico em questão do filtro de nuvens, visto que os pixels em que tem a maior quantidade de nuvem são retirados e são preservados todos os pixels mais limpos encontrados. Este fato também expõe a maior falha desta implementação, que é a dependência de um pixel dentro da coleção para a geração do mosaico, semelhante a medoid implementada por Flood (2013) e que pode ser melhorado como foi feito por ROBERTS et al. (2017). através da mediana geométrica. Essa melhora pode ser obtida com a utilização da API do GEE via REST, onde é possível utilizar outras funções para montagem do mosaico e filtragem de pixel visto que é limitada as opções oferecidas pela API do GEE padrão.

A Figura 18 mostra o comparativo entre a melhor imagem encontrada na coleção e o mosaico gerado, em primeira vista já é possível identificar o quanto a imagem modelo está prejudicada por uma concentração de nuvem fina, mas que abrange toda a imagem, o que acaba sendo absorvido pelo mosaico que seleciona esses pixels como os mais bem encontrados. É possível verificar também que apesar do mosaico manter os pixels com nuvem, ele substitui aqueles que existem um melhor pixel dentro da coleção.

Figura 18. Comparativo da imagem modelo do quarto cenário e imagem de mosaico.



Fonte: Code Editor (GEE) – o Autor.

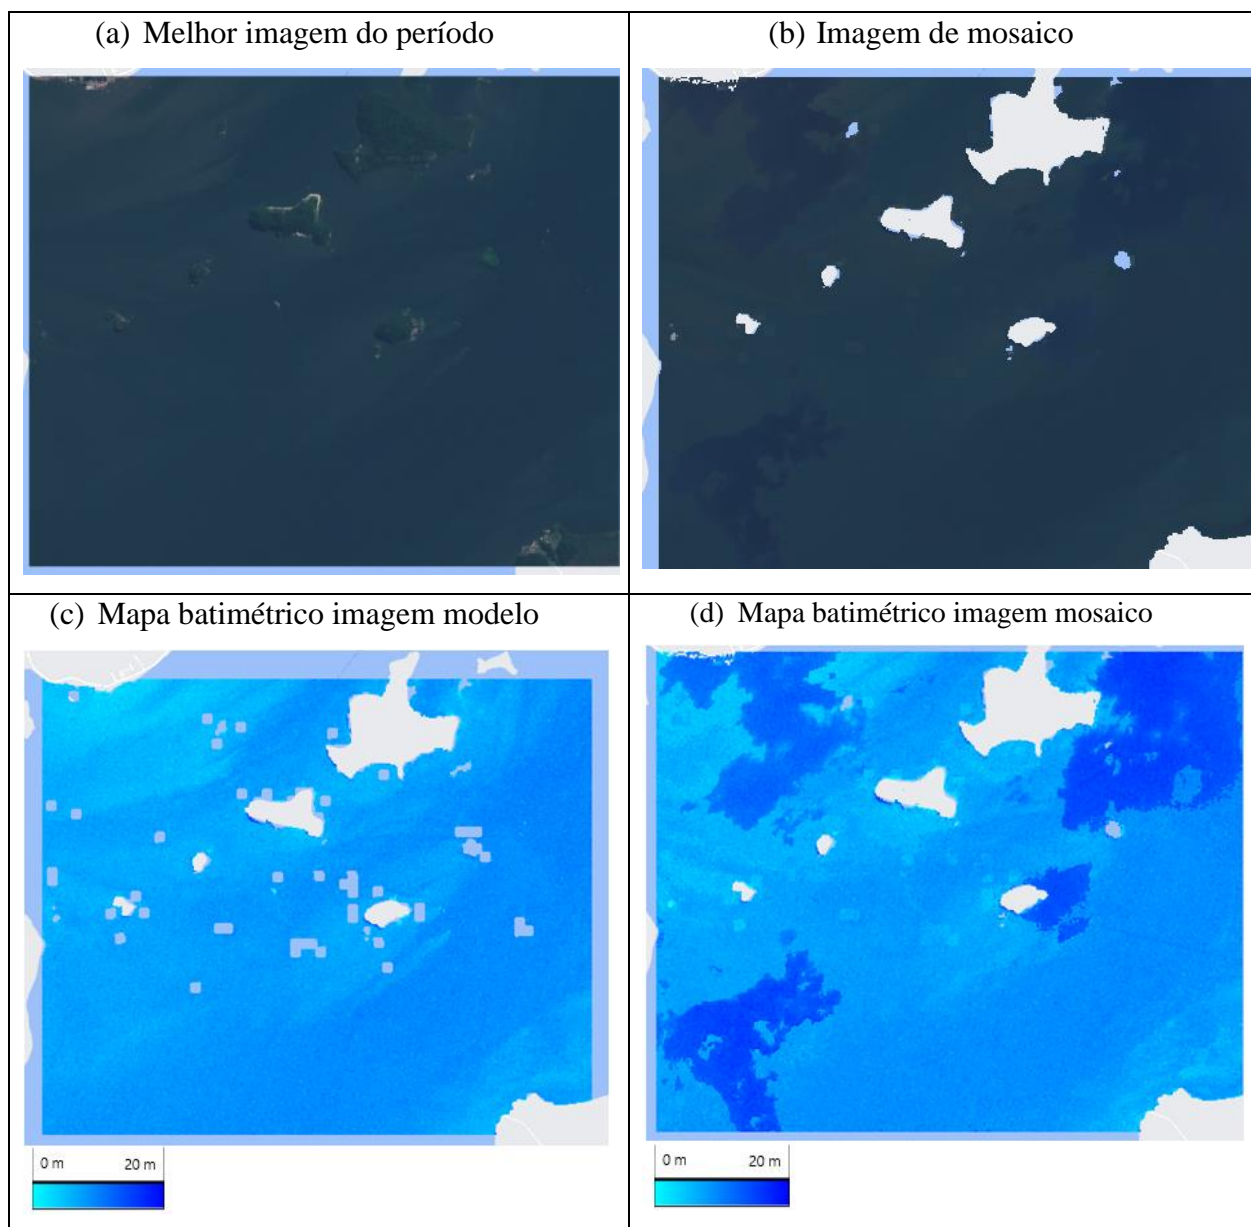
Em termos batimétricos foi gerado o mapa batimétrico das duas imagens e analisado os erros, a melhor imagem do período obteve um RMSE de 4,66 metros e como já observado anteriormente o mosaico obteve um RMSE menor que este, mostrando assim a superioridade do mosaico em cenários como este. A Figura 18-c e 18-d mostra o comparativo da estimativa de batimetria entre as duas imagens e demonstra o quanto a camada fina de nuvem interfere na estimativa, bem como mostra os pontos em que o mosaico possibilita melhor a estimativa do local neste período.

3.4.6 Quinto Cenário: Período de 01/01/2018 a 30/05/2018– região próxima as ilhas.

Para este teste, foi idealizada a aplicação da máscara do primeiro cenário, buscando verificar sua precisão em outro local e período, visto que foi alterado também o período a ser testado para mais meses. A região compreende um local com ilhas, gerando um pouco mais de dificuldade para o algoritmo filtrar não só nuvens, mas também locais não aquáticos. Para este teste também foi executado o AG para retornar uma máscara específica para o local e averiguar o quanto ela melhora comparada a máscara do primeiro período.

Para realização do teste comparativo, foi selecionada a imagem do dia 20/05/2018 como imagem modelo, mesmo que existissem outras imagens de boa qualidade, o motivo é que essa é a data em que foi utilizado como modelo para concepção do algoritmo de batimetria e consequentemente tem o melhor RMSE. A imagem modelo retornou um RMSE de 3,39 metros, enquanto a imagem de mosaico gerada a partir da máscara do primeiro cenário gerou um RMSE de 3,59 metros, o que indica certa proximidade entre as duas imagens na questão de erro. A Figura 19 traz as duas imagens do local, sendo a Figura 19-a a imagem modelo e a figura 19-b a imagem de mosaico. Analisando os resultados é possível verificar que a imagem de mosaico retira bem certos artefatos da imagem, entretanto, peca na inclusão de partes mais escuras na imagem que foge da distribuição normal da imagem, causando assim a diminuição da precisão, isso indica que a máscara preza muito pela concentração de azul e do NDWI sempre priorizando pixels que contenham muito disso sem verificar se os pixels vizinhos têm essa mesma concentração.

Figura 19. Comparativo da imagem modelo do quinto cenário e imagem de mosaico.



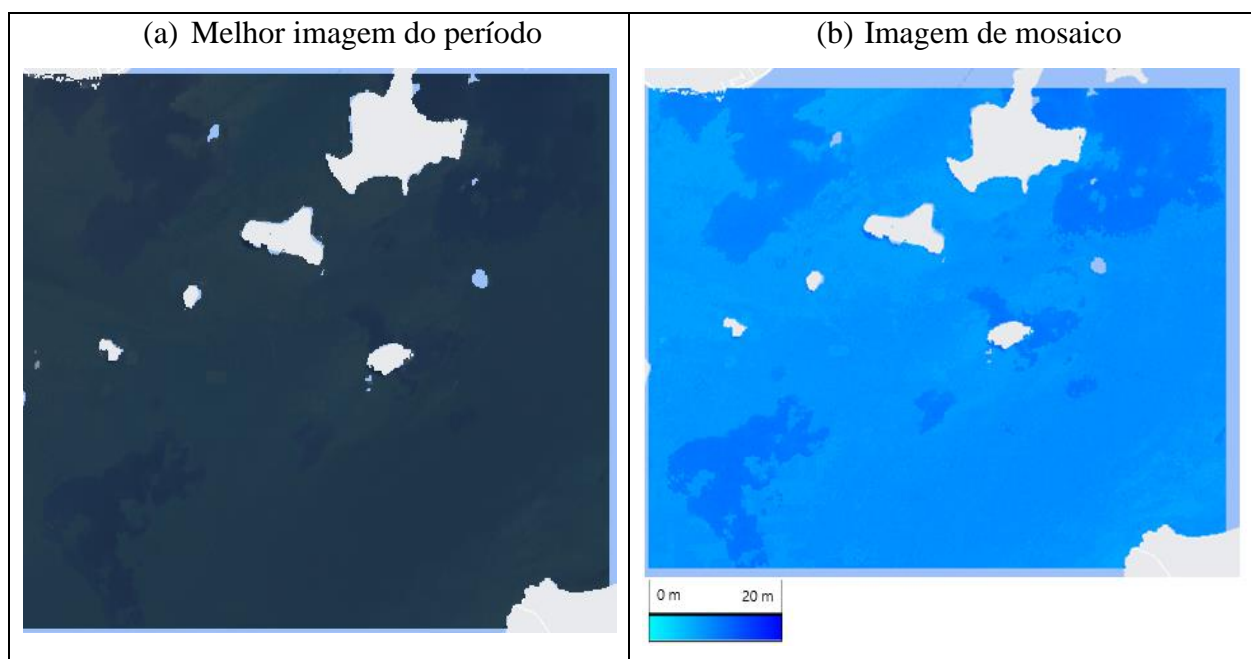
Fonte: Code Editor (GEE) – o Autor.

O mapa batimétrico das duas imagens foi gerado e apresentam características semelhantes na maior parte, tendo uma falha na predição da imagem de mosaico, como já comentado, onde em locais mais rasos foram introduzidos pixels de água profundo e gerou um erro visual do local. No mais a imagem de mosaico preenche os pixels faltantes da imagem modelo e mantém boa parte da distribuição da batimetria do local normalizada, mesmo sendo composta por imagens de um período de 5 meses, mostrando que o mosaico permite um equilíbrio das bandas, mesmo que não seja em sua totalidade. As Figuras 19-c e 19-d mostra os mapas batimétricos gerados e suas diferenças visuais que justificam a diferença entre os erros gerados, visto que a estimativa diverge em poucos locais. Com esse resultado pode-se confirmar que a máscara gerada consegue abranger não só outros períodos,

como também outros locais com diferentes morfologias, podendo ser aplicado em várias situações.

Para averiguar se há melhora no erro ou no mapa batimétrico, foi gerada uma máscara para o período e região em questão. A melhora do RMSE não foi muito relevante tendo a redução de apenas 0,01 metros atingindo 3,58 metros de RMSE, o que comprova a abrangência da máscara do primeiro cenário sendo ela atribuível a todos os períodos e locais, com média de erro semelhante a melhor imagem e ao mosaico de máscara específica. A Figura 20 mostra os resultados visuais da máscara específica, onde pode ser visto que foram suavizadas as partes substituídas incorretamente por locais mais profundos permitindo assim uma visualização mais parecida com a imagem modelo e diminuindo superficialmente o erro.

Figura 20. Imagem de mosaico de uma máscara específica para o quinto cenário e mapa batimétrico gerado a partir desta imagem.

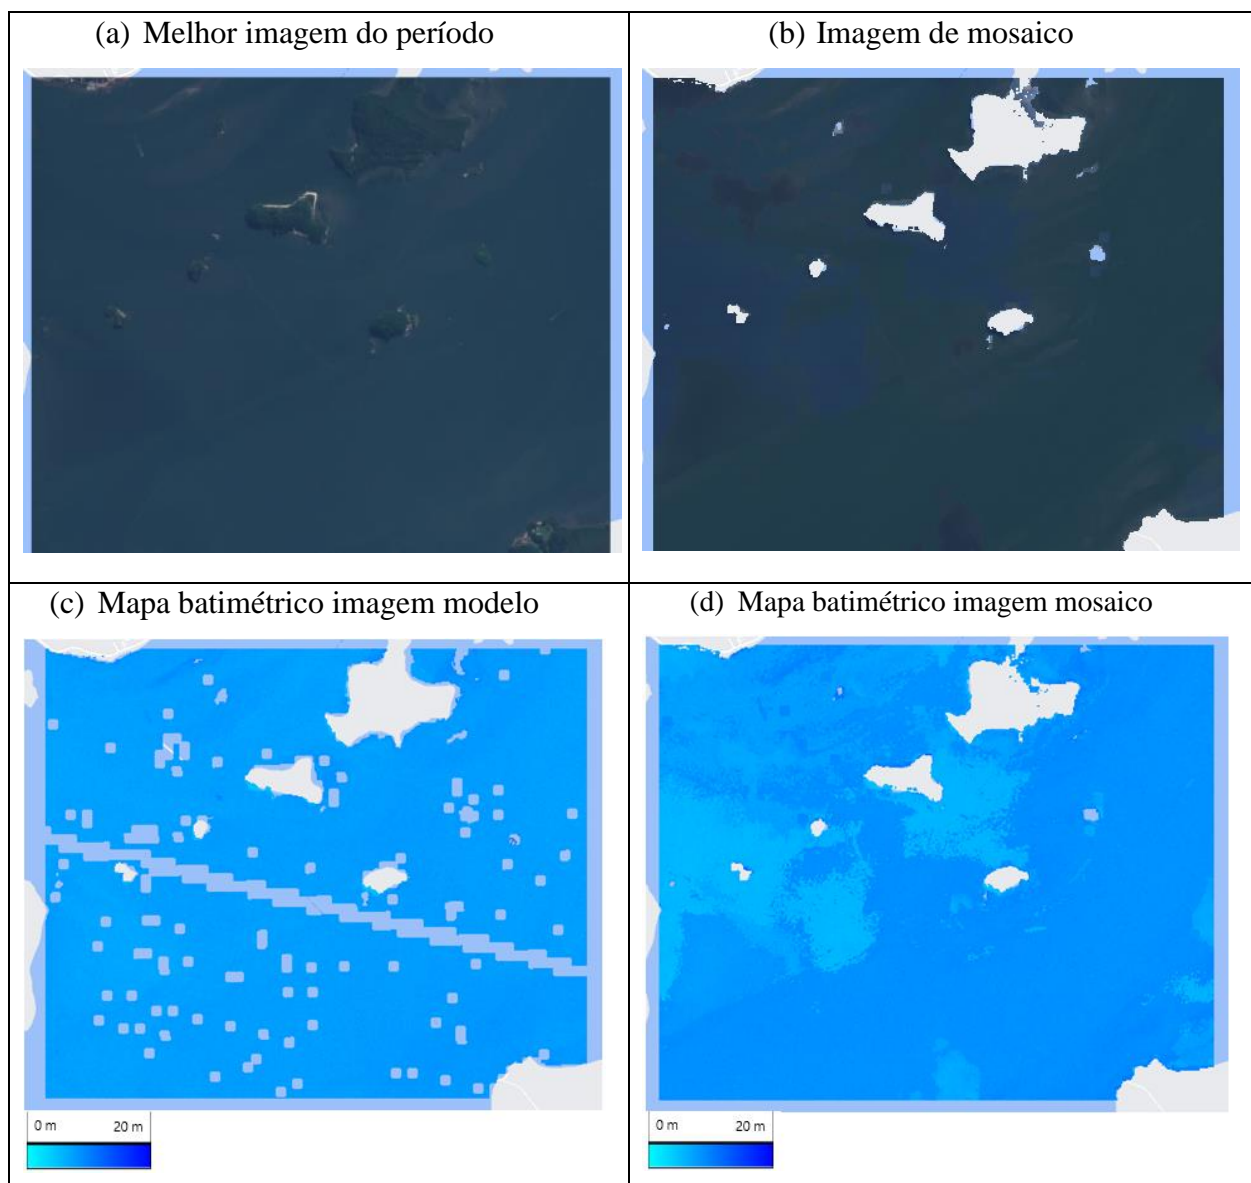


Fonte: Code Editor (GEE) – o Autor.

3.4.7 Sexto Cenário: Período de 01/06/2018 a 30/12/2018– região próxima as ilhas.

O último cenário previsto foi simular a estimativa de batimetria com a máscara do primeiro cenário e uma máscara gerada especificamente para este cenário, na região próxima as ilhas com período de seis meses, compreendendo os últimos meses do ano em que foi realizada a medição no local. Foi escolhida como imagem modelo a imagem do dia 14/07/2018 em que tem uma concentração baixa de nuvens. A imagem modelo atingiu um RMSE 3,62 metros comparados com os dados medidos no local.

Figura 21. Comparativo da imagem modelo do sexto cenário e imagem de mosaico.



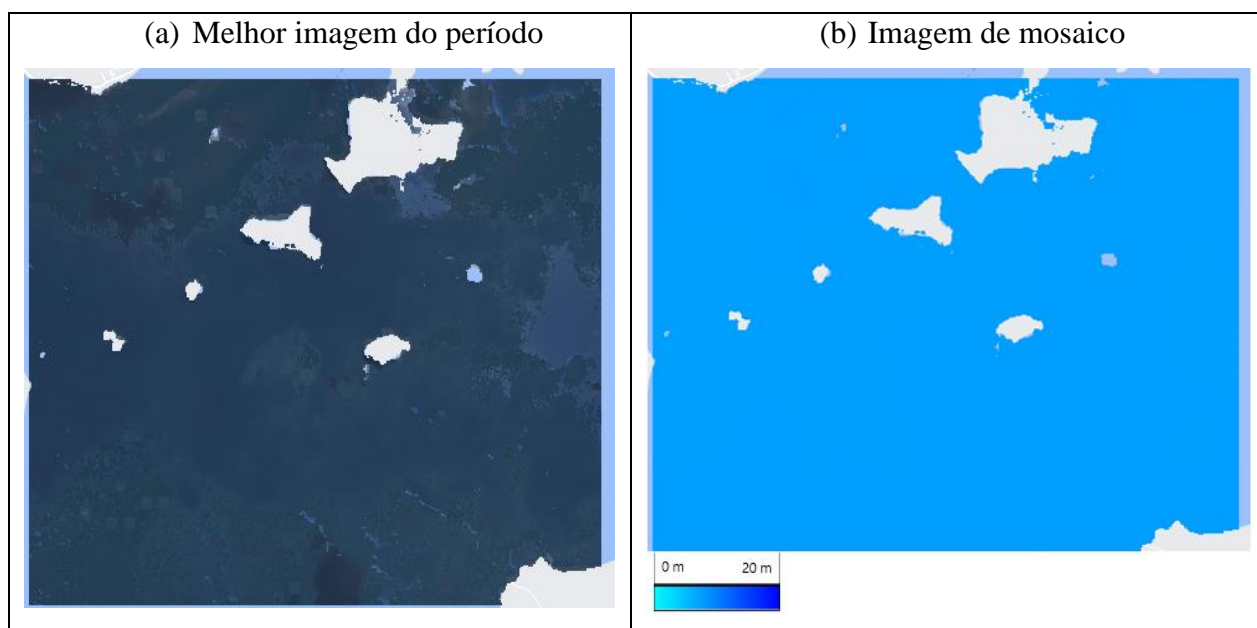
Fonte: Code Editor (GEE) – o Autor.

O teste realizado com a máscara do primeiro cenário gerou um RMSE de 3,56 metros e obteve um desempenho melhor que a melhor imagem da coleção mesmo que por pouca diferença. Nas Figuras 21-a e 21-b é possível visualizar as principais diferenças entre as imagens, o mosaico destacou partes mais esverdeadas dos pixels e trouxe alguns pontos com o azul mais forte, divergindo da imagem modelo que tem essas cores mais suavizadas, é possível verificar também ponto em que o mosaico trouxe pixels muito mais escuros que qualquer ponto da imagem modelo e que estimam a batimetria com uma diferença maior, aumentando o RMSE.

Os mapas batimétricos gerados, conforme mostra as Figuras 21-c e 21-d, explicam o motivo do mosaico ter tido um melhor desempenho comparado a imagem modelo, visto que a

imagem modelo perde muitos dados de estimativa tendo pouca assertividade por conta de características encontradas que foram retiradas pelo filtro. Já a imagem de mosaico traz o mapa completo e suavizado, mesmo que tenha partes em que é mais destacado uma profundidade mais rasa que não deveria constar. No geral a imagem de mosaico preserva boa parte do mapa e traz uma profundidade próxima a imagem modelo, atingindo em alguns pontos mais assertividade na predição.

Figura 22. Imagem de mosaico de uma máscara específica para o sexto cenário e mapa batimétrico gerado a partir desta imagem.



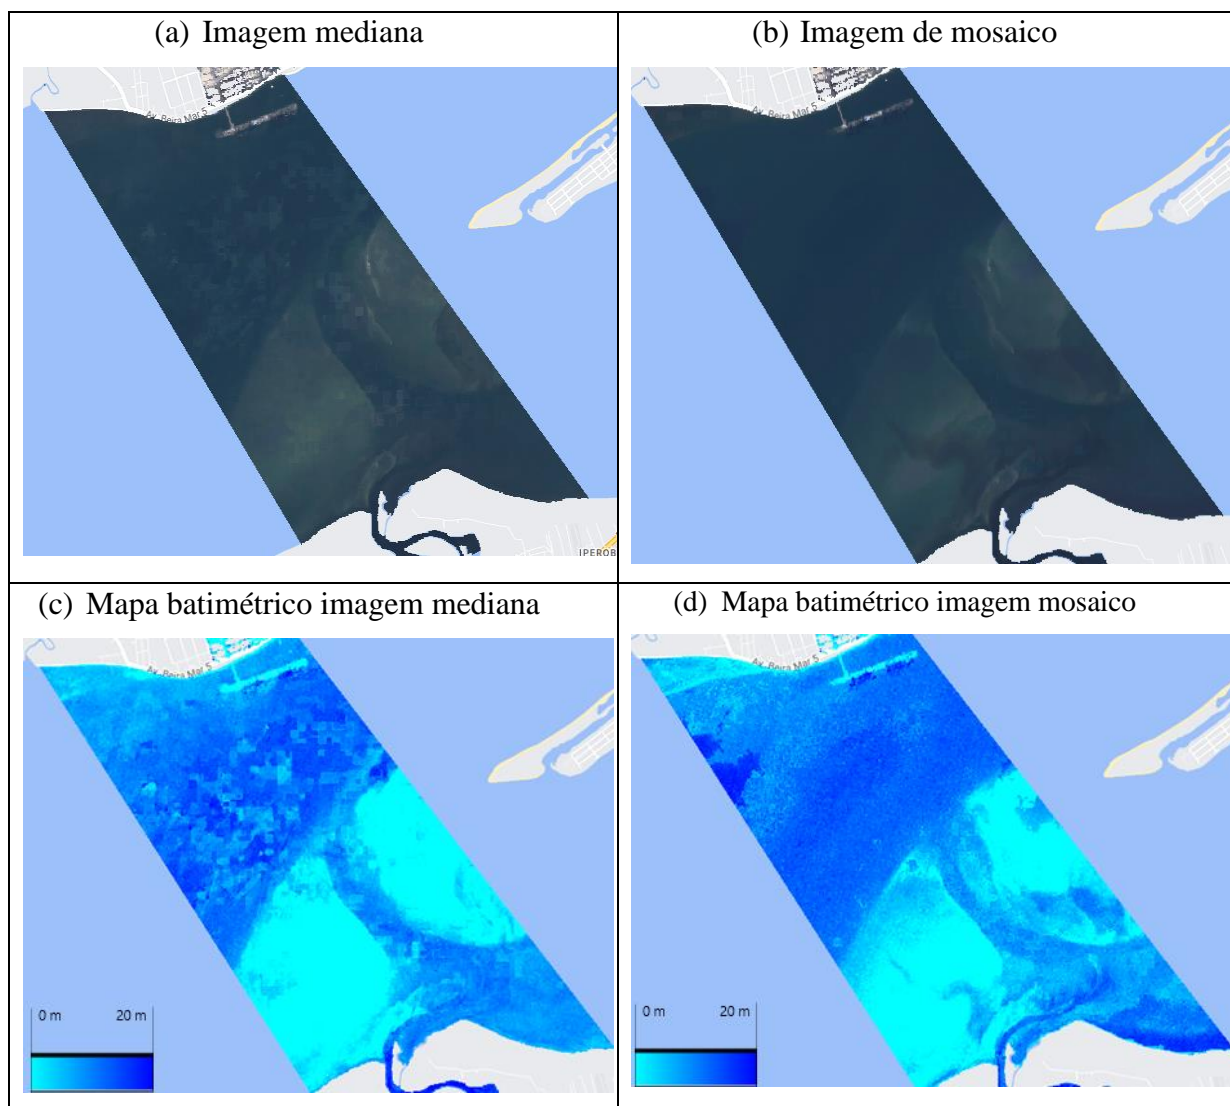
Fonte: Code Editor (GEE) – o Autor.

Por fim foi gerada uma máscara específica para este período e local e analisado os impactos na estimativa de batimetria comparado ao mosaico da máscara do primeiro cenário, tida como máscara geral. A Figura 22 mostra os resultados desta máscara específica e em primeira vista já é possível verificar que o AG não conseguiu convergir para um resultado satisfatório visualmente, a imagem traz vários pixels com ruídos e muito fortes como se estourasse o limite de renderização. O mapa batimétrico gerado também traz uma única predição, praticamente, para todo o local mostrando que a imagem não preservou as características de cada ponto da imagem. Ainda assim os resultados da máscara específica atingiram um RMSE de 3,62 metros, igualando ao RMSE atingido pela melhor imagem do período, o que mostra que mesmo em resultados não tão satisfatório, a máscara consegue atingir um nível próximo a imagem modelo.

3.4.8 Comparação com a imagem mediana e análise de histogramas.

Hoje em dia no CASSIE está sendo implantada como alternativa a escolha manual de imagens para batimetria a imagem mediana, que consiste em criar uma imagem com a mediana dos valores de cada banda de uma coleção de imagens, gerando a partir disso o mapa batimétrico do local. A imagem tende a ter uma qualidade boa, entretanto depende muito das imagens que contém coleção, em casos de muitas imagens com nuvens, a mediana tende a perder a qualidade da imagem final. Como comparativo foram geradas duas imagens medianas de dois locais diferentes em dois períodos diferentes e comparado com as imagens mosaico geradas nas mesmas condições. As Figuras 23-a e 23-b mostra as duas imagens geradas para região próxima ao porto no período de 01/01/2018 até 30/05/2018, onde a imagem a esquerda se refere a imagem mediana e a imagem a direita se refere a imagem de mosaico. Nesta imagem é possível identificar que a imagem mediana traz uma imagem equilibrada visualmente com algumas partes com pequenos ruídos mais claros, já a imagem de mosaico traz uma imagem mais bonita visualmente e totalmente equilibrada, entretanto a imagem de mosaico traz uma imagem mais escura que a mediana que preserva as cores mais claras.

Figura 23. Comparativo da imagem do segundo período e imagem de mosaicos.



Fonte: Code Editor (GEE) – o Autor.

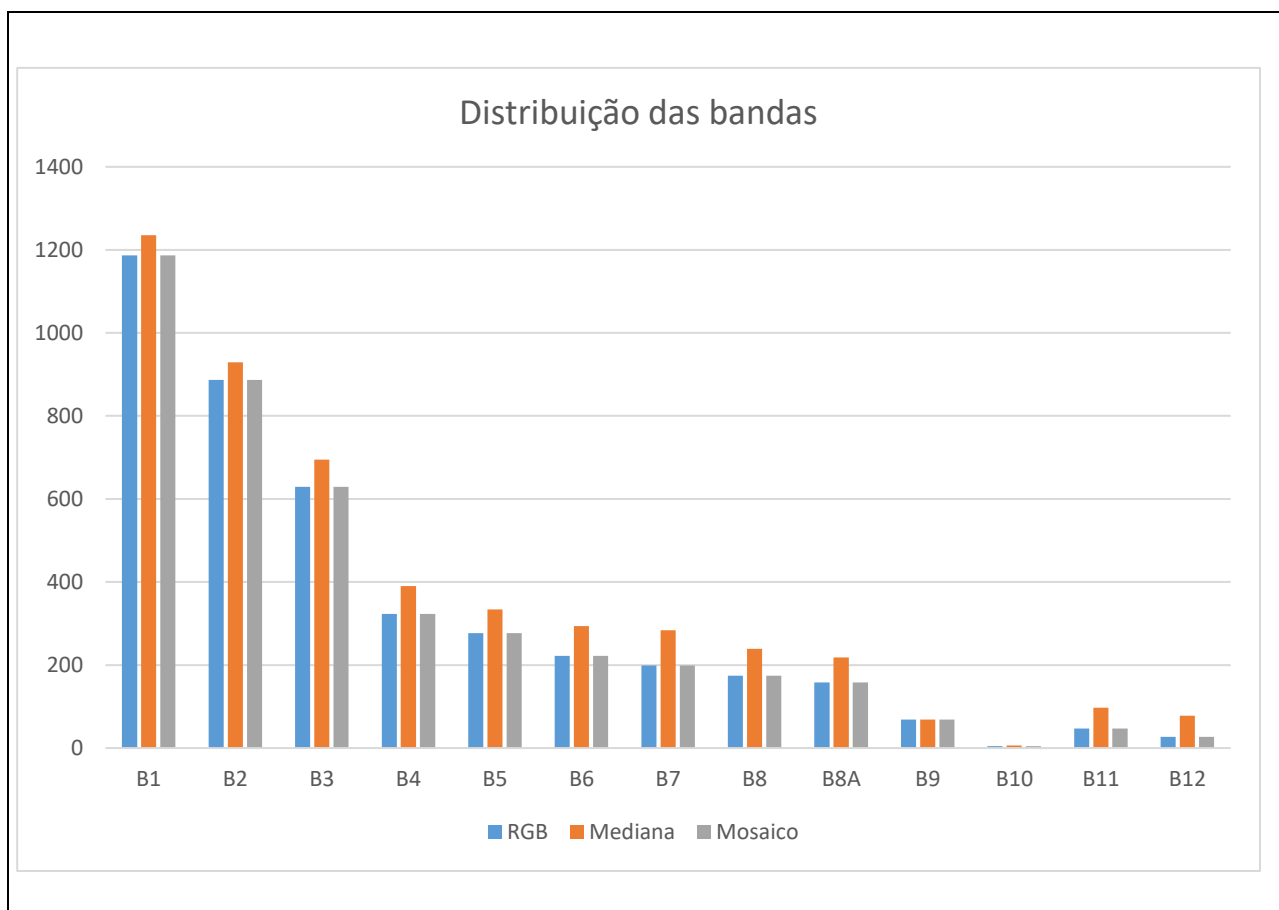
A geração do mapa batimétrico trouxe pontos mais visíveis na imagem mediana, as Figuras 23-c e 23-d mostram os mapas batimétricos gerados da mediana e da imagem de mosaico. A imagem mediana atinge um erro RMSE 4,11 metros, enquanto a imagem de mosaico tem o RMSE 3,9 metros, mostrando que a imagem de mosaico tem um desempenho melhor tanto visualmente, quanto estatisticamente do que a imagem mediana. Ao visualizar o mapa batimétrico, é possível verificar que a imagem mediana perde muito na continuidade, tendo muitos ruídos na estimativa, flutuando entre raso e profundo sem suavidade. Já a imagem de mosaico, como já explanado anteriormente, mantém um padrão mais suavizado e coerente com a imagem RGB, mesmo que tenham ponto em que a profundidade fuja do padrão da imagem.

Para refinar a análise, tanto da imagem mediana, quanto da imagem de mosaico foi gerado de um local aleatório do mapa para verificar a variação dos valores de cada banda nas

imagens geradas, comparando com uma imagem de boa qualidade da coleção. O ponto escolhido aleatoriamente no mapa foi da coordenada (-48.60238, -26.19092), uma região mais profunda próxima ao porto e na parte central da imagem utilizada nos exemplos desta seção. Os valores utilizados para gerar o gráfico foram gerados pela opção de inspeção disponível no GEE, onde é possível analisar os valores de cada banda de um ponto específico escolhido no mapa.

A Figura 24 mostra o gráfico gerado para comparar as imagens no ponto aleatório, onde é possível visualizar o quanto a imagem de mosaico preserva o equilíbrio das bandas, ficando bem próximo da imagem modelo, enquanto isso a imagem mediana tem valores superiores a imagem modelo e a imagem de mosaico, mostrando que esta alternativa pode elevar os valores das estimativas em alguns casos, mesmo que a proporção seja parecida com a imagem modelo.

Figura 24. Gráfico de distribuição das bandas da imagem modelo, da mediana e do mosaico.

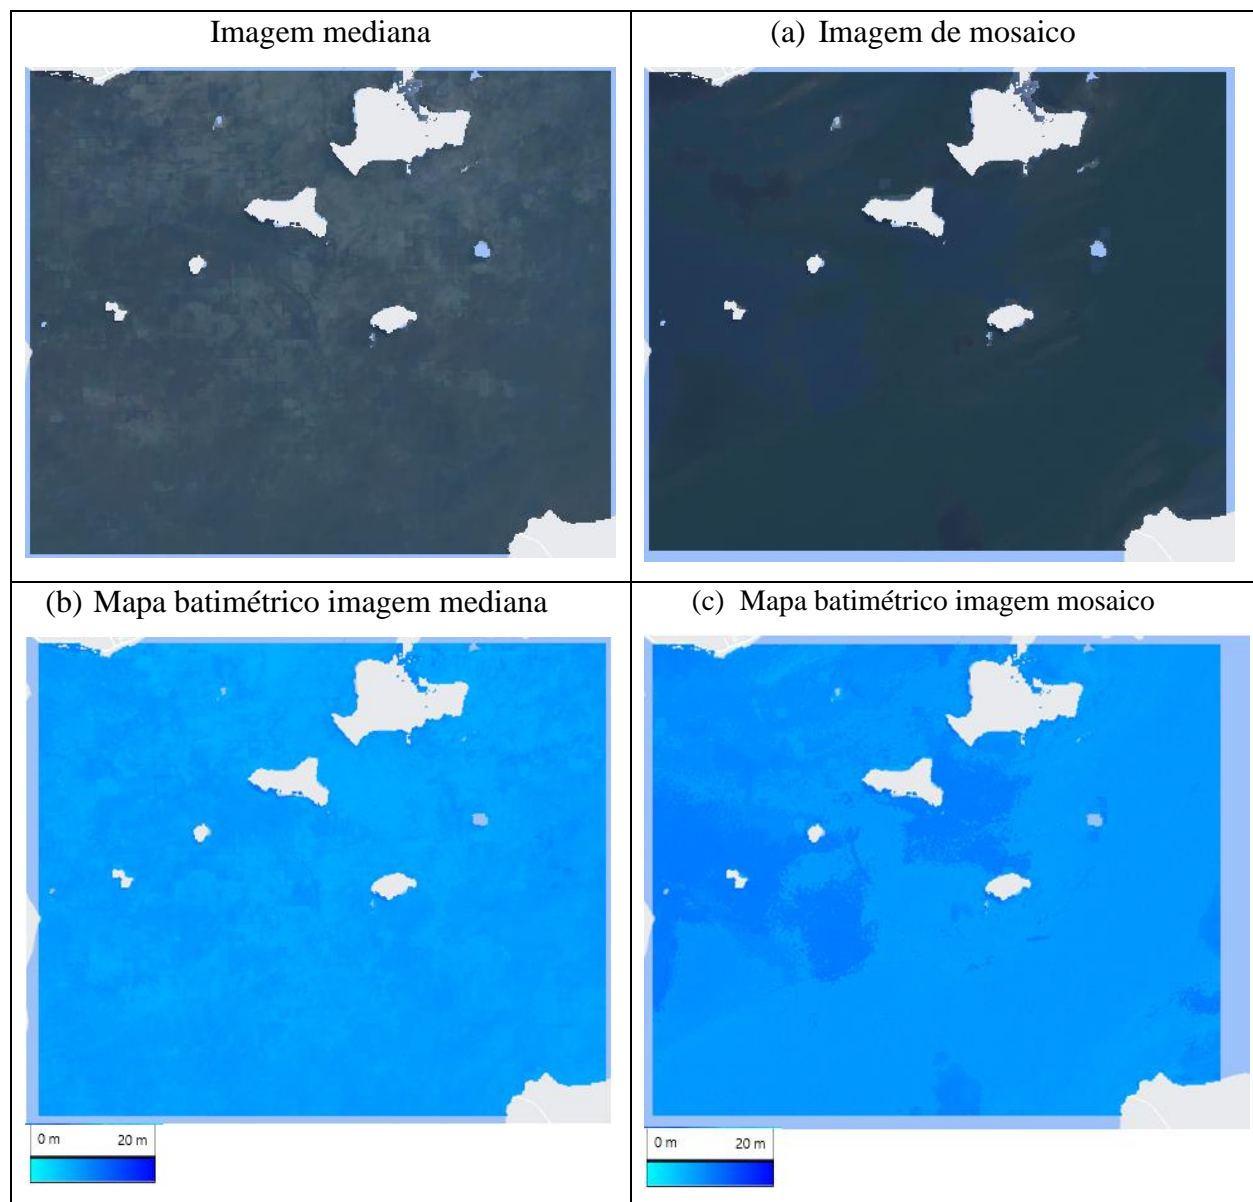


Fonte: o Autor

O segundo teste efetuado, compreendia o segundo local no período de 01/06/2018 até 30/12/2018 com a imagem mediana e a imagem de mosaico, verificando seus erros respectivos e sua qualidade visual tanto da imagem, quanto do mapa batimétrico gerado. As

Figuras 25-a e 25-b mostram as imagens geradas para o local onde é possível identificar os principais problemas visuais de ambas as imagens, sendo na imagem mediana os ruídos provavelmente causados por pixels de nuvem ou pixels de maré baixa que distorcem um pouco a imagem e para imagem de mosaico como já explanado anteriormente, há uma adição de áreas mais profundas indevidamente com destaques mais azuis em alguns locais do mapa.

Figura 25. Comparativo da imagem gerada pela mediana e a imagem de mosaico.




Fonte: Code Editor (GEE) – o Autor.

Em questão estatística foi identificado que a imagem mediana obteve um RMSE de 3,59 metros neste local e período, tendo um bom resultado mesmo com problemas na visibilidade do mapa, chegando próximo ao RMSE atingido pela imagem de mosaico que foi de 3,56 metros. O erro próximo pode se dar por conta de o local ter uma profundidade média em todo o mapa, facilitando a estimativa caso a mediana se mantenha igual em todo mapa,

diferente do outro local que tem pontos diferentes de profundidade e dificulta mais a predição caso a imagem não esteja adequada. As figuras 25-c e 25-d mostram os mapas batimétricos do local gerados pelas duas imagens e confirmam a afirmação feita anteriormente que o local tem uma profundidade parecida em todos os pontos e assim ambas as imagens conseguem chegar em predições parecidas a ver pelo mapa quase todo repleto de um azul claro. É possível verificar também os pontos já apontados dos erros das imagens, tanto os ruídos quanto as partes profundas atribuídas incorretamente.

Semelhante ao que foi feito no primeiro teste, foi escolhido aleatoriamente um ponto na imagem para analisar a distribuição das bandas e verificar se as imagens mantêm os valores próximos ao real. Neste ponto foi adquirido o valor de cada uma das bandas de todas as imagens geradas e da melhor imagem do período e gerado um gráfico de dispersão para analisar a distribuição das bandas. A figura 26 mostra o gráfico construído, onde é possível ver que a imagem mediana, como no outro teste, obteve um valor mais alto que a imagem modelo e a imagem de mosaico, enquanto a imagem de mosaico teve os seus valores abaixo a imagem modelo, diferente do que ocorreu no outro teste onde as bandas ficaram quase iguais, mostrando um pouco mais de dificuldade da máscara em locais como este em manter a estrutura das bandas da melhor imagem.

Figura 26. Gráfico de distribuição das bandas da imagem modelo, da mediana e do mosaico.




Fonte: o Autor

b

3.4.9 Comparativo de erros

Para comparar melhor a distribuição das diferenças que geraram os erros de estimativa foi realizada a plotagem no mapa as linhas que foram feitas as medições em campo disponibilizadas, posteriormente foi feito um trabalho de abstração dos dados para diminuir a quantidade de dados e criar um gráfico de dispersão em bolha para mostrar a distribuição das diferenças entre o predito e o real em relação as coordenadas. Com isso vai ser possível estimar em quais localizações tem mais diferença entre o real e o predito para estimular elencar onde há mais probabilidade de erro na estimativa.

Figura 27. Imagem dos pontos medidos em campo que originaram os dados batimétricos.

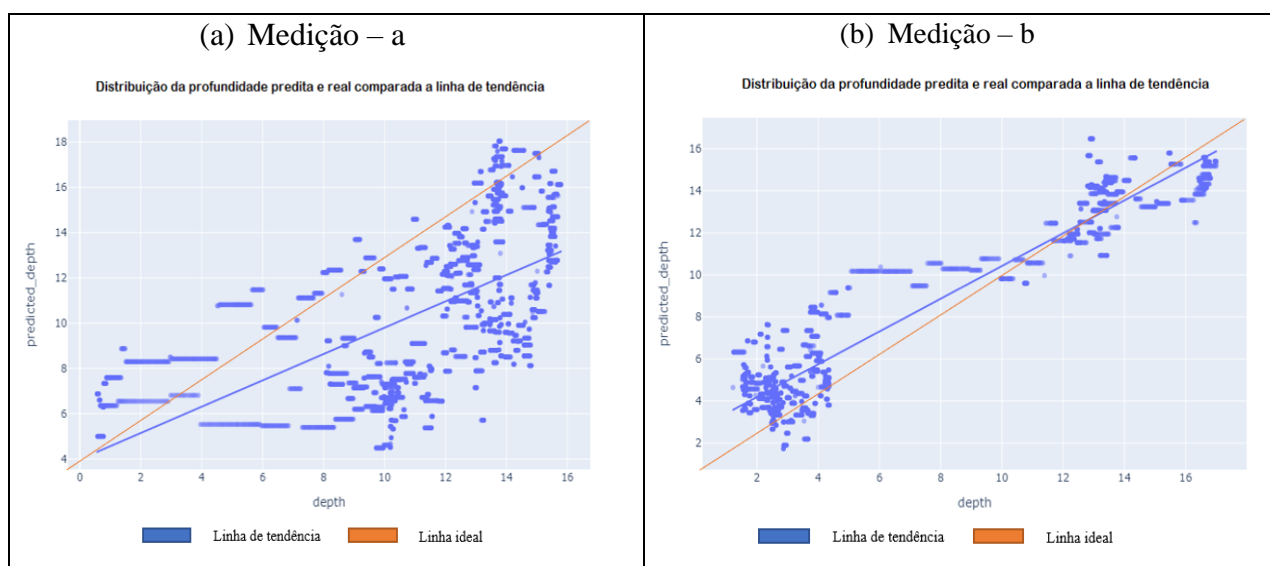


Fonte: o Autor

A Figura 27 mostra onde foram feitas as medições em campo no local selecionado, mostrando as linhas onde foram obtidas as profundidades dos dados disponibilizados. Os dados dessas linhas são usados para treinar o modelo de estimação da batimetria e consequentemente servem para validar o quanto as imagens geradas, tanto mosaico quanto mediana, para estimativa chegam próximo ao real avaliando o erro de estimativa para todo local da imagem.

Para comparar o comportamento de predição dos tipos de imagens que podem ser usadas no processo, foram gerados gráficos de dispersão das predições em função aos dados de treino, comparando com a linha de tendência e a linha ideal para essas predições. Para fins de comparação, foi feito um gráfico para cada ponto de coleta de dados mostrado na Figura 27, para três tipos de imagem: uma imagem escolhida manualmente, uma imagem composta de um período de seis meses e uma imagem mediana de um período de seis meses. A Figura 28 mostra os gráficos de dispersão para as duas medições para a imagem escolhida manualmente, a imagem escolhida foi do dia 21/05/2018 e teve uma distribuição próxima a linha de tendência de a linha ideal, divergindo mais na medição – a e tendo um melhor resultado na medição – b. Como a medição – a tem profundidades maiores e teve mais dispersão dos dados que a medição – b, é possível identificar que para uma imagem escolhida manualmente, locais com profundidade maiores tendem a ter erros maiores de predição, como também é possível identificar que a precisão atingida na medição – b que manteve o erro de estimativa pequeno, visto que a dispersão comparada a linha de tendência é bem pequena.

Figura 28. Gráfico de distribuição das diferenças entre a profundidade predita e a profundidade medida em campo.

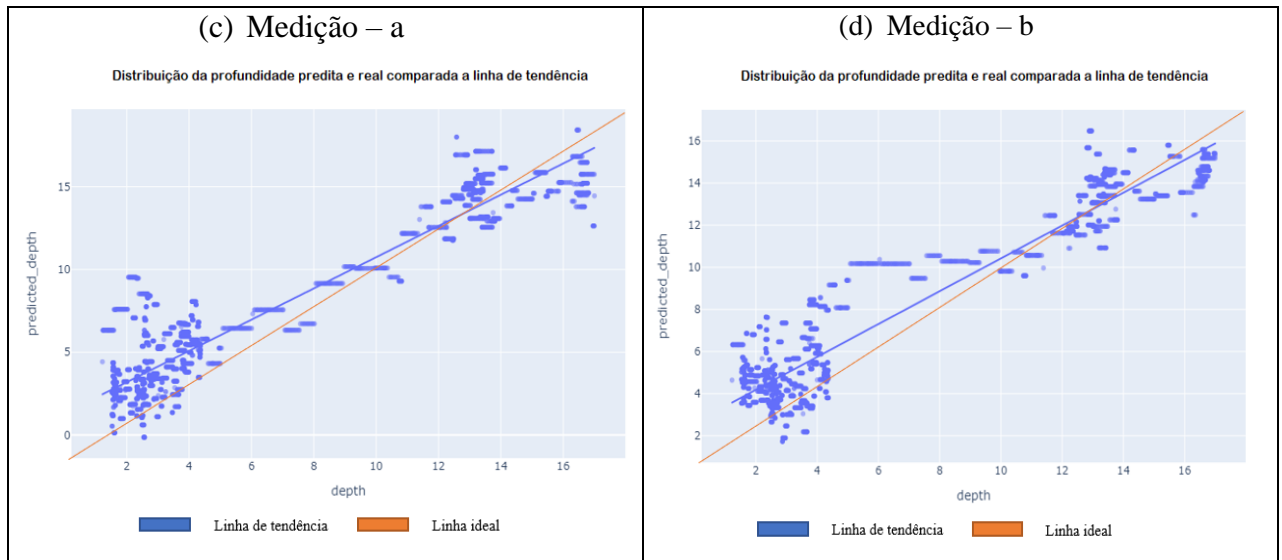


Fonte: o Autor

Para imagem de mosaico, do período de 01/06/2018 a 30/12/2018, foi gerado os mesmos dois gráficos mostrando a distribuição das predições comparado aos dados de treino. A Figura 29 mostra os gráficos para medição – a e para medição – b, com isso é possível identificar que a imagem de mosaico atingiu predições mais bem distribuídas em torno da linha de tendência, não tendo valores muito distantes, tanto para a medição – a, quanto para medição – b. Diferente da imagem escolhida manualmente, a imagem de mosaico teve uma melhor correlação na medição – a, onde as predições ficaram próximas tanto da linha de

tendencia quanto da linha ideal, enquanto na medição – b, por mais que acompanhasse a linha de tendencia, ficou um tanto distante da linha ideal.

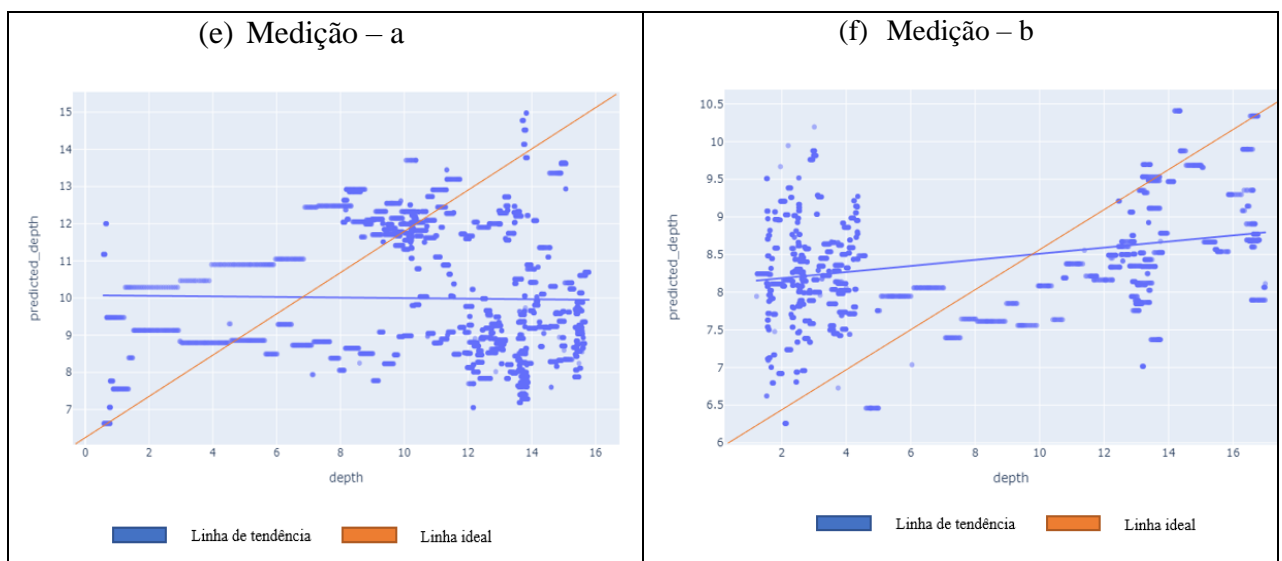
Figura 29. Gráfico de distribuição das diferenças entre a profundidade predita e a profundidade medida em campo.



Fonte: o Autor

Semelhantemente aos casos anteriores, foram gerados os gráficos de dispersão da imagem mediana, do período de 01/06/2018 a 30/12/2018, comparando as previsões aos dados de treino e gerado as linhas de tendencia e ideal. A Figura 30 mostra os gráficos para cada medição, onde é possível identificar que a imagem mediana tem o pior desempenho na estimativa, tendo os dados muito dispersos da linha de tendencia e da linha ideal, justificando os grandes erros de estimativa apresentados anteriormente.


Figura 30. Gráfico de distribuição das diferenças entre a profundidade predita e a profundidade medida em campo.



Fonte: o Autor

Para mostrar o quanto a diferença das predições não seguem uma distribuição normal, foi feito o gráfico entre a diferença de predição (medida pelo valor absoluto da diferença entre a profundidade medida e a predita) e a profundidade medida para verificar se há algum padrão de aumento da diferença de predição em função da profundidade do local, conforme mostra a Figura 28. Ao analisar o gráfico da Figura 28, é possível verificar que a diferença entre a profundidade medida e predita não segue padrão, visto que há uma flutuação da diferença na mesma faixa de profundidade, atingindo as maiores diferenças na profundidade de 14 e 15 metros e atingindo a menor diferença nas faixas de profundidade de 1, 2, 4, 7, 8, 9, 10, 11, 12, 13, 14, 15 metros. Vale ressaltar que em profundidades de 7 a 15 metros o algoritmo consegue estimar valores mais precisos, com diferença mínima próxima a 0 metros e diferença máxima em torno de 6 metros. É possível verificar também que profundidades acima de 15 metros tendem a aumentar a diferença entre a predição predita e a predição real, indicando uma limitação no método para profundidades maiores.

Figura 31. Gráfico da variação da diferença entre a profundidade medida e a real em função da profundidade real



Fonte: o Autor

4 CONCLUSÃO

O presente estudo teve por objetivo melhorar a escolha de imagens de satélite para a utilização no cálculo de batimetria, tema escolhido juntamente ao projeto CASSIE que está implantando um módulo de batimetria à ferramenta web. Os resultados da pesquisa proporcionaram uma melhora na escolha automatizada de imagens, entretanto, a solução não melhora o processo atual em termos de precisão na estimativa, tendo apenas a melhora de escolha automatizada e no filtro de nuvens. Isso é visto na comparação do erro, onde em apenas três dos seis cenários testados o mosaico teve um RMSE menor que a imagem modelo da coleção e superou a imagem mediana nos mesmos termos, mas sem grandes melhorias, visto que as diferenças entre os erros não passaram de 1 metro aproximadamente.

Um dos pontos positivos encontrados na pesquisa será a facilidade na geração de uma imagem próxima a real num período de até seis meses, podendo substituir a tecnologia da imagem mediana que é a tecnologia atual sendo desenvolvida para a ferramenta. Isso é possível, pois a imagem gerada a partir das máscaras calculadas preservam a distribuição das bandas das melhores imagens do período, mantendo os valores bem próximos a de uma imagem escolhida manualmente e com qualidade boa (sem nuvens, barcos e de boa iluminação), mesmo que tenha alguns ruídos na substituição de pixels. Com os resultados apresentados nesta pesquisa foi possível confirmar que a imagem gerada pelas máscaras proporciona um resultado batimétrico melhor que a imagem mediana, mas não melhora comparado a uma imagem modelo.

Um dos pontos negativos encontrados foi a limitação da plataforma do GEE e suas API's, visto que há pouca documentação de algumas ferramentas, lentidão, objetos restritos que só podem ser lidos pelo GEE e limitação de funções e comandos dos paradigmas de programação conhecidos. Esses pontos acabam por afetar o desempenho de vários algoritmos que dependem da API do GEE para executar, no caso desta pesquisa o AG não teve o desempenho esperado por conta da lentidão do processamento de dados da API do GEE e por conta disso se tornou inviável a geração de máscaras em larga escala. Mesmo com esses contrapontos, foi encontrado uma API via REST do GEE que pode resolver parte desses problemas e pode ser mais bem estudada em trabalhos futuros, onde é possível obter os valores das bandas em um array, podendo assim fazer todo o processo de cálculo de batimetria e erro de estimativa via Python, podendo diminuir o tempo de execução e tornar essa aplicação mais performática.

Outro ponto negativo encontrado que pode ter impedido melhores resultados foi o algoritmo de batimetria disponível, visto que mesmo no melhor cenário o RMSE encontrado é de 2,9 metros, o que é um erro grande para batimetria, não atendendo as especificações técnicas da Diretoria de Hidrografia e Navegação para levantamentos batimétricos de Ordem 1 (erro máximo permitido até 0,50 m) (GAGG, 2016). Um dos pontos que limita a estimativa de batimetria é o método de regressão utilizado, visto que o método de regressão linear não consegue estimar com muita precisão, sendo necessário uma regressão polinomial para descrever melhor os dados, conforme explicado por Fillipi (2018). Outro ponto que limita o algoritmo de batimetria é a correlação da profundidade com as bandas ou o NDWI utilizado, conforme Fillipi (2018) a correlação máxima encontrada foi de aproximadamente 60% para o NDWI das bandas B5 (infravermelho de borda) e B3 (Verde) para o mesmo local e período utilizado nesta pesquisa. Esses pontos podem ser verificados futuramente para tentar melhorar a precisão da geração das imagens e consequentemente diminuir o erro de estimativa.

Em questão de desenvolvimento, foi encontrado dificuldades na execução do AG dentro da plataforma do GEE (*Code Editor*), visto que alguns comandos não eram reconhecidos pela plataforma e as variáveis numéricas eram constantemente transformadas no objeto numérico do GEE, o que impediam operações de comparação como igualdade, menor ou maior, etc. Com isso foi necessário migrar para outra plataforma, inicialmente visando o Java Script, então foi decidido já anexar essa execução ao CASSIE e construir uma chamada dentro da ferramenta, o que não obteve sucesso por conta da forma de autenticação ter sido mudada pela Google, não permitindo novas conexões na antiga forma de autenticação que é usada no CASSIE. Por fim, foi migrado para o Python, onde foi possível executar todo o algoritmo e então testar os resultados das máscaras nas gerações de imagens e estimativa de batimetria. Para execução do algoritmo no Python foram utilizados o Google Colaboratory e o Pycharm, inicialmente utilizando o Colaboratory para execução, mas por conta do limite de tempo de execução foi necessário executar no Pycharm localmente para finalizar toda a execução do algoritmo.

Referente a utilização do algoritmo genético para a aplicação é possível afirmar que apesar de ser fácil de implementar, não atingiu a melhora da imagem e do erro suficientemente, além de sofrer com lentidão causada por fatores externos, as variações possíveis dependem muito dos tamanhos dos genes e em casos de genes menores que 4 a variação da população e dos coeficientes tende a ser menor e o resultado convergir mais rapidamente, como também o tamanho da população e a quantidade de gerações impactam na convergência do melhor resultado. Desta forma, para questões onde precisam de mais

variabilidade dos coeficientes, vale a utilização de outra tecnologia de inteligência artificial. Vale ressaltar que o AG não obteve o melhor resultado por conta de fatores externos, como a lentidão de retorno da API do GEE e por isso os parâmetros de sucesso da utilização desta tecnologia podem ser alterados caso esse problema seja resolvido futuramente, indicando o uso do AG em tarefas semelhantes.

Em relação aos objetivos, portanto, pode-se afirmar que foram atingidos, visto que a aplicação tem a capacidade de gerar máscaras para geração de mosaicos para aplicar no algoritmo de batimetria e remove a maioria das imperfeições encontradas numa coleção de imagens, como nuvens e embarcações, gerando uma imagem que atinge um erro RMSE que flutua próximo ao RMSE gerado por uma imagem escolhida manualmente, com diferença de ± 1 metro. Entretanto, como o projeto precisa de uma solução melhor que uma imagem escolhida manualmente, esta solução não se torna ideal, mesmo que em comparação a imagem mediana, esta seja a melhor opção.

4.1 TRABALHOS FUTUROS

Como continuação desta pesquisa, pode ser feita a exploração de novas entradas para o AG como outros tipos de NDWI, utilizando outras bandas como as bandas de infravermelho próximo, além de outras configurações existentes para o AG que não puderam ser exploradas por conta da lentidão. Testar a utilização de outras tecnologias para encontrar os pesos das bandas como redes neurais e florestas aleatórias, que tiveram bons resultados no ramo de batimetria. Outro trabalho futuro é a exploração API via REST para melhorar o tempo de execução do AG, visto que esse algoritmo permite manipular melhor os valores das bandas via Python, bem como explorar a utilização do Google Cloud para executar as funções mais pesadas do AG. Outra exploração em trabalho futuro é a de novas funções para selecionar o pixel das imagens, visto que esse trabalho limitou-se a soma das bandas e do NDWI, podendo testar funções mais próximas a base teórica de autores de batimetria ou encontrar uma função que se adapte a todos os algoritmos de batimetria que possam ser utilizados na estimativa de batimetria.

5 REFERÊNCIAS

ALMEIDA, Luis Pedro; OLIVEIRA, Israel Efraim de; LYRA, Rodrigo; DAZZI, Rudimar Luís Scaranto; MARTINS, Vinícius Gabriel; KLEIN, Antonio Henrique da Fontoura. Coastal Analyst System from Space Imagery Engine (CASSIE): Shoreline management module. **ELSEVIER - Estuarine, Coastal and Shelf Science**, v.140. 2021.

AWAD, Mohamad; CHEHDI, Kacem; NASRI, Ahmad. ENHANCEMENT OF THE SEGMENTATION PROCESS OF MULTICOMPONENT IMAGES USING FUSION WITH GENETIC ALGORITHM. **5th International Multi-Conference on Systems, Signals and Devices**. 2008.

BASITH, Abdul; PRASTYANI, Ratna. Evaluating ACOMP, FLAASH and QUAC on Worldview-3 for satellite derived bathymetry (SDB) in shallow water. **Geodesy and Cartography**, v. 46, n. 3, p. 151, 2020. Disponível em: <<https://doi.org/10.3846/gac.2020.11426>>

BENTO, E. P.; KAGAN, N. Algoritmos genéticos e variantes na solução de problemas de configuração de redes de distribuição. **Revista Controle & Automação**, v. 19, n. 3, jul. de 2008.

BILHALVA, Wagner Danton de Bittencourt. **Batimetria de pequenos reservatórios através de metodologia convencional e alternativa**. Dissertação de Mestrado em Geomática. Universidade Federal de Santa Maria – UFSM. Santa Maria, RS, 2013.

BRASIL. MINISTÉRIO DA SAÚDE. SECRETARIA DE VIGILÂNCIA EM SAÚDE. Vigilância e controle da qualidade da água para consumo humano. Brasília: Ministério da Saúde, 2006.

CABALLERO, Isabel; STUMPF, Richard P. Retrieval of nearshore bathymetry from Sentinel-2A and 2B satellites in South Florida coastal Waters. **ELSEVIER - Estuarine, Coastal and Shelf Science**. 226 106277. 2019

COLLINS, Tyler K. **A Centrality Based Multi-Objective Disease-Gene Association Approach Using Genetic Algorithms**. Dissertação de mestrado em Ciência do curso de Matemática e Ciências. Universidade de Brock - St. Catharines, Ontario, Canadá. 2019.

COSTA, Lucas; NUNES, Leon; AMPATZIDIS, Yiannis. A new visible band index (vNDVI) for estimating NDVI values on RGB images utilizing genetic algorithms. **ELSEVIER - Estuarine, Coastal and Shelf Science**, v.172. 2020.

DANILO, Céline; MELGANI, Farid. Wave Period and Coastal Bathymetry Using Wave Propagation on Optical Images. **IEEE - Transactions on Geoscience and Remote Sensing**. Trento, Italia. Julho de 2016.

DICKENS, Kevin; ARMSTRONG, Albert. Application of Machine Learning in Satellite Derived Bathymetry and Coastline Detection. **SMU Data Science Review**: Vol. 2: No. 1, Article 4. 2019.

FILHO, Marco Antonio Itaborahy. **Análise de algoritmos genéticos e evolução diferencial para otimização de funções não-lineares** multimodais. TCC (Graduação) – Curso de Engenharia Elétrica. Universidade Tecnológica Federal do Paraná – UTFPR. Ponta Grossa, PR, 2018.

FILIPPI, Bianca. **OBTENÇÃO DE BATIMETRIA EM ESTUÁRIOS ATRAVÉS DE IMAGENS DE SATÉLITE: ESTUDO DE CASO NA BAÍA DA BABITONGA, SC.** 2020. TCC (Graduação) – Curso de Oceanografia, Universidade Federal de Santa. Florianópolis, 2020.

FLOOD, Neil. Seasonal Composite Landsat TM/ETM+ Images Using the Medoid (a Multi-Dimensional Median). **Remote Sensing**, v. 5, n. 12, p. 6481–6500, 2013. Disponível em: <<http://dx.doi.org/10.3390/rs5126481>>.

FRANÇA, Paulo Henrique Praça de. **Avaliação Comparativa de Métodos e Técnicas Batimétricas na Obtenção das Curvas Cota X Área X Volume de Reservatórios em Usinas Hidrelétricas.** Pós-Graduação em Geociências Aplicadas e Geodinâmica. Universidade de Brasília – UnB. Brasília, 2019.

FREIRE, Ricardo Ramos. **Evaluating satellite derived bathymetry in regard to total propagated uncertainty, multi-temporal change detection, and multiple non-linear estimation.** Dissertação para Doutorado em Filosofia dentro da Engenharia Oceânica. Universidade de New Hampshire, Estados Unidos, julho de 2017.

GAGG, Gilberto. **APOSTILA DE LEVANTAMENTOS HIDROGRÁFICOS-NOÇÕES GERAIS.** UFRGS-Universidade Federal do Rio Grande do Sul, IGEO-Instituto de Geociências, Departamento de Geodesia. Rio Grande do Sul, 2016.

GAO, Jay. Bathymetric mapping by means of remote sensing: methods, accuracy and limitations, **Progress in Physical Geography: Earth and Environment**, v. 33, n. 1, mai. de 2009. Disponível em: <<http://dx.doi.org/10.1177/0309133309105657>>. Acesso em: 15 de out. de 2021.

GOODRICH, Kyle; SMITH, Ross. AI Expands Reach of SDB - Machine Learning, ICESat-2 Enhance Satellite-Derived Bathymetry. **Sea Technology**. Vol. 62, n. 6. jun. 2021.

JESUS, Helga G. C. F. Mendes.; LUGON JUNIOR, J.; FERREIRA, Cristine Nunes. Revisão das Tecnologias Utilizadas para Levantamento Batimétrico em Corpos Hídricos. **Boletim do Observatório Ambiental Alberto Ribeiro Lamego, Campos dos Goytacazes**, v. 9, n. 2, p. 145–163, 30 dez. 2015.

KENNEDY, Emma V.; Roelfsema, Chris M.; Lyons, M Mitchell B. et al. Reef Cover, a coral reef classification for global habitat mapping from remote sensing. **Sci Data**, v.8, n. 196 (2021). <https://doi.org/10.1038/s41597-021-00958-z>

KULKARNI, Jyoti S. Image Fusion by a Hybrid Multiobjective Genetic Algorithm Technique. **International Journal of Recent Technology and Engineering (IJRTE)**, v. 11, n. 1, mai. 2022.

LI, Jiwei; KNAPP, David E; LYONS, Mitchell; ROELFSEMA, Chris; PHINN, Stuart; SCHILL, Steven R; ASNER, Gregory P. Automated Global Shallow Water Bathymetry Mapping Using Google Earth Engine. **Remote Sensing**, Basel, v. 13, n. 8, 2 abr. 2021.

LILLESAND, T.; KIEFER, R.W. Remote Sensing and Image Interpretation. 3.ed. New York: John Wiley & Sons, 1994.

LOPES, H. S. Fundamentos da Computação Evolucionária e Aplicações. Bandeirantes, Paraná, 2006. 52-106 p.

LOZADA, G.; NUNES, K. S. Metodologia científica. Porto Alegre: Sagah, 2019.

LUMBAN-GAOL Yustisi A.; DEWI, Ratna Sari; OKTAVIANI, Nadya; ADITYA Sandi. Reef Cover, a coral reef classification for global habitat mapping from remote sensing. **Sci Data**, v.8, n. 196 (2021). <https://doi.org/10.1038/s41597-021-00958-z>

LYZENG, David R. Passive remote sensing techniques for mapping water depth and bottom features. **Applied Optics**, v. 17, n. 3, p. 379, 1 fev. 1978.

LYZENG, David R. Shallow-Water Bathymetry Using Combined Lidar and Passive Multispectral Scanner Data. **International Journal of Remote Sensing**, 6, 115-125. 1985. <http://dx.doi.org/10.1080/014311685089>

MISRA, Ankita; Ramakrishnan, Balaji. Assessment of coastal geomorphological changes using multi-temporal Satellite-Derived Bathymetry. **ELSEVIER - Estuarine, Coastal and Shelf Science**, v. 2070. 104213. 2020.

MISRA, Ankita; VOJINOVIC, Zoran, Ramakrishnan, Balaji; LUIJENDIJK, Arjen; RANASINGHE, Roshanka. Shallow water bathymetry mapping using Support Vector Machine (SVM) technique and multispectral imagery. *Int. J. Remote Sensing*, v. 39, n.13, 4431–4450. 2018. DOI: 10.1080/01431161.2017.1421796

MOBLEY, C.D. Light and Water: Radiative Transfer in Natural Waters. Academic Press: San Diego, CA, USA, 1994.

MORAIS, Rafael Lima de. **Uso de Árvores Aleatórias para Classificação Sensorial de Arroz Cozido**. TCC (Graduação) – Curso de Estatística. Universidade de Brasília - UnB. Brasília, 2017.

MORGAN, Grayson R.; WANG, Cuizhen; LI, Zhenlong; et al. Deep Learning of High-Resolution Aerial Imagery for Coastal Marsh Change Detection: A Comparative Study. **ISPRS International Journal of Geo-Information**, v. 11, n. 2, p. 100, 2022. Disponível em: <<http://dx.doi.org/10.3390/ijgi11020100>>.

NAJAR, Mahmoud Al; THOUMYRE, Grégoire; BERGSMA, Erwin W. J.; ALMAR, Rafael; BENSHILA, Rachid; WILSON, Dennis G. Satellite derived bathymetry using deep learning. **Springer Science**. França. Jul. 2021.

NIROUMAND-JADIDI, Milad; BOVOLO, Francesca; BRUZZONE, Lorenzo. Water Quality Retrieval from PRISMA Hyperspectral Images: First Experience in a Turbid Lake and Comparison with Sentinel-2. **Remote Sensing**, v. 12, n. 23, 6 dez. 2020.

PE'ERI, S.; PARRISS, C.; AZUIKE, C.; ALEXANDER, L.; ARMSTRONG, A.; Satellite remote sensing as a reconnaissance tool for assessing nautical chart adequacy and completeness. *Mar. Geod.* 37 (3), 293–314. 2014.

PEREIRA, Jógerson Pinto Gomes; BARACUHY, José Geraldo de Vasconcelos. *Ecobatimetria - Teoria e Prática*. Campina Grande: Gráfica Agenda, 2008.

POLITO, Paulo S.; SATO, Olga T.; AUGUSTO, Fábio L. *Oceanografia por Satélites*. USP – Universidade de São Paulo, Laboratório de Oceanografia por Satélites. São Paulo, 2012.

PONTE, Caio; CAMINHA, Carlos; FURTADO, Vasco. Otimização de Florestas Aleatórias através de ponderação de folhas em árvore de regressão. *In: ENCONTRO NACIONAL DE INTELIGÊNCIA ARTIFICIAL E COMPUTACIONAL (ENIAC)*, 17., 2020, Evento Online. **Anais [...]**. Porto Alegre: Sociedade Brasileira de Computação, 2020. p. 698-708. DOI: <https://doi.org/10.5753/eniac.2020.12171>.

ROBERTS, Dale; MUELLER, Norman; MCINTYRE, Alexis. High-Dimensional Pixel Composites From Earth Observation Time Series. **IEEE - Transactions on Geoscience and Remote Sensing**. v. 55, n. 11, nov. de 2017.

SAGAR, Stephen; PHILLIPS, Claire; BALA, Biswajit; et al. Generating Continental Scale Pixel-Based Surface Reflectance Composites in Coastal Regions with the Use of a Multi-Resolution Tidal Model. **Remote Sensing**, v. 10, n. 3, p. 480, 2018. Disponível em: <<http://dx.doi.org/10.3390/rs10030480>>.

SAGAWA, Tatsuyuki; YAMASHITA, Yuta; OKUMURA, Toshio; YAMANOKUCHI, Tsutomu; Satellite Derived Bathymetry Using Machine Learning and Multi-Temporal Satellite Image. **Remote Sensing**, Japão, v. 11, n. 10, 14 mai. 2019.

SALAMEH, Edward, FRAPPART, Frédéric, ALMAR, Rafael, et al.; Monitoring Beach Topography and Nearshore Bathymetry Using Spaceborne Remote Sensing: A Review. **Remote Sensing**, v. 11, n. 19, 21 set. 2019,

SANTACATTARINA, Ricardo. **Implementação de uma API em arquitetura serverless no ambiente da AWS para predição de batimetria em estuários através da aplicação de métodos de aprendizado de máquina em imagens multiespectrais de satélites**. TCC (Graduação) – Curso de Engenharia da Computação. Universidade Federal de Santa Catarina – UFSC. Araranguá, SC, 2021.

SHEPHERD, James D.; SCHINDLER, Jan; DYMOND, John R. Automated Mosaicking of Sentinel-2 Satellite Imagery. **Remote Sensing**, v. 12, n. 22, p. 3680, 2020. Disponível em: <<http://dx.doi.org/10.3390/rs12223680>>.

STUMPF, R. P.; HOLDERIED, K.; SINCLAIR, M. Determination of water depth with highresolution satellite imagery over variable bottom types. **Limnology And Oceanography**, v. 48, n. 12, p. 547-556, 2003

TAKAHASHI, Adriana. **Máquina de Vetores-Suporte Intervalar**. Tese de Doutorado em Engenharia de Computação. Universidade Federal do Rio Grande do Norte – UFRN. Natal, RN, 2012.

TANG, Kelvin Kang Wee; MAHMUD, Mohd Razali. Imagery-derived bathymetry in Strait of Johor's turbid waters using multispectral images. **The International Archives of the Photogrammetry, Remote Sensing and Spatial Information Sciences**, v. XLII-4/W9, 2018.

TOME, Moises Alberto Evelin Pereira. Levantamento batimétrico do rio Curuçá – PA. TCC (Graduação) - Engenharia de Cartografia e Agrimensura. Universidade Federal Rural da Amazônia. Belém, PA, 2019.

TRAGANOS, Dimosthenis. Development of seagrass monitoring techniques using remote sensing data. Doutorado em Ciências Naturais, Universidade de Osnabrueck. Osnabrueque, Alemanha, julho de 2020.

TRAGANOS, Dimosthenis; POURSANIDIS, Dimitris; AGGARWAL, Bharat; et al. Estimating Satellite-Derived Bathymetry (SDB) with the Google Earth Engine and Sentinel-2. **Remote Sensing**, v. 10, n. 6, p. 859, 2018. Disponível em: <<http://dx.doi.org/10.3390/rs10060859>>.

TRAGANOS, Dimosthenis; REINARTZ, Peter. Machine learning based retrieval of benthic reflectance and Posidonia oceanica seagrass extent using a semi-analytical inversion of Sentinel-2 satellite data. **International Journal of Remote Sensing**, 2018. DOI: 10.1080/01431161.2018.1519289

TURNER, Ian L.; HARLEY, Mitchell D.; ALMAR, Rafael; BERGSMA, Erwin W.J.; Satellite optical imagery in Coastal Engineering. **ELSEVIER - Estuarine, Coastal and Shelf Science**. 167 103919. 2021.

PACHECO, A.; HORTA, J.; LOUREIRO, C.; FERREIRA, Ó. Retrieval of nearshore bathymetry from Landsat 8 images: A tool for coastal monitoring in shallow waters. **ELSEVIER - Estuarine, Coastal and Shelf Science**, v.159. 2014.

VOS, Kilian; SPLINTER, Kristen D.; HARLEY, Mitchell D.; SIMMONS, Joshua A.; TURNER, Ian L. CoastSat: A Google Earth Engine-enabled Python toolkit to extract shorelines from publicly available satellite imagery. **ELSEVIER - Estuarine, Coastal and Shelf Science**, v.122. 2019.

ZHANG, Lina; ZHANG, Lijuan; ZHANG, Liduo. Application research of digital media image processing technology based on wavelet transform. **EURASIP Journal on Image and Video Processing**.